# Detecção automática de anomalias fitossanitárias em hortaliças folhosas utilizando visão computacional e aprendizado de máquina

**José Pedro Vieira Silva, Leanderson André**

Bacharelado em Engenharia de Software
Universidade da Região de Joinville (Univille) – Joinville – SC – Brasil

vieirasilvajosepedro@gmail.com / leandersonandre@univille.br

***Abstract.*** *This work investigates to what extent a phytosanitary screening system for leafy vegetables, based on transfer learning, trained on public images audited for data leakage and equipped with confidence calibration and abstention, remains reliable on photographs taken under real field conditions. Three convolutional networks (EfficientNet-B0, MobileNetV2 and ResNet-50) are compared with paired McNemar tests, and a Vision Transformer (ViT-B/16) will be added under the same protocol. On a test set drawn from the same sources as the training data, EfficientNet-B0 reaches 98.48% balanced accuracy (95% CI 98.32–98.64) and outperforms the other two ($p < 10^{-12}$), yet the abstention threshold intercepts only 31% of its errors. On a source never seen in training, the previous model version scored 75.4% (N = 484); on 13 field photographs the current one scores 83.8%, a sample too small to distinguish model versions.*

***Resumo.*** *Este trabalho investiga em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em transfer learning, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo. Três redes convolucionais (EfficientNet-B0, MobileNetV2 e ResNet-50) são comparadas por teste de McNemar pareado, e um Vision Transformer (ViT-B/16) será acrescentado sob o mesmo protocolo. Em teste extraído das mesmas fontes do treino, o EfficientNet-B0 atinge 98,48% de acurácia balanceada (IC 95%: 98,32–98,64) e supera os outros dois ($p < 10^{-12}$), mas o limiar de abstenção intercepta apenas 31% dos seus erros. Em uma fonte nunca vista no treino, a versão anterior do modelo obteve 75,4% (N = 484); em 13 fotografias de campo, a atual obtém 83,8%, amostra insuficiente para distinguir versões do modelo.*

## 1. Introdução

Segundo o Censo Agropecuário de 2017, 77% dos estabelecimentos rurais brasileiros pertencem à agricultura familiar (IBGE, 2019), segmento no qual o diagnóstico fitossanitário ainda depende predominantemente de inspeção visual manual — processo lento, inconsistente e condicionado à experiência do produtor. Hortaliças folhosas como alface, rúcula, espinafre, acelga e couve são culturas de ciclo curto e alta perecibilidade, nas quais o atraso na identificação de doenças, pragas ou deficiências nutricionais se traduz rapidamente em perda de produção.

O aprendizado profundo tornou-se a abordagem dominante para o diagnóstico foliar automatizado desde que Mohanty, Hughes e Salathé (2016) reportaram acurácias superiores a 99% com redes neurais convolucionais (CNNs) treinadas no dataset PlantVillage. Esse desempenho, contudo, é obtido sobre imagens de estúdio — folha isolada, fundo homogêneo, iluminação controlada — e a literatura registra quedas acentuadas quando os mesmos modelos são aplicados a fotografias de lavoura, fenômeno denominado *domain gap* (Barbedo, 2018; Ahmad; Gamal; Saraswat, 2023). Some-se a isso um problema menos discutido: a validade do próprio protocolo de avaliação. Na primeira fase deste trabalho (TCC-I), uma auditoria por hash perceptual revelou que 57,35% do conjunto de teste era composto por fotografias quase idênticas a imagens de treino, o que invalidou a acurácia de 99,01% inicialmente obtida. Após a reconstrução do particionamento, o melhor modelo atingiu 98,49% de acurácia balanceada no domínio de teste, mas apenas 73,3% em uma validação exploratória com 13 fotografias de horta real.

Esses resultados deslocam o problema: a questão deixa de ser se uma CNN classifica folhas de estúdio e passa a ser quanto um sistema desse tipo vale em uso real. Como um sistema que erra com aparência de certeza transfere confiança indevida ao produtor, a calibração da confiança e a capacidade de abster-se fazem parte do objeto de estudo.

## 1.1 Questão de pesquisa

Diante do exposto, este trabalho busca responder à seguinte questão de pesquisa: **em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em redes neurais convolucionais com transfer learning, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e mecanismo de abstenção, mantém desempenho confiável quando aplicado a fotografias capturadas em condições reais de campo?**

A questão desdobra-se em três perguntas operacionais, que orientam a análise dos dados descrita na Seção 3.5: (Q1) qual arquitetura apresenta o melhor desempenho no domínio de teste, com significância estatística; (Q2) em que medida as probabilidades calibradas e o limiar de abstenção interceptam os erros do modelo; e (Q3) qual é a magnitude do *domain gap* entre laboratório e campo e se ele varia conforme a cultura, o tipo de manifestação do sintoma e a distância de captura.

## 1.2 Objetivos

O **objetivo geral** deste trabalho é avaliar o desempenho e a confiabilidade de um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, baseado em transfer learning com as redes convolucionais EfficientNet-B0, MobileNetV2 e ResNet-50 e, como arquitetura de contraste, o Vision Transformer ViT-B/16, quantificando com rigor estatístico a diferença entre o desempenho obtido em laboratório e em condições reais de campo.

Para atingi-lo, definem-se os seguintes **objetivos específicos**:

a) consolidar o conjunto de dados de treinamento a partir de fontes públicas, com deduplicação por hash perceptual e particionamento agrupado, reportando o vazamento residual entre partições;

b) comparar o desempenho das arquiteturas no conjunto de teste, com métricas robustas ao desbalanceamento de classes e teste estatístico pareado;

c) avaliar a calibração das probabilidades de saída e a eficácia do mecanismo de abstenção em interceptar erros de classificação;
d) construir um conjunto de validação de campo com gabarito, abrangendo mais de uma cultura, diferentes tipos de sintoma e diferentes distâncias de captura;
e) quantificar o *domain gap* entre laboratório e campo, com intervalos de confiança e testes adequados a amostras pequenas;
f) investigar se o desempenho em campo varia conforme a cultura, o tipo de manifestação do sintoma (cromática ou estrutural) e a distância de captura.

## 2. Revisão da literatura

### 2.1 Aprendizado profundo e transfer learning no diagnóstico foliar

As CNNs extraem hierarquias de características visuais por camadas convolucionais e dominam a classificação de imagens (Russell; Norvig, 2022). A ResNet-50 (He et al., 2016) introduziu conexões residuais, com 25,6 milhões de parâmetros; a MobileNetV2 (Sandler et al., 2018) usa convoluções separáveis e blocos residuais invertidos, com 3,4 milhões, favorecendo dispositivos móveis; e a EfficientNet-B0 (Tan; Le, 2019) equilibra profundidade, largura e resolução por escalonamento composto, com 5,3 milhões. Os Vision Transformers (Dosovitskiy et al., 2021) substituem a convolução por autoatenção sobre blocos de 16×16 pixels; o ViT-B/16 tem 86,6 milhões de parâmetros e menos viés indutivo espacial que as CNNs. O transfer learning reutiliza pesos aprendidos no ImageNet como ponto de partida para a tarefa-alvo (Faceli et al., 2023), com eficácia demonstrada no diagnóstico foliar (Mohanty; Hughes; Salathé, 2016; Too et al., 2019). Barbedo (2018), contudo, mostra que ampliar o volume de dados tem retorno decrescente se a diversidade das condições de captura não aumenta.

### 2.2 Validade experimental: vazamento de dados e domain gap

Vazamento de dados designa a presença, no conjunto de avaliação, de informação indisponível no momento da predição real, tipicamente por contaminação a partir do treino (Kaufman et al., 2012). Em imagens, a forma mais comum é a duplicação quase exata: a mesma fotografia com recorte, compressão ou rotação diferentes, distribuída entre treino e teste por um particionamento aleatório por arquivo. Datasets públicos de doenças de plantas frequentemente redistribuem o PlantVillage entre si, o que agrava o risco. Geirhos et al. (2020) enquadram o fenômeno no conceito mais amplo de *shortcut learning*: redes profundas exploram qualquer regularidade que reduza a perda, e um teste que compartilhe essa regularidade não a detecta.

O *domain gap* é a discrepância entre o desempenho em condições controladas e em condições de uso. Modelos treinados em imagens de estúdio podem cair para a faixa de 31% a 72% de acurácia em fotografias de lavoura, que contêm solo, sombra, sobreposição de folhas e iluminação variável (Ahmad; Gamal; Saraswat, 2023; Upadhyay et al., 2025). Neste trabalho o salto é duplo: de estúdio para campo e de espécies-proxy para espécies-alvo, pois o PlantVillage não contém as hortaliças-alvo.

### 2.3 Calibração de confiança e classificação seletiva

Guo et al. (2017) demonstraram que as probabilidades produzidas por redes profundas modernas são sistematicamente mal calibradas e propuseram o *temperature scaling*, que

divide os logits por um escalar T aprendido na validação sem alterar a classe predita. A calibração é medida pelo Erro de Calibração Esperado (ECE), que compara confiança declarada e acurácia observada em faixas de confiança (Naeini; Cooper; Hauskrecht, 2015). Sobre um modelo calibrado constrói-se um classificador seletivo, que se abstém abaixo de um limiar $\tau$, trocando cobertura por acurácia seletiva (Geifman; El-Yaniv, 2017). Complementarmente, o índice Excess Green ($ExG = 2g - r - b$), proposto por Woebbecke et al. (1995), permite rejeitar imagens sem vegetação antes da inferência.

## 3. Procedimentos metodológicos

### 3.1 Caracterização da pesquisa

Quanto à abordagem, a pesquisa é quantitativa, pois os resultados são expressos por métricas numéricas e submetidos a análise estatística; quanto aos objetivos, é exploratória e descritiva; quanto aos procedimentos técnicos, é experimental, uma vez que as variáveis de interesse — arquitetura, calibração, limiar de abstenção e domínio de avaliação — são manipuladas sob condições controladas e reprodutíveis (Gil, 2010). Todo o pipeline é executado por script, com semente fixa (42) e registro dos parâmetros e métricas de cada execução.

### 3.2 Dados de treinamento e teste

O dataset binário (saudável × anômalo) é construído a partir de seis fontes públicas do Kaggle, incluindo o PlantVillage como proxy visual e datasets específicos de alface. A rotulagem é automática, por busca em largura sobre a árvore de diretórios, e cada decisão pasta-rótulo é registrada em um mapa de auditoria. Para evitar vazamento, cada imagem é reduzida a um hash perceptual invariante às oito transformações do grupo diedral D4; imagens com distância de Hamming $\leq 4$ são agrupadas por união-busca e cada grupo é atribuído integralmente a uma única partição (≈70/15/15, estratificada por classe). A versão atual contém 170.772 imagens — 120.861 de treino, 25.944 de validação e 23.967 de teste — com vazamento residual de 0,04% no teste, métrica usada como critério de aceitação do particionamento. As três partições provêm das mesmas seis fontes, em proporções quase idênticas; o teste mede, portanto, desempenho intra-fonte.

Em um quarto ciclo foram incorporados dois lotes preparados com o mesmo protocolo: 3.209 imagens de espinafre-de-malabar (*Basella alba*, e não *Spinacia oleracea*) e 1.142 recortes de 49 fotografias de alface com míldio, particionados pela fotografia de origem.

### 3.3 Modelos e treinamento

As três CNNs são inicializadas com pesos do ImageNet e ajustadas integralmente por até 30 épocas (otimizador AdamW, taxa de aprendizado de $10^{-3}$, escalonador de cosseno, parada antecipada com paciência 10, entropia cruzada com *label smoothing* de 0,1 e amostragem ponderada pelo inverso da frequência de classe), com imagens de 224×224 pixels. O ViT-B/16 segue o mesmo protocolo de dados, perda, seleção de modelo e calibração; mudam apenas os hiperparâmetros de otimização, ajustados ao que é usual no ajuste fino de transformers: taxa de aprendizado de $5\times10^{-5}$, decaimento de pesos de 0,05, duas épocas de aquecimento e limitação da norma do gradiente. Compara-se, portanto, cada arquitetura com uma receita adequada a ela, e não com hiperparâmetros idênticos. Após o treino, cada modelo é calibrado por *temperature*

*scaling* no conjunto de validação, e o limiar de abstenção $\tau$ é escolhido como o menor valor, a partir de 0,85, que assegura acurácia seletiva de pelo menos 98% na validação. Em produção, o sistema devolve um de quatro veredictos: saudável, anômalo, inconclusivo (confiança $< \tau$) ou não é folha (fração de pixels vegetativos por ExG inferior a 10%).

### 3.4 Coleta dos dados de campo

Os dados de campo serão coletados em hortas da região de Joinville (SC), com telefone celular, sob luz natural e sem preparação da cena. A meta é de 100 a 300 fotografias no total, com mínimo de 15 e meta de 25 fotografias por cultura incluída — priorizando cobrir bem ao menos duas culturas além da alface, em vez de cobrir superficialmente as cinco. Busca-se proporção próxima de 50/50 entre folhas saudáveis e anômalas em cada cultura e variedade de sintomas (manchas, clorose, oídio ou míldio, perfurações por inseto, murcha). Para 20% a 30% das folhas de interesse, são tiradas três fotografias em distâncias diferentes: aproximada, média e ampla. Cada cultura inclui ainda duas ou três imagens sem folha (solo, mão, parede), para verificar a guarda de vegetação.

Quatro regras garantem a validade do conjunto: (i) o rótulo de cada fotografia é registrado no momento da coleta, antes de qualquer inferência, e fotografias ambíguas são excluídas com o motivo anotado; (ii) as fotografias de campo nunca são usadas para treinamento; (iii) comparações entre versões do modelo usam exatamente o mesmo conjunto de fotografias; e (iv) as 13 fotografias já utilizadas, por terem orientado decisões de desenvolvimento no TCC-I, são tratadas como conjunto histórico e reportadas separadamente da estimativa final.

### 3.5 Como os dados serão analisados

A análise é organizada em quatro blocos, que respondem às perguntas operacionais Q1 a Q3. O Quadro 1 relaciona cada objetivo específico aos dados e às técnicas de análise. Adota-se nível de significância $\alpha = 0{,}05$ e, sempre que houver múltiplas comparações sobre os mesmos dados, a correção sequencial de Holm (1979). As análises são implementadas em Python.

#### 3.5.1 Desempenho no domínio de teste (Q1)

Considerando a classe anômala como positiva, calculam-se a partir da matriz de confusão a acurácia global, a precisão, a revocação, o F1-score por classe e macro, a área sob a curva ROC (AUC) e a latência média de inferência. A **métrica principal é a acurácia balanceada** (Equação 1), média das revocações das duas classes, que não é inflada pelo desbalanceamento de aproximadamente 1,35:1 do dataset (Brodersen et al., 2010):

$$AB = \tfrac{1}{2} \cdot \left[ \frac{VP}{(VP + FN)} + \frac{VN}{(VN + FP)} \right] \tag{1}$$

Os falsos negativos — plantas doentes declaradas saudáveis — são reportados separadamente, por constituírem o erro de maior custo agronômico. Os intervalos de confiança de 95% das métricas são estimados por bootstrap estratificado por classe, com 10.000 reamostragens (Efron; Tibshirani, 1993). Como todas as arquiteturas são avaliadas sobre as mesmas 23.967 imagens, a comparação entre pares de modelos usa o teste de McNemar (McNemar, 1947), recomendado por Dietterich (1998) para comparar

classificadores sobre um mesmo conjunto de teste. O teste considera apenas os casos discordantes — *b*, imagens que só o modelo A acerta, e *c*, as que só o modelo B acerta:

$$\chi^2 = ( |b - c| - 1 )^2 / ( b + c ) \quad (2)$$

Um classificador trivial que sempre responde "anômalo" (58,66% de acurácia global, 50% de acurácia balanceada) serve de piso de referência.

### 3.5.2 Calibração e classificação seletiva (Q2)

A calibração é avaliada pelo ECE com $M = 15$ faixas de confiança de igual largura (Equação 3), onde $B_m$ é o conjunto de predições cuja confiança cai na faixa $m$ e $n$ é o total de predições, antes e depois do *temperature scaling*, acompanhado do diagrama de fiabilidade:

$$ECE = \Sigma_m ( |B_m| / n ) \cdot | \text{acc}(B_m) - \text{conf}(B_m) | \quad (3)$$

O mecanismo de abstenção é avaliado por três medidas: a **cobertura** (fração de imagens que recebem diagnóstico), a **acurácia seletiva** (acurácia entre as imagens diagnosticadas) e a **fração de erros interceptados** (erros com confiança inferior a $\tau$). A curva risco–cobertura, obtida variando $\tau$ entre 0,50 e 0,99, permite discutir o ponto de operação escolhido. Compara-se ainda a confiança calibrada média de acertos e erros pelo teste de Mann-Whitney, para verificar se a confiança separa as duas situações.

### 3.5.3 Desempenho em campo e domain gap (Q3)

Em campo, cada fotografia tem três desfechos possíveis: acerto, erro ou abstenção. As abstenções não são contadas como erro nem como acerto; são reportadas como taxa própria, e as métricas de acerto são calculadas sobre os diagnósticos efetivamente emitidos, de forma uniforme em todas as versões do modelo. As imagens sem folha são analisadas à parte, pela taxa de rejeição correta da guarda de vegetação.

Como as amostras de campo são pequenas, toda proporção é acompanhada do intervalo de confiança de Wilson a 95% (Wilson, 1927), que mantém boa cobertura mesmo com N reduzido, ao contrário da aproximação normal. Para a acurácia balanceada, que é média de duas proporções, o intervalo é estimado por bootstrap estratificado. O *domain gap* é definido como a diferença entre a acurácia balanceada no teste e em campo; como a incerteza do teste (N = 23.967) é desprezível frente à de campo, seu intervalo é determinado essencialmente pelo intervalo de campo. A comparação entre versões do modelo sobre as mesmas fotografias utiliza o teste de McNemar em sua forma exata (binomial sobre os pares discordantes).

O tamanho de amostra pretendido decorre da amplitude do intervalo de Wilson para uma proporção de 80%: mais de 40 pontos percentuais com as 13 fotografias atuais, 15,5 com 100 e 9,0 com 300, o que já permite detectar diferenças da magnitude do *domain gap* esperado.

### 3.5.4 Análises estratificadas e análise qualitativa dos erros

Para responder à segunda parte de Q3, a acurácia de campo é desagregada por três fatores, cada um associado a uma hipótese exploratória. **H1**: o desempenho difere entre culturas, já que apenas a alface possui dados de treino específicos. **H2**: o modelo erra mais em sintomas estruturais (murcha, perfurações) do que em sintomas cromáticos (manchas, clorose, revestimentos), hipótese levantada pela inspeção dos erros de campo

no TCC-I. **H3**: o desempenho diminui à medida que a distância de captura aumenta. H1 e H3 são testadas pelo teste exato de Fisher generalizado (Freeman-Halton) sobre tabelas de contingência fator × desfecho, e H3 também pelo teste de tendência de Cochran-Armitage, dado que as distâncias são ordenadas; H2 é testada pelo teste exato de Fisher em tabela 2×2 (Agresti, 2013). Como os subgrupos serão pequenos, reportam-se também os tamanhos de efeito — diferenças de proporções com intervalo de Newcombe (1998) —, e os resultados são interpretados como exploratórios, e não confirmatórios.

Por fim, cada erro de campo é examinado qualitativamente com mapas Grad-CAM (Selvaraju et al., 2017), gerados sobre a última camada de características de cada arquitetura, e classificado quanto à causa provável: sintoma sutil, enquadramento amplo, fundo com vegetação, iluminação ou rótulo duvidoso.

**Quadro 1. Relação entre objetivos específicos, dados e técnicas de análise**

| Objetivo | Dados | Técnicas de análise |
|---|---|---|
| a) Consolidar o dataset | Imagens públicas; hashes perceptuais | Taxa de redundância; vazamento residual por partição (critério < 1%) |
| b) Comparar arquiteturas | Teste (23.967 imagens) | Acurácia balanceada, F1 macro, AUC, falsos negativos; IC por bootstrap; McNemar com correção de Holm |
| c) Calibração e abstenção | Validação e teste | ECE e diagrama de fiabilidade; cobertura, acurácia seletiva, erros interceptados; curva risco–cobertura; Mann-Whitney |
| d) Conjunto de campo | Fotografias de horta com gabarito | Estatística descritiva por cultura, classe, sintoma e distância; registro de exclusões |
| e) Quantificar o domain gap | Teste × campo | Diferença de acurácia balanceada; IC de Wilson e bootstrap; McNemar exato entre versões |
| f) Fatores do desempenho | Campo estratificado | Fisher / Freeman-Halton; Cochran-Armitage; IC de Newcombe; Grad-CAM dos erros |

Fonte: elaboração própria (2026).

## 4. Análise dos dados e discussão dos resultados

Os resultados vão até o quarto ciclo de treinamento. Q1 e Q2 já têm resposta no domínio de teste para as três CNNs; o ViT-B/16 e as análises de campo (Q3) dependem do treinamento ainda por concluir e da coleta descrita na Seção 3.4.

**Tabela 1. Desempenho no conjunto de teste (23.967 imagens), quarto ciclo**

| Modelo | Parâm. | Acur. bal. | F1 macro | AUC | ECE | FN | Latência |
|---|---|---|---|---|---|---|---|
| EfficientNet-B0 | 5,3 M | 98,48% | 98,44% | 0,9982 | 0,0039 | 209 | 8,0 ms |
| MobileNetV2 | 3,4 M | 97,89% | 97,83% | 0,9976 | 0,0055 | 294 | 5,1 ms |
| ResNet-50 | 25,6 M | 97,82% | 97,70% | 0,9966 | 0,0061 | 352 | 5,8 ms |

FN = falsos negativos. Latência em GPU RTX 3050 (6 GB). Fonte: elaboração própria (2026).

O EfficientNet-B0 obteve o melhor resultado em todas as métricas de qualidade. O intervalo de confiança de 95% da sua acurácia balanceada (98,32% a 98,64%) não se sobrepõe aos do MobileNetV2 (97,70% a 98,07%) e do ResNet-50 (97,63% a 98,00%), e o teste de McNemar exato com correção de Holm confirma a diferença ($p = 9{,}0\times10^{-13}$ e $p = 2{,}6\times10^{-17}$). MobileNetV2 e ResNet-50 não diferem entre si ($p = 0{,}13$), embora o

segundo tenha 7,5 vezes mais parâmetros. Isso responde a Q1 neste teste; com um único treino por modelo, a conclusão não se estende às arquiteturas em geral.

Quanto a Q2, o *temperature scaling* reduziu o ECE do EfficientNet-B0 na validação de 0,0509 para 0,0027. No teste, a confiança calibrada separa acertos de erros (média de 0,990 contra 0,874; Mann-Whitney, $p < 0,001$), mas o limiar $\tau = 0,85$ intercepta apenas 113 dos 363 erros (31,1%), com abstenção em 1,2% das imagens: mais de dois terços dos erros saem com confiança elevada.

A Tabela 1 deve ser lida com uma ressalva: o teste é extraído das mesmas seis fontes do treino, de modo que os 98,48% são uma acurácia intra-fonte. A medida disponível fora dessas fontes é o lote de espinafre-de-malabar, que o modelo do terceiro ciclo nunca viu: nele, a acurácia balanceada do EfficientNet-B0 foi de 75,4% (N = 484), 23 pontos abaixo, embora as imagens também sejam de folha isolada sobre fundo claro. Incorporado o lote ao treino, o mesmo teste subiu para 88,4% (IC 95%: 85,3% a 91,2%; McNemar exato, p de Holm = $5,9\times10^{-12}$). No teste original, EfficientNet-B0 e ResNet-50 não mudaram entre os dois ciclos (p = 1,00), mas o MobileNetV2 caiu de 98,18% para 97,89% (p de Holm = 0,015). O ganho é significativo, mas intra-fonte: o modelo aprende a aparência das fontes de treino, e isso não informa sobre o campo.

**Tabela 2. Validação exploratória em campo (13 fotografias de alface), por ciclo**

| Ciclo | Correção aplicada | Diagnósticos | Acertos | Proporção | IC 95% (Wilson) |
|---|---|---|---|---|---|
| 1 | Vazamento de dados | 12 de 13 | 11 | 91,7% | [64,6%; 98,5%] |
| 2 | Abstenção; dados de alface | 13 de 13 | 10 | 76,9% | [49,7%; 91,8%] |
| 3 | Rotulagem automática | 11 de 13 | 8 | 72,7% | [43,4%; 90,3%] |
| 4 | Espinafre e míldio no treino | 13 de 13 | 11 | 84,6% | [57,8%; 95,7%] |

Fonte: elaboração própria (2026).

A Tabela 2 mostra por que a análise estatística é central neste trabalho. Em pontos estimados, o desempenho de campo teria piorado nos três primeiros ciclos, mesmo com a correção de defeitos reais — entre eles, 3.972 imagens de alface saudável rotuladas como doentes. No entanto, os quatro intervalos de Wilson se sobrepõem entre 64,6% e 90,3%: com N = 13, as versões são estatisticamente indistinguíveis. A amostra atual foi suficiente para revelar o defeito de rotulagem, invisível às métricas de laboratório, mas não tem poder para decidir entre modelos, o que justifica a coleta planejada.

Os nove erros emitidos em campo nos quatro ciclos tiveram confiança calibrada entre 0,949 e 0,999, e no quarto ciclo não houve abstenção. O limiar $\tau$ é ajustado na validação, que compartilha a distribuição do treino; fora dela, o ECE passou de 0,003 para 0,146. A calibração precisa ser verificada no domínio de uso.

## 5. Conclusão

No domínio de teste, Q1 e Q2 têm resposta para as três CNNs: o EfficientNet-B0 supera os outros dois com significância estatística e suas probabilidades são bem calibradas, mas o limiar de abstenção deixa passar mais de dois terços dos erros. A questão central — quanto um sistema de triagem fitossanitária treinado em imagens públicas vale em condições reais de campo — permanece aberta: o desempenho é de 98,48% nas fontes de treino, foi de 75,4% em uma fonte nunca vista e de 84,6% de acertos em 13 fotografias de campo, com intervalo de 57,8% a 95,7%.

As próximas etapas são o treinamento do ViT-B/16 e a coleta do conjunto de campo, com fotografias de fundo real, pré-requisito para as análises das Seções 3.5.3 e 3.5.4. Estão em avaliação a separação das fotografias por horta, em conjuntos de avaliação e de adaptação, e um teste direto da dependência do fundo.

## Referências


AGRESTI, A. **Categorical data analysis**. 3. ed. Hoboken: Wiley, 2013.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. **IEEE Access**, v. 11, p. 9042-9057, 2023. DOI: 10.1109/ACCESS.2023.3240100.

BARBEDO, J. G. A. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. **Computers and Electronics in Agriculture**, v. 153, p. 46-53, 2018. DOI: 10.1016/j.compag.2018.08.013.

BRODERSEN, K. H. et al. The balanced accuracy and its posterior distribution. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 20., 2010, Istambul. **Proceedings** [...]. IEEE, 2010. p. 3121-3124. DOI: 10.1109/ICPR.2010.764.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895-1923, 1998. DOI: 10.1162/089976698300017197.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 9., 2021. **Proceedings** [...]. 2021.

EFRON, B.; TIBSHIRANI, R. J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993.

FACELI, K. et al. **Inteligência artificial**: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2023.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. **Proceedings** [...]. 2017.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. **Nature Machine Intelligence**, v. 2, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

GIL, A. C. **Como elaborar projetos de pesquisa**. 5. ed. São Paulo: Atlas, 2010.

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017. **Proceedings** [...]. PMLR, 2017. p. 1321-1330.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016. **Proceedings** [...]. IEEE, 2016. p. 770-778.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Agropecuário 2017**: resultados definitivos. Rio de Janeiro: IBGE, 2019.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, n. 2, p. 153-157, 1947. DOI: 10.1007/BF02295996.

MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. **Frontiers in Plant Science**, v. 7, 1419, 2016. DOI: 10.3389/fpls.2016.01419.

NAEINI, M. P.; COOPER, G. F.; HAUSKRECHT, M. Obtaining well calibrated probabilities using Bayesian binning. In: AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE, 29., 2015. **Proceedings** [...]. AAAI, 2015. p. 2901-2907.

NEWCOMBE, R. G. Interval estimation for the difference between independent proportions: comparison of eleven methods. **Statistics in Medicine**, v. 17, n. 8, p. 873-890, 1998.

RUSSELL, S.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2022.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018. **Proceedings** [...]. IEEE, 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017. **Proceedings** [...]. IEEE, 2017. p. 618-626.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019. **Proceedings** [...]. PMLR, 2019. p. 6105-6114.

TOO, E. C. et al. A comparative study of fine-tuning deep learning models for plant disease identification. **Computers and Electronics in Agriculture**, v. 161, p. 272-279, 2019. DOI: 10.1016/j.compag.2018.03.032.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. **Artificial Intelligence Review**, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927. DOI: 10.2307/2276774.

WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. **Transactions of the ASAE**, v. 38, n. 1, p. 259-269, 1995. DOI: 10.13031/2013.27838.