Detecção automática de anomalias fitossanitárias em hortaliças folhosas utilizando visão computacional e aprendizado de máquina

José Pedro Vieira Silva, Leanderson André

Bacharelado em Engenharia de Software
Universidade da Região de Joinville (Univille) – Joinville – SC – Brasil

{josepedro, leandersonandre}@univille.br

Abstract. *This work investigates to what extent a phytosanitary screening system for leafy vegetables, based on transfer learning, trained on public images audited for data leakage and equipped with confidence calibration and abstention, remains reliable on photographs taken under real field conditions. Three convolutional networks (EfficientNet-B0, MobileNetV2 and ResNet-50) and a Vision Transformer (ViT-B/16) are compared with paired McNemar tests. On a test set drawn from the same sources as the training data, EfficientNet-B0 and ViT-B/16 tie at 98.48% balanced accuracy (95% CI 98.32 –98.64; p = 0.26) and outperform the other two ($p < 10^{-11}$), yet the abstention threshold intercepts only 31% and 15% of their errors. On a source never seen in training, the previous model version scored 75.4% (N = 484); on 13 field photographs the current one scores 83.8%, a sample too small to distinguish model versions.*

Resumo. *Este trabalho investiga em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em transfer learning, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo. Três redes convolucionais (EfficientNet-B0, MobileNetV2 e ResNet-50) e um Vision Transformer (ViT-B/16) são comparados por teste de McNemar pareado. Em teste extraído das mesmas fontes do treino, EfficientNet-B0 e ViT-B/16 empatam em 98,48% de acurácia balanceada (IC 95%: 98,32–98,64; p = 0,26) e superam os outros dois ($p < 10^{-11}$), mas o limiar de abstenção intercepta apenas 31% e 15% dos seus erros. Em uma fonte nunca vista no treino, a versão anterior do modelo obteve 75,4% (N = 484); em 13 fotografias de campo, a atual obtém 83,8%, amostra insuficiente para distinguir versões do modelo.*

1. Introdução

A inteligência artificial (IA) consolidou-se como uma das áreas mais ativas da computação, e o aprendizado profundo tornou-se a abordagem predominante em tarefas de percepção, como a classificação de imagens (Russell; Norvig, 2022). Redes neurais sustentam hoje aplicações em diagnóstico médico por imagem, inspeção industrial e agricultura de precisão, e o *transfer learning* tornou essas técnicas acessíveis a problemas com poucos dados rotulados, ao reaproveitar modelos pré-treinados (Faceli et al., 2023).

Na agricultura, uma das aplicações mais estudadas é o diagnóstico de doenças de plantas a partir de fotografias de folhas. O tema é relevante no Brasil, onde 77% dos estabelecimentos rurais pertencem à agricultura familiar (IBGE, 2019), segmento no qual o diagnóstico fitossanitário ainda depende predominantemente de inspeção visual manual. Hortaliças folhosas como alface, rúcula, espinafre, acelga e couve são culturas de ciclo curto e alta perecibilidade, nas quais o atraso na identificação de doenças, pragas ou deficiências nutricionais se traduz rapidamente em perda de produção.

Os trabalhos relacionados mostram um contraste entre laboratório e campo. Redes neurais convolucionais (CNNs) treinadas no dataset PlantVillage superam 99% de acurácia (Mohanty; Hughes; Salathé, 2016), mas sobre imagens de estúdio — folha isolada, fundo homogêneo, iluminação controlada. Em fotografias de lavoura a acurácia cai, fenômeno denominado *domain gap* (Barbedo, 2018), e uma revisão sistemática recente situa o campo entre 70% e 85% (Shafay et al., 2025). Estudos recentes passaram a combinar validação sem vazamento de dados, calibração da confiança e abstenção (Ergün et al., 2026; Workneh et al., 2026), mas em culturas como videira e amêndoa; para hortaliças folhosas os trabalhos são menos numerosos e avaliados em partições do próprio conjunto de dados (Abbasi; Martinez; Ahmad, 2023; Kabya et al., 2026).

O problema deste trabalho nasce dessa lacuna e de um resultado próprio. Na primeira fase (TCC-I), uma auditoria por *hash* perceptual revelou que 57,35% do conjunto de teste era composto por fotografias quase idênticas a imagens de treino, o que invalidou a acurácia de 99,01% inicialmente obtida. Após a reconstrução do particionamento, o melhor modelo atingiu 98,49% de acurácia balanceada no domínio de teste, mas apenas 73,3% em uma validação exploratória com 13 fotografias de horta real. A questão passa a ser quanto um sistema desse tipo vale em uso real; e, como um sistema que erra com aparência de certeza transfere confiança indevida ao produtor, a calibração da confiança e a capacidade de abster-se fazem parte do objeto de estudo.

Diante do exposto, a questão de pesquisa é: em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em *transfer learning*, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e mecanismo de abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo? Ela se desdobra em três perguntas operacionais: (Q1) qual arquitetura apresenta o melhor desempenho no domínio de teste, com significância estatística; (Q2) em que medida as probabilidades calibradas e o limiar de abstenção interceptam os erros do modelo; e (Q3) qual é a magnitude do *domain gap* entre laboratório e campo e se ele varia conforme a cultura, o tipo de manifestação do sintoma e a distância de captura.

O objetivo geral é avaliar o desempenho e a confiabilidade de um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, baseado em *transfer learning* com as redes convolucionais EfficientNet-B0, MobileNetV2 e ResNet-50 e, como arquitetura de contraste, o *Vision Transformer* ViT-B/16, quantificando com rigor estatístico a diferença entre o desempenho em laboratório e em condições reais de campo. Os objetivos específicos são: (a) consolidar o conjunto de dados de treinamento a partir de fontes públicas, com deduplicação e particionamento agrupado, reportando o vazamento residual; (b) comparar as arquiteturas no conjunto de teste, com métricas robustas ao desbalanceamento de classes e teste estatístico pareado; (c) avaliar a calibração das probabilidades e a eficácia da abstenção em interceptar erros; (d)

construir um conjunto de validação de campo com gabarito, abrangendo mais de uma cultura, diferentes tipos de sintoma e distâncias de captura; (e) quantificar o *domain gap* entre laboratório e campo, com intervalos de confiança e testes adequados a amostras pequenas; e (f) investigar se o desempenho em campo varia conforme a cultura, o tipo de manifestação do sintoma (cromática ou estrutural) e a distância de captura.

2. Revisão da literatura

Esta seção apresenta os modelos utilizados e o *transfer learning*, os conceitos que sustentam a validade da avaliação e os trabalhos relacionados, com os quais os resultados são comparados na Seção 4.

2.1 Modelos de aprendizado profundo e transfer learning

As CNNs extraem hierarquias de características visuais por camadas convolucionais e dominam a classificação de imagens (Russell; Norvig, 2022). A ResNet-50 introduziu conexões residuais e tem, na versão original de 1.000 classes, 25,6 milhões de parâmetros (He et al., 2016); a MobileNetV2 usa convoluções separáveis e blocos residuais invertidos, com 3,4 milhões (Sandler et al., 2018); e a EfficientNet-B0 equilibra profundidade, largura e resolução por escalonamento composto, com 5,3 milhões (Tan; Le, 2019). Os *Vision Transformers* substituem a convolução por autoatenção sobre blocos de 16×16 pixels; o ViT-B/16 tem 86,6 milhões de parâmetros e menos viés indutivo espacial que as CNNs (Dosovitskiy et al., 2021). O *transfer learning* reutiliza pesos aprendidos no ImageNet como ponto de partida para a tarefa-alvo (Faceli et al., 2023), com eficácia demonstrada no diagnóstico foliar (Mohanty; Hughes; Salathé, 2016). Ampliar o volume de dados, contudo, tem retorno decrescente se a diversidade das condições de captura não aumenta (Barbedo, 2018).

2.2 Validade da avaliação: vazamento, domain gap e calibração

Vazamento de dados designa a presença, no conjunto de avaliação, de informação indisponível no momento da predição real, tipicamente por contaminação a partir do treino (Kaufman et al., 2012). Em imagens, a forma mais comum é a duplicação quase exata: a mesma fotografia com recorte, compressão ou rotação diferentes, distribuída entre treino e teste por um particionamento aleatório por arquivo. O fenômeno enquadra-se no conceito mais amplo de *shortcut learning*: redes profundas exploram qualquer regularidade que reduza a perda, e um teste que compartilhe essa regularidade não a detecta (Geirhos et al., 2020).

O *domain gap* é a discrepância entre o desempenho em condições controladas e em condições de uso. Modelos treinados em imagens de estúdio podem cair para a faixa de 31% a 72% de acurácia em fotografias de lavoura, que contêm solo, sombra, sobreposição de folhas e iluminação variável (Ahmad; Gamal; Saraswat, 2023; Upadhyay et al., 2025). Neste trabalho o salto é duplo: de estúdio para campo e de espécies-*proxy* para espécies-alvo, pois o PlantVillage não contém as hortaliças-alvo.

As probabilidades produzidas por redes profundas modernas são sistematicamente mal calibradas, o que se corrige com o *temperature scaling*, que divide os *logits* por um escalar T aprendido na validação sem alterar a classe predita (Guo et al., 2017). A calibração é medida pelo Erro de Calibração Esperado (ECE), que compara confiança declarada e acurácia observada em faixas de confiança (Naeini; Cooper; Hauskrecht,

2015). Sobre um modelo calibrado constrói-se um classificador seletivo, que se abstém abaixo de um limiar τ, trocando cobertura por acurácia seletiva (Geifman; El-Yaniv, 2017). Complementarmente, o índice *Excess Green* (ExG = $2g - r - b$) permite rejeitar imagens sem vegetação antes da inferência (Woebbecke et al., 1995).

2.3 Trabalhos relacionados

A busca por trabalhos relacionados foi feita na Web of Science, em outubro de 2026, com termos de doença de plantas e aprendizado profundo combinados a generalização em campo, vazamento de dados, calibração e hortaliças folhosas; o Quadro 1 resume os estudos mais próximos. Classificadores que passam de 99% no PlantVillage caem para 26% a 30% no conjunto de campo PlantDoc, e o ajuste fino completo de um modelo de fundação piora a transferência (Nguyen et al., 2026); arquiteturas com *transformers* são, ainda assim, apontadas como mais robustas (Shafay et al., 2025). Dois estudos adotam protocolo semelhante ao deste trabalho: com amêndoa, a validação agrupada quase não altera o F1 macro, mas um teste com fontes disjuntas o reduz a 0,56 (Workneh et al., 2026); com videira, a EfficientNet-B0 obtém 73,8% em um conjunto externo (Ergün et al., 2026). Não foi localizado estudo que reúna, para hortaliças folhosas, auditoria de vazamento, calibração com abstenção e avaliação fora da fonte de treino.

Quadro 1. Trabalhos relacionados e comparação com este trabalho

Trabalho	Cultura	Protocolo de avaliação	Resultado fora da origem
Nguyen et al. (2026)	Várias	PlantVillage → PlantDoc; McNemar	26% a 30%; 51% com DINOv2 congelado
Ergün et al. (2026)	Videira	Conjunto externo; calibração	73,8%; ECE de 0,287 para 0,038
Workneh et al. (2026)	Amêndoa	Validação agrupada; calibração; abstenção	F1 macro de 0,98 para 0,56
Kabya et al. (2026)	Espinafre-de-malabar	Partição do próprio conjunto	97,3% (teste interno)
Este trabalho	Hortaliças folhosas	Deduplicação; calibração; abstenção	98,48% para 75,4% (fonte retida)

Fonte: elaboração própria (2026), a partir dos trabalhos citados.

3. Procedimentos metodológicos

A pesquisa é quantitativa quanto à abordagem, exploratória e descritiva quanto aos objetivos e experimental quanto aos procedimentos técnicos, pois arquitetura, calibração, limiar de abstenção e domínio de avaliação são manipulados sob condições controladas e reprodutíveis (Gil, 2010). Todo o *pipeline* é executado por *script*, com semente fixa (42) e registro dos parâmetros e métricas de cada execução.

3.1 Dados, modelos e treinamento

O dataset binário (saudável × anômalo) é construído a partir de seis fontes públicas do Kaggle, incluindo o PlantVillage como proxy visual e datasets específicos de alface. A rotulagem é automática, por busca em largura sobre a árvore de diretórios, e cada decisão pasta-rótulo é registrada em um mapa de auditoria. Para evitar vazamento, cada imagem é reduzida a um hash perceptual invariante às oito transformações do grupo diedral D4; imagens com distância de Hamming ≤ 4 são agrupadas por união-busca e cada grupo é atribuído integralmente a uma única partição (≈70/15/15, estratificada por

classe), descartando-se os grupos com rótulos contraditórios. Das 176.126 imagens reunidas restam 170.772 — 120.861 de treino, 25.944 de validação e 23.967 de teste —, com vazamento residual de 0,04% no teste por esse critério. As três partições provêm das mesmas seis fontes, em proporções quase idênticas; o teste mede, portanto, desempenho intra-fonte. O critério não alcança, porém, variantes muito alteradas da mesma fotografia: 23% do teste são rotações, recortes e filtros de fotografias de alface com outra variante no treino.

Em um quarto ciclo foram incorporados dois lotes preparados com o mesmo protocolo: 3.209 imagens de espinafre-de-malabar (*Basella alba*, e não *Spinacia oleracea*) e 1.142 recortes de 49 fotografias de alface com míldio, particionados pela fotografia de origem, o que eleva o conjunto a 175.123 imagens.

As três CNNs são inicializadas com pesos do ImageNet e ajustadas integralmente por até 30 épocas (otimizador AdamW, taxa de aprendizado de 10^{-3}, escalonador de cosseno, parada antecipada com paciência 10, entropia cruzada com *label smoothing* de 0,1 e amostragem ponderada pelo inverso da frequência de classe), com imagens de 224×224 pixels. O ViT-B/16 segue o mesmo protocolo de dados, perda, seleção de modelo e calibração; mudam apenas os hiperparâmetros de otimização, ajustados ao que é usual no ajuste fino de transformers: taxa de aprendizado de 5×10^{-5}, decaimento de pesos de 0,05, duas épocas de aquecimento e limitação da norma do gradiente. Após o treino, cada modelo é calibrado por *temperature scaling* no conjunto de validação, e o limiar de abstenção τ é escolhido como o menor valor, a partir de 0,85, que assegura acurácia seletiva de pelo menos 98% na validação. Em produção, o sistema devolve um de quatro veredictos: saudável, anômalo, inconclusivo (confiança $< \tau$) ou não é folha (fração de pixels vegetativos por ExG inferior a 10%).

3.2 Coleta dos dados de campo

Os dados de campo serão coletados em hortas da região de Joinville (SC), com telefone celular, sob luz natural e sem preparação da cena. A meta é de 100 a 300 fotografias no total, com mínimo de 15 e meta de 25 fotografias por cultura incluída. Busca-se proporção próxima de 50/50 entre folhas saudáveis e anômalas em cada cultura e variedade de sintomas (manchas, clorose, oídio ou míldio, perfurações por inseto, murcha). Para 20% a 30% das folhas de interesse, são tiradas três fotografias em distâncias diferentes: aproximada, média e ampla. Cada cultura inclui ainda duas ou três imagens sem folha (solo, mão, parede), para verificar a guarda de vegetação.

Quatro regras garantem a validade do conjunto: (i) o rótulo é registrado no momento da coleta, antes de qualquer inferência, e fotografias ambíguas são excluídas com o motivo anotado; (ii) as fotografias de campo nunca são usadas para treinamento; (iii) versões do modelo são comparadas sobre exatamente as mesmas fotografias; e (iv) as 13 fotografias já utilizadas no TCC-I formam um conjunto histórico, reportado à parte.

3.3 Análise dos dados

A análise responde, em sequência, às perguntas operacionais Q1 a Q3. O Quadro 2 relaciona cada objetivo específico aos dados e às técnicas de análise. Adota-se nível de significância $\alpha = 0{,}05$ e, sempre que houver múltiplas comparações sobre os mesmos dados, a correção sequencial de Holm (1979).

Para o desempenho no domínio de teste (Q1), considerando a classe anômala como positiva, calculam-se a partir da matriz de confusão a acurácia global, a precisão, a revocação, o F1-score por classe e macro, a área sob a curva ROC (AUC) e a latência média de inferência. A **métrica principal é a acurácia balanceada** (Equação 1), média das revocações das duas classes, que não é inflada pelo desbalanceamento de aproximadamente 1,35:1 do dataset (Brodersen et al., 2010):

$$AB = ½ \cdot [\ VP / (VP + FN) + VN / (VN + FP)\ ] \quad (1)$$

Os falsos negativos — plantas doentes declaradas saudáveis — são reportados separadamente, por constituírem o erro de maior custo agronômico. Os intervalos de confiança de 95% são estimados por *bootstrap* estratificado por classe, com 10.000 reamostragens (Efron; Tibshirani, 1993). Como todas as arquiteturas são avaliadas sobre as mesmas 23.967 imagens, pares de modelos são comparados pelo teste de McNemar, que considera apenas as imagens em que os dois modelos discordam (McNemar, 1947; Dietterich, 1998).

Para Q2, a calibração é avaliada pelo ECE com $M = 15$ faixas de confiança de igual largura (Equação 2), onde B_m é o conjunto de predições cuja confiança cai na faixa m e n é o total de predições, antes e depois do *temperature scaling*, acompanhado do diagrama de fiabilidade:

$$ECE = \Sigma_m\ (\ |B_m| / n\ ) \cdot |\ \mathrm{acc}(B_m) - \mathrm{conf}(B_m)\ | \quad (2)$$

O mecanismo de abstenção é avaliado pela cobertura (fração de imagens que recebem diagnóstico), pela acurácia seletiva (acurácia entre as imagens diagnosticadas) e pela fração de erros interceptados (erros com confiança inferior a τ). A curva risco–cobertura, com τ entre 0,50 e 0,99, permite discutir o ponto de operação, e o teste de Mann-Whitney compara a confiança calibrada de acertos e erros.

Para Q3, em campo, cada fotografia tem três desfechos possíveis: acerto, erro ou abstenção. As abstenções não são contadas como erro nem como acerto; são reportadas como taxa própria, e as métricas de acerto são calculadas sobre os diagnósticos efetivamente emitidos. As imagens sem folha são analisadas à parte, pela taxa de rejeição correta da guarda de vegetação.

Como as amostras de campo são pequenas, toda proporção é acompanhada do intervalo de confiança de Wilson a 95% (Wilson, 1927); para a acurácia balanceada, o intervalo é estimado por *bootstrap* estratificado. O *domain gap* é definido como a diferença entre a acurácia balanceada no teste e em campo, e versões do modelo são comparadas sobre as mesmas fotografias pelo teste de McNemar exato. O tamanho de amostra pretendido decorre da amplitude do intervalo de Wilson para uma proporção de 80%: mais de 40 pontos percentuais com as 13 fotografias atuais, 15,5 com 100 e 9,0 com 300.

Ainda em Q3, a acurácia de campo é desagregada por três fatores, cada um com uma hipótese exploratória: (H1) o desempenho difere entre culturas, já que apenas a alface possui dados de treino específicos; (H2) o modelo erra mais em sintomas estruturais (murcha, perfurações) do que em cromáticos (manchas, clorose, revestimentos); e (H3) o desempenho diminui com a distância de captura. H1 e H3 são testadas pelo teste exato de Fisher generalizado (Freeman-Halton), H3 também pelo teste de tendência de Cochran-Armitage, e H2 pelo teste exato de Fisher em tabela 2×2 (Agresti, 2013). Como os subgrupos serão pequenos, reportam-se as diferenças de proporções com

intervalo de confiança (Newcombe, 1998), e os resultados são interpretados como exploratórios.

Por fim, cada erro de campo é examinado qualitativamente com mapas Grad-CAM (Selvaraju et al., 2017) e classificado quanto à causa provável: sintoma sutil, enquadramento amplo, fundo com vegetação, iluminação ou rótulo duvidoso.

Quadro 2. Relação entre objetivos específicos, dados e técnicas de análise

Objetivo	Dados	Técnicas de análise
a) Consolidar o dataset	Imagens públicas; hashes perceptuais	Taxa de redundância; vazamento residual por partição (critério < 1%)
b) Comparar arquiteturas	Teste (23.967 imagens)	Acurácia balanceada, F1 macro, AUC, falsos negativos; IC por bootstrap; McNemar com correção de Holm
c) Calibração e abstenção	Validação e teste	ECE e diagrama de fiabilidade; cobertura, acurácia seletiva, erros interceptados; curva risco–cobertura; Mann-Whitney
d) Conjunto de campo	Fotografias de horta com gabarito	Estatística descritiva por cultura, classe, sintoma e distância; registro de exclusões
e) Quantificar o domain gap	Teste × campo	Diferença de acurácia balanceada; IC de Wilson e bootstrap; McNemar exato entre versões
f) Fatores do desempenho	Campo estratificado	Fisher / Freeman-Halton; Cochran-Armitage; IC de Newcombe; Grad-CAM dos erros

Fonte: elaboração própria (2026).

4. Análise dos dados e discussão dos resultados

Os resultados vão até o quarto ciclo de treinamento; as análises de campo (Q3) dependem da coleta descrita na Seção 3.2.

Tabela 1. Desempenho no conjunto de teste (23.967 imagens), quarto ciclo

Modelo	Parâm.	Acur. bal.	F1 macro	AUC	ECE	FN	Latência
EfficientNet-B0	4,0 M	98,48%	98,44%	0,9982	0,0039	209	7,2 ms
MobileNetV2	2,2 M	97,89%	97,83%	0,9976	0,0055	294	5,3 ms
ResNet-50	23,5 M	97,82%	97,70%	0,9966	0,0061	352	8,6 ms
ViT-B/16	85,8 M	98,48%	98,53%	0,9976	0,0018	137	19,4 ms

Parâm. = modelo treinado, com saída de duas classes. FN = falsos negativos. Latência em GPU RTX 3050 (6 GB), medida na mesma sessão para os quatro modelos. Fonte: elaboração própria (2026).

EfficientNet-B0 e ViT-B/16 empatam: têm a mesma acurácia balanceada e o mesmo intervalo de confiança de 95% (98,32% a 98,64%), e o teste de McNemar exato com correção de Holm não os distingue ($p = 0,26$). Ambos superam o MobileNetV2 (97,70% a 98,07%) e o ResNet-50 (97,63% a 98,00%), com $p \leq 1,4\times10^{-12}$, e estes dois não diferem entre si ($p = 0,26$), embora o segundo tenha dez vezes mais parâmetros. O perfil de erro, porém, é distinto: o ViT-B/16 comete menos falsos negativos (137 contra 209) e mais falsos positivos (204 contra 154), com 21 vezes mais parâmetros que o EfficientNet-B0 e latência 2,7 vezes maior. Isso responde a Q1 neste teste; com um único treino por modelo e hiperparâmetros de otimização próprios do ViT-B/16, a conclusão não se estende às arquiteturas em geral.

Quanto a Q2, o *temperature scaling* reduziu o ECE na validação de 0,0509 para 0,0027 no EfficientNet-B0 e de 0,0472 para 0,0022 no ViT-B/16. No teste, a confiança

calibrada do EfficientNet-B0 separa acertos de erros (média de 0,990 contra 0,874; Mann-Whitney, $p < 0,001$), mas o limiar $\tau = 0,85$ intercepta apenas 113 dos 363 erros (31,1%), com abstenção em 1,2% das imagens. No ViT-B/16 a interceptação é ainda menor: 51 dos 341 erros (15,0%), com abstenção em 0,5%. Nos dois modelos, mais de dois terços dos erros saem com confiança elevada; o ViT-B/16 tem o menor ECE da Tabela 1 e, ao mesmo tempo, a menor fração de erros interceptados, o que mostra que boa calibração média não garante que os erros se concentrem nas confianças baixas.

A Tabela 1 deve ser lida com uma ressalva: o teste é extraído das mesmas seis fontes do treino, de modo que os 98,48% são uma acurácia intra-fonte. A medida disponível fora dessas fontes é o lote de espinafre-de-malabar, que o modelo do terceiro ciclo nunca viu: nele, a acurácia balanceada do EfficientNet-B0 foi de 75,4% (N = 484), 23 pontos abaixo, embora as imagens também sejam de folha isolada sobre fundo claro. Incorporado o lote ao treino, o mesmo teste subiu para 88,4% (IC 95%: 85,3% a 91,2%; McNemar exato, p de Holm = $5,9\times10^{-12}$). O ViT-B/16 obteve 84,4% nesse lote (IC 95%: 80,9% a 87,7%), sem diferença significativa para o EfficientNet-B0 (p de Holm = 0,51) e com o pior ECE dos quatro modelos (0,11). No teste original, EfficientNet-B0 e ResNet-50 não mudaram entre os dois ciclos (p = 1,00), mas o MobileNetV2 caiu de 98,18% para 97,89% (p de Holm = 0,015). O ganho é significativo, mas intra-fonte: o modelo aprende a aparência das fontes de treino, e isso não informa sobre o campo.

Tabela 2. Validação exploratória em campo (13 fotografias de alface), por ciclo

Ciclo	Correção aplicada	Diagnósticos	Acertos	Proporção	IC 95% (Wilson)
1	Vazamento de dados	12 de 13	11	91,7%	[64,6%; 98,5%]
2	Abstenção; dados de alface	13 de 13	10	76,9%	[49,7%; 91,8%]
3	Rotulagem automática	11 de 13	8	72,7%	[43,4%; 90,3%]
4	Espinafre e míldio no treino	13 de 13	11	84,6%	[57,8%; 95,7%]
4*	ViT-B/16, mesmos dados	12 de 13	12	100%	[75,8%; 100%]

Ciclos 1 a 4: EfficientNet-B0. * ViT-B/16, dados do ciclo 4. Fonte: elaboração própria (2026).

A Tabela 2 mostra por que a análise estatística é central neste trabalho. Em pontos estimados, o desempenho de campo teria piorado nos três primeiros ciclos, mesmo com a correção de defeitos reais — entre eles, 3.972 imagens de alface saudável rotuladas como doentes. No entanto, os quatro intervalos de Wilson dos ciclos se sobrepõem entre 64,6% e 90,3%, e o do ViT-B/16, que acertou os 12 diagnósticos que emitiu e se absteve em uma fotografia, sobrepõe-se a todos eles: com N = 13, versões e arquiteturas são estatisticamente indistinguíveis. A amostra revelou o defeito de rotulagem, mas não tem poder para decidir entre modelos, o que justifica a coleta planejada.

Os nove erros emitidos em campo nos quatro ciclos, concentrados em quatro fotografias, tiveram confiança calibrada entre 0,949 e 0,999, e no quarto ciclo não houve abstenção. O limiar τ é ajustado na validação, que compartilha a distribuição do treino; fora dela, o ECE passou de 0,003 para 0,146. A calibração precisa ser verificada no domínio de uso.

Esses resultados são coerentes com os trabalhos do Quadro 1. A queda de 98,48% para 75,4% em uma fonte retida tem a mesma ordem de grandeza dos 73,8% da EfficientNet-B0 em um conjunto externo de videira (Ergün et al., 2026) e, como no estudo com amêndoa, só aparece quando a fonte é separada (Workneh et al., 2026); o contraste com os 97,3% reportados para o espinafre-de-malabar em partição interna (Kabya et al., 2026) indica que a diferença está no protocolo de avaliação, e não na cultura. O empate

entre ViT-B/16 e EfficientNet-B0 diverge da robustez atribuída aos *transformers* (Shafay et al., 2025), mas concorda com a evidência de que o ajuste fino completo não reduz o *domain gap* (Nguyen et al., 2026). A literatura atribui a perda à pouca diversidade das condições de captura no treino (Barbedo, 2018), e o próprio teste a reproduz: dentro de uma mesma fonte, as culturas fotografadas em lavoura (mandioca, arroz, cana-de-açúcar e café; N = 4.530) têm acurácia balanceada de 86,3% (IC 95%: 84,5% a 88,0%) no EfficientNet-B0 e concentram 81% dos seus erros, contra 99,7% nas demais culturas (N = 10.061); nas de lavoura, as quatro arquiteturas ficam entre 83,4% e 87,8%. Na calibração, o estudo de videira reduz o ECE do conjunto externo de 0,287 para 0,038 (Ergün et al., 2026), ao passo que aqui o ECE de campo permanece em 0,146 após a calibração feita na validação, o que recomenda reservar fotografias de campo para recalibração.

5. Conclusão

No domínio de teste, Q1 e Q2 têm resposta para as quatro arquiteturas: EfficientNet-B0 e ViT-B/16 empatam e superam as outras duas com significância estatística; suas probabilidades são bem calibradas, mas o limiar de abstenção deixa passar mais de dois terços dos erros. Trocar a CNN por um transformer com 21 vezes mais parâmetros não altera esse quadro, o que indica que o limite do sistema está nos dados, e não na arquitetura. A questão central — quanto um sistema de triagem fitossanitária treinado em imagens públicas vale em condições reais de campo — permanece aberta: o desempenho é de 98,48% nas fontes de treino, foi de 75,4% em uma fonte nunca vista e de 84,6% de acertos em 13 fotografias de campo, com intervalo de 57,8% a 95,7%.

A próxima etapa é a coleta do conjunto de campo, com fotografias de fundo real, pré-requisito para as análises de Q3 (Seção 3.3). Estão em avaliação a separação das fotografias por horta, em conjuntos de avaliação e de adaptação, e um teste direto da dependência do fundo.

Referências

ABBASI, R.; MARTINEZ, P.; AHMAD, R. Crop diagnostic system: a robust disease detection and management system for leafy green crops grown in an aquaponics facility. **Artificial Intelligence in Agriculture**, v. 10, p. 1-12, 2023. DOI: 10.1016/j.aiia.2023.09.001.

AGRESTI, A. **Categorical data analysis**. 3. ed. Hoboken: Wiley, 2013.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. **IEEE Access**, v. 11, p. 9042-9057, 2023. DOI: 10.1109/ACCESS.2023.3240100.

BARBEDO, J. G. A. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. **Computers and Electronics in Agriculture**, v. 153, p. 46-53, 2018. DOI: 10.1016/j.compag.2018.08.013.

BRODERSEN, K. H. et al. The balanced accuracy and its posterior distribution. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 20., 2010, Istambul. **Proceedings** [...]. IEEE, 2010. p. 3121-3124. DOI: 10.1109/ICPR.2010.764.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895-1923, 1998. DOI: 10.1162/089976698300017197.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 9., 2021. **Proceedings** [...]. 2021.

EFRON, B.; TIBSHIRANI, R. J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993.

ERGÜN, E. et al. Confidence and uncertainty aware deep learning for reliable grape leaf disease diagnosis under real world field conditions. **Frontiers in Plant Science**, v. 17, 1839652, 2026. DOI: 10.3389/fpls.2026.1839652.

FACELI, K. et al. **Inteligência artificial**: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2023.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. **Proceedings** [...]. 2017.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. **Nature Machine Intelligence**, v. 2, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

GIL, A. C. **Como elaborar projetos de pesquisa**. 5. ed. São Paulo: Atlas, 2010.

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017. **Proceedings** [...]. PMLR, 2017. p. 1321-1330.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016. **Proceedings** [...]. IEEE, 2016. p. 770-778.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Agropecuário 2017**: resultados definitivos. Rio de Janeiro: IBGE, 2019.

KABYA, N. D. et al. Towards practical AI for agriculture: a self-supervised attention framework for spinach leaf disease detection. **PLOS ONE**, v. 21, n. 1, e0340989, 2026. DOI: 10.1371/journal.pone.0340989.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, n. 2, p. 153-157, 1947. DOI: 10.1007/BF02295996.

MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. **Frontiers in Plant Science**, v. 7, 1419, 2016. DOI: 10.3389/fpls.2016.01419.

NAEINI, M. P.; COOPER, G. F.; HAUSKRECHT, M. Obtaining well calibrated probabilities using Bayesian binning. In: AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE, 29., 2015. **Proceedings** [...]. AAAI, 2015. p. 2901-2907.

NEWCOMBE, R. G. Interval estimation for the difference between independent proportions: comparison of eleven methods. **Statistics in Medicine**, v. 17, n. 8, p. 873-890, 1998.

NGUYEN, T. A. et al. From laboratory to field: frozen foundation-model features toward robust plant disease recognition. **Smart Agricultural Technology**, v. 15, 102531, 2026. DOI: 10.1016/j.atech.2026.102531.

RUSSELL, S.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2022.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018. **Proceedings** [...]. IEEE, 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017. **Proceedings** [...]. IEEE, 2017. p. 618-626.

SHAFAY, M. et al. Recent advances in plant disease detection: challenges and opportunities. **Plant Methods**, v. 21, 140, 2025. DOI: 10.1186/s13007-025-01450-0.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019. **Proceedings** [...]. PMLR, 2019. p. 6105-6114.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. **Artificial Intelligence Review**, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927. DOI: 10.2307/2276774.

WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. **Transactions of the ASAE**, v. 38, n. 1, p. 259-269, 1995. DOI: 10.13031/2013.27838.

WORKNEH, A. D. et al. Leakage-aware, calibrated, and explainable deep learning for robust almond disease classification. **Computers and Electronics in Agriculture**, v. 256, 112464, 2026. DOI: 10.1016/j.compag.2026.112464.