# Detecção automática de anomalias fitossanitárias em hortaliças folhosas utilizando visão computacional e aprendizado de máquina

**José Pedro Vieira Silva, Leanderson André**

Bacharelado em Engenharia de Software
Universidade da Região de Joinville (Univille) – Joinville – SC – Brasil

{josepedro, leandersonandre}@univille.br

***Abstract.*** *This work investigates to what extent a phytosanitary screening system for leafy vegetables, based on transfer learning, trained on public images audited for data leakage and equipped with confidence calibration and abstention, remains reliable on photographs taken under real field conditions. Three convolutional networks (EfficientNet-B0, MobileNetV2 and ResNet-50) and a Vision Transformer (ViT-B/16) are compared with paired McNemar tests. On a test set drawn from the same sources as the training data, EfficientNet-B0 and ViT-B/16 tie at 98.48% balanced accuracy (95% CI 98.32 –98.64; $p = 0.26$) and outperform the other two ($p < 10^{-11}$), yet the abstention threshold intercepts only 31% and 15% of their errors. On a source never seen in training, an earlier version scored 75.4% ($N = 484$). A fifth cycle that splits lettuce by original photograph and balances labels within each crop cuts false alarms on field-photographed crops, at a cost in sensitivity. On 13 field photographs, versions are indistinguishable.*

***Resumo.*** *Este trabalho investiga em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em transfer learning, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo. Três redes convolucionais (EfficientNet-B0, MobileNetV2 e ResNet-50) e um Vision Transformer (ViT-B/16) são comparados por teste de McNemar pareado. Em teste extraído das mesmas fontes do treino, EfficientNet-B0 e ViT-B/16 empatam em 98,48% de acurácia balanceada (IC 95%: 98,32–98,64; $p = 0,26$) e superam os outros dois ($p < 10^{-11}$), mas o limiar de abstenção intercepta apenas 31% e 15% dos seus erros. Em uma fonte nunca vista no treino, uma versão anterior obteve 75,4% ($N = 484$). Um quinto ciclo, que separa a alface pela fotografia original e equilibra os rótulos dentro de cada cultura, reduz os falsos alarmes em culturas fotografadas em lavoura, com perda de sensibilidade. Em 13 fotografias de campo, as versões são indistinguíveis.*

## 1. Introdução

A inteligência artificial (IA) consolidou-se como uma das áreas mais ativas da computação, e o aprendizado profundo tornou-se a abordagem predominante em tarefas de percepção, como a classificação de imagens (Russell; Norvig, 2022). Redes neurais sustentam hoje aplicações em diagnóstico médico por imagem, inspeção industrial e

agricultura de precisão, e o *transfer learning* tornou essas técnicas acessíveis a problemas com poucos dados rotulados, ao reaproveitar modelos pré-treinados (Faceli et al., 2023).

Na agricultura, uma das aplicações mais estudadas é o diagnóstico de doenças de plantas a partir de fotografias de folhas. O tema é relevante no Brasil, onde 77% dos estabelecimentos rurais pertencem à agricultura familiar (IBGE, 2019), segmento no qual o diagnóstico fitossanitário ainda depende predominantemente de inspeção visual manual. Hortaliças folhosas como alface, rúcula, espinafre, acelga e couve são culturas de ciclo curto e alta perecibilidade, nas quais o atraso na identificação de doenças, pragas ou deficiências nutricionais se traduz rapidamente em perda de produção.

Os trabalhos relacionados mostram um contraste entre laboratório e campo. Redes neurais convolucionais (CNNs) treinadas no dataset PlantVillage superam 99% de acurácia (Mohanty; Hughes; Salathé, 2016), mas sobre imagens de estúdio — folha isolada, fundo homogêneo, iluminação controlada. Em fotografias de lavoura a acurácia cai, fenômeno denominado *domain gap* (Barbedo, 2018), e uma revisão sistemática recente situa o campo entre 70% e 85% (Shafay et al., 2025). Estudos recentes passaram a combinar validação sem vazamento de dados, calibração da confiança e abstenção (Ergün et al., 2026; Workneh et al., 2026), mas em culturas como videira e amêndoa; para hortaliças folhosas os trabalhos são menos numerosos e avaliados em partições do próprio conjunto de dados (Abbasi; Martinez; Ahmad, 2023; Kabya et al., 2026).

O problema deste trabalho nasce dessa lacuna e de um resultado próprio. Na primeira fase (TCC-I), uma auditoria por *hash* perceptual revelou que 57,35% do conjunto de teste era composto por fotografias quase idênticas a imagens de treino, o que invalidou a acurácia de 99,01% inicialmente obtida. Após a reconstrução do particionamento, o melhor modelo atingiu 98,49% de acurácia balanceada no domínio de teste, mas apenas 73,3% em uma validação exploratória com 13 fotografias de horta real. A questão passa a ser quanto um sistema desse tipo vale em uso real; e, como um sistema que erra com aparência de certeza transfere confiança indevida ao produtor, a calibração da confiança e a capacidade de abster-se fazem parte do objeto de estudo.

Diante do exposto, a questão de pesquisa é: em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em *transfer learning*, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e mecanismo de abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo? Ela se desdobra em três perguntas operacionais: (Q1) qual arquitetura apresenta o melhor desempenho no domínio de teste, com significância estatística; (Q2) em que medida as probabilidades calibradas e o limiar de abstenção interceptam os erros do modelo; e (Q3) qual é a magnitude do *domain gap* entre laboratório e campo e se ele varia conforme a cultura, o tipo de manifestação do sintoma e a distância de captura.

O objetivo geral é avaliar o desempenho e a confiabilidade de um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, baseado em *transfer learning* com as redes convolucionais EfficientNet-B0, MobileNetV2 e ResNet-50 e, como arquitetura de contraste, o *Vision Transformer* ViT-B/16, quantificando com rigor estatístico a diferença entre o desempenho em laboratório e em condições reais de campo. Os objetivos específicos são: (a) consolidar o conjunto de dados de treinamento a partir de fontes públicas, com deduplicação e particionamento agrupado, reportando o

vazamento residual; (b) comparar as arquiteturas no conjunto de teste, com métricas robustas ao desbalanceamento de classes e teste estatístico pareado; (c) avaliar a calibração das probabilidades e a eficácia da abstenção em interceptar erros; (d) construir um conjunto de validação de campo com gabarito, abrangendo mais de uma cultura, diferentes tipos de sintoma e distâncias de captura; (e) quantificar o *domain gap* entre laboratório e campo, com intervalos de confiança e testes adequados a amostras pequenas; e (f) investigar se o desempenho em campo varia conforme a cultura, o tipo de manifestação do sintoma (cromática ou estrutural) e a distância de captura.

## 2. Revisão da literatura

Esta seção apresenta os modelos, os conceitos que sustentam a validade da avaliação e os trabalhos relacionados, retomados na Seção 4.

### 2.1 Modelos de aprendizado profundo e transfer learning

As CNNs extraem hierarquias de características visuais por camadas convolucionais e dominam a classificação de imagens (Russell; Norvig, 2022). Na versão original de 1.000 classes, a ResNet-50, que introduziu as conexões residuais, tem 25,6 milhões de parâmetros (He et al., 2016); a MobileNetV2, com convoluções separáveis e blocos residuais invertidos, 3,4 milhões (Sandler et al., 2018); e a EfficientNet-B0, que equilibra profundidade, largura e resolução por escalonamento composto, 5,3 milhões (Tan; Le, 2019). Os *Vision Transformers* substituem a convolução por autoatenção sobre blocos de 16×16 pixels; o ViT-B/16 tem 86,6 milhões de parâmetros e menos viés indutivo espacial que as CNNs (Dosovitskiy et al., 2021). O *transfer learning* reutiliza pesos aprendidos no ImageNet como ponto de partida (Faceli et al., 2023), com eficácia demonstrada no diagnóstico foliar (Mohanty; Hughes; Salathé, 2016), mas ampliar o volume de dados tem retorno decrescente se a diversidade das condições de captura não aumenta (Barbedo, 2018).

### 2.2 Validade da avaliação: vazamento, domain gap e calibração

Vazamento de dados designa a presença, no conjunto de avaliação, de informação indisponível na predição real, tipicamente por contaminação a partir do treino (Kaufman et al., 2012). Em imagens, a forma mais comum é a duplicação quase exata — a mesma fotografia com recorte, compressão ou rotação diferentes — distribuída entre treino e teste por um particionamento aleatório por arquivo. É um caso de *shortcut learning*: redes profundas exploram qualquer regularidade que reduza a perda, e um teste que compartilhe essa regularidade não a detecta (Geirhos et al., 2020).

O *domain gap* é a discrepância entre o desempenho em condições controladas e em condições de uso: modelos treinados em imagens de estúdio podem cair para 31% a 72% de acurácia em fotografias de lavoura, com solo, sombra, sobreposição de folhas e iluminação variável (Ahmad; Gamal; Saraswat, 2023; Upadhyay et al., 2025). Aqui o salto é duplo, de estúdio para campo e de espécies-*proxy* para espécies-alvo, pois o PlantVillage não contém as hortaliças-alvo.

As probabilidades de redes profundas modernas são sistematicamente mal calibradas, o que se corrige com o *temperature scaling*, que divide os *logits* por um escalar $T$ aprendido na validação sem alterar a classe predita (Guo et al., 2017). A calibração é medida pelo Erro de Calibração Esperado (ECE), que compara confiança declarada e

acurácia observada por faixas de confiança (Naeini; Cooper; Hauskrecht, 2015). Sobre um modelo calibrado constrói-se um classificador seletivo, que se abstém abaixo de um limiar τ, trocando cobertura por acurácia seletiva (Geifman; El-Yaniv, 2017), e o índice *Excess Green* (ExG = $2g - r - b$) permite rejeitar antes da inferência imagens sem vegetação (Woebbecke et al., 1995).

### 2.3 Trabalhos relacionados

A busca por trabalhos relacionados foi feita na Web of Science, em outubro de 2026, combinando doença de plantas e aprendizado profundo com generalização em campo, vazamento de dados, calibração e hortaliças folhosas; o Quadro 1 resume os estudos mais próximos. Classificadores que passam de 99% no PlantVillage caem para 26% a 30% no conjunto de campo PlantDoc, sobretudo por atribuírem a folha à cultura errada, e o ajuste fino completo de um modelo de fundação piora a transferência (Nguyen et al., 2026); uma revisão aponta arquiteturas híbridas como mais robustas e o ViT puro como mais sensível ao ambiente (Shafay et al., 2025). Dois estudos adotam protocolo semelhante ao deste: com amêndoa, a validação agrupada quase não altera o F1 macro, mas um teste com fontes disjuntas o reduz a 0,56 (Workneh et al., 2026); com videira, a EfficientNet-B0 obtém 73,8% em um conjunto externo (Ergün et al., 2026). Não foi localizado estudo que reúna, para hortaliças folhosas, auditoria de vazamento, calibração com abstenção e avaliação fora da fonte de treino.

**Quadro 1. Trabalhos relacionados e comparação com este trabalho**

| Trabalho | Cultura | Protocolo de avaliação | Resultado fora da origem |
|---|---|---|---|
| Nguyen et al. (2026) | Várias | PlantVillage → PlantDoc; McNemar | 26% a 30%; 51% com DINOv2 congelado |
| Ergün et al. (2026) | Videira | Conjunto externo; calibração | 73,8%; ECE de 0,287 para 0,038 |
| Workneh et al. (2026) | Amêndoa | Validação agrupada; calibração; abstenção | F1 macro de 0,98 para 0,56 |
| Kabya et al. (2026) | Espinafre-de-malabar | Partição do próprio conjunto | 97,3% (teste interno) |
| Este trabalho | Hortaliças folhosas | Deduplicação; calibração; abstenção | 75,4% (fonte retida, ciclo 3); 85,8% a 90,1% (lote retido, ciclo 5) |

Fonte: elaboração própria (2026), a partir dos trabalhos citados.

## 3. Procedimentos metodológicos

A pesquisa é quantitativa, exploratória e descritiva quanto aos objetivos e experimental quanto aos procedimentos, pois arquitetura, calibração, limiar de abstenção e domínio de avaliação são manipulados sob condições controladas e reprodutíveis (Gil, 2010); todo o *pipeline* roda por *script*, com semente fixa (42) e registro dos parâmetros e métricas de cada execução.

### 3.1 Dados, modelos e treinamento

O dataset binário (saudável × anômalo) reúne seis fontes públicas do Kaggle, entre elas o PlantVillage, como *proxy* visual, e datasets de alface. A rotulagem é automática, por busca em largura na árvore de diretórios, com cada decisão pasta-rótulo registrada em um mapa de auditoria. Contra o vazamento, cada imagem é reduzida a um *hash*

perceptual invariante às oito transformações do grupo diedral D4; imagens a distância de Hamming $\leq 4$ são agrupadas por união-busca, e cada grupo vai inteiro para uma partição (≈70/15/15, estratificada por classe), descartados os grupos com rótulos contraditórios. Das 176.126 imagens reunidas restam 170.772 (120.861 de treino, 25.944 de validação e 23.967 de teste), com vazamento residual de 0,04% no teste por esse critério. As partições provêm das mesmas seis fontes, e o teste mede desempenho intra-fonte. O critério não alcança variantes muito alteradas da mesma fotografia: 23% do teste são rotações, recortes e filtros de fotografias de alface com outra variante no treino.

Em um quarto ciclo foram incorporados dois lotes preparados com o mesmo protocolo: 3.209 imagens de espinafre-de-malabar (*Basella alba*, e não *Spinacia oleracea*) e 1.142 recortes de 49 fotografias de alface com míldio, particionados pela fotografia de origem, o que eleva o conjunto a 175.123 imagens.

As três CNNs são inicializadas com pesos do ImageNet e ajustadas integralmente por até 30 épocas, com imagens de 224×224 pixels (AdamW, taxa de aprendizado de $10^{-3}$ com escalonador de cosseno, parada antecipada com paciência 10, entropia cruzada com *label smoothing* de 0,1 e amostragem ponderada pelo inverso da frequência de classe). O ViT-B/16 segue o mesmo protocolo de dados, perda, seleção e calibração, com hiperparâmetros de otimização usuais no ajuste fino de *transformers*: taxa de $5\times10^{-5}$, decaimento de pesos de 0,05, duas épocas de aquecimento e limitação da norma do gradiente. Cada modelo é calibrado por *temperature scaling* na validação, e $\tau$ é o menor valor, a partir de 0,85, que assegura acurácia seletiva de ao menos 98% na validação. Em produção, o sistema devolve um de quatro veredictos: saudável, anômalo, inconclusivo (confiança $< \tau$) ou não é folha (menos de 10% de pixels vegetativos por ExG).

Um quinto ciclo corrige três defeitos achados em auditoria posterior: a alface passa a ser particionada pela fotografia original, com uma por original na validação e no teste (176 no teste, 15 doentes); 8.266 imagens de pastas que a rotulagem deixava de fora, quase todas de dano por praga, entram como anômalas; e a amostragem equilibra os rótulos dentro de cada cultura, sem pesos na perda, porque cultura e rótulo estavam associados (87% da alface de treino era saudável). Um lote de espinafre-de-malabar (574 imagens) fica fora do treino, onde permanece outro lote da espécie. São 152.057 imagens, 1,7% do teste a distância $\leq 4$ do treino, e as demais fontes mantêm a partição, o que permite comparar os ciclos imagem a imagem.

### 3.2 Coleta dos dados de campo

Os dados de campo serão coletados em hortas da região de Joinville (SC), com telefone celular, sob luz natural e sem preparação da cena: de 100 a 300 fotografias, com mínimo de 15 e meta de 25 por cultura, proporção próxima de 50/50 entre folhas saudáveis e anômalas e variedade de sintomas (manchas, clorose, oídio ou míldio, perfurações, murcha). Para 20% a 30% das folhas há três fotografias em distâncias diferentes (aproximada, média e ampla), e cada cultura inclui duas ou três imagens sem folha (solo, mão, parede), para verificar a guarda de vegetação.

Quatro regras garantem a validade do conjunto: (i) o rótulo é registrado na coleta, antes de qualquer inferência, e fotografias ambíguas são marcadas, e o resultado é reportado com e sem elas; (ii) fotografias de campo nunca entram no treino; (iii) versões do

modelo são comparadas sobre as mesmas fotografias; e (iv) as 13 fotografias do TCC-I formam um conjunto histórico, reportado à parte.

### 3.3 Análise dos dados

A análise responde às perguntas Q1 a Q3, e o Quadro 2 relaciona cada objetivo específico aos dados e às técnicas. Adota-se $\alpha = 0{,}05$, com a correção sequencial de Holm (1979) nas comparações múltiplas sobre os mesmos dados.

Para o desempenho no domínio de teste (Q1), considerando a classe anômala como positiva, calculam-se a partir da matriz de confusão a acurácia global, a precisão, a revocação, o F1-score por classe e macro, a área sob a curva ROC (AUC) e a latência média de inferência. A **métrica principal é a acurácia balanceada** (Equação 1), média das revocações das duas classes, que não é inflada pelo desbalanceamento de aproximadamente 1,35:1 do dataset (Brodersen et al., 2010):

$$AB = \tfrac{1}{2} \cdot \left[ \, VP / (VP + FN) + VN / (VN + FP) \, \right] \tag{1}$$

Os falsos negativos — plantas doentes declaradas saudáveis — são reportados à parte, por serem o erro de maior custo agronômico. Os intervalos de confiança de 95% vêm de *bootstrap* estratificado por classe, com 10.000 reamostragens (Efron; Tibshirani, 1993), e, como as arquiteturas são avaliadas sobre as mesmas 23.967 imagens, pares de modelos são comparados pelo teste de McNemar, que considera só as imagens em que os dois discordam (McNemar, 1947; Dietterich, 1998).

Para Q2, a calibração é avaliada pelo ECE com $M = 15$ faixas de confiança de igual largura (Equação 2), onde $B_m$ é o conjunto de predições cuja confiança cai na faixa $m$ e $n$ é o total de predições, antes e depois do *temperature scaling*, acompanhado do diagrama de fiabilidade:

$$ECE = \Sigma_m \left( |B_m| / n \right) \cdot \left| \, \mathrm{acc}(B_m) - \mathrm{conf}(B_m) \, \right| \tag{2}$$

O mecanismo de abstenção é avaliado pela cobertura (fração de imagens que recebem diagnóstico), pela acurácia seletiva (acurácia entre as diagnosticadas) e pela fração de erros interceptados (confiança inferior a $\tau$); a curva risco–cobertura, com $\tau$ de 0,50 a 0,99, orienta o ponto de operação, e o teste de Mann-Whitney compara a confiança de acertos e erros.

Para Q3, cada fotografia de campo tem três desfechos: acerto, erro ou abstenção. As abstenções são reportadas como taxa própria, e as métricas de acerto, calculadas sobre os diagnósticos emitidos; as imagens sem folha medem a rejeição correta da guarda de vegetação.

Como as amostras de campo são pequenas, toda proporção leva intervalo de confiança de Wilson a 95% (Wilson, 1927), e a acurácia balanceada, intervalo por *bootstrap* estratificado. O *domain gap* é a diferença entre a acurácia balanceada no teste e em campo, e versões do modelo são comparadas sobre as mesmas fotografias pelo teste de McNemar exato. Para uma proporção de 80%, o intervalo de Wilson tem mais de 40 pontos de amplitude com 13 fotografias, 15,5 com 100 e 9,0 com 300, o que define a meta de coleta.

Ainda em Q3, a acurácia de campo é desagregada por três hipóteses exploratórias: o desempenho difere entre culturas, pois só a alface tem dados de treino específicos (H1); é menor em sintomas estruturais, como murcha e perfurações, do que em cromáticos,

como manchas e clorose (H2); e diminui com a distância de captura (H3). H1 e H3 são testadas pelo teste exato de Freeman-Halton, H3 também pelo de Cochran-Armitage, e H2 pelo teste exato de Fisher (Agresti, 2013); as diferenças de proporções são reportadas com intervalo de Newcombe (1998), e os resultados, interpretados como exploratórios. Cada erro de campo é ainda examinado com mapas Grad-CAM (Selvaraju et al., 2017) e classificado quanto à causa provável: sintoma sutil, enquadramento amplo, fundo com vegetação, iluminação ou rótulo duvidoso.

**Quadro 2. Relação entre objetivos específicos, dados e técnicas de análise**

| Objetivo | Dados | Técnicas de análise |
|---|---|---|
| a) Consolidar o dataset | Imagens públicas; hashes perceptuais | Taxa de redundância; vazamento residual por partição (critério < 1%) |
| b) Comparar arquiteturas | Teste (23.967 imagens) | Acurácia balanceada, F1 macro, AUC, FN; bootstrap; McNemar e Holm |
| c) Calibração e abstenção | Validação e teste | ECE; cobertura, acurácia seletiva, erros interceptados; Mann-Whitney |
| d) Conjunto de campo | Fotografias de horta com gabarito | Descrição por cultura, classe, sintoma e distância |
| e) Quantificar o domain gap | Teste × campo | Diferença de acurácia balanceada; Wilson; McNemar exato |
| f) Fatores do desempenho | Campo estratificado | Freeman-Halton; Cochran-Armitage; Newcombe; Grad-CAM |

Fonte: elaboração própria (2026).

## 4. Análise dos dados e discussão dos resultados

As Tabelas 1 e 2 vão até o quarto ciclo de treinamento, e a Tabela 3 apresenta o quinto; as análises de campo (Q3) dependem da coleta descrita na Seção 3.2.

**Tabela 1. Desempenho no conjunto de teste (23.967 imagens), quarto ciclo**

| Modelo | Parâm. | Acur. bal. | F1 macro | AUC | ECE | FN | Latência |
|---|---|---|---|---|---|---|---|
| EfficientNet-B0 | 4,0 M | 98,48% | 98,44% | 0,9982 | 0,0039 | 209 | 7,2 ms |
| MobileNetV2 | 2,2 M | 97,89% | 97,83% | 0,9976 | 0,0055 | 294 | 5,3 ms |
| ResNet-50 | 23,5 M | 97,82% | 97,70% | 0,9966 | 0,0061 | 352 | 8,6 ms |
| ViT-B/16 | 85,8 M | 98,48% | 98,53% | 0,9976 | 0,0018 | 137 | 19,4 ms |

Parâm. = modelo treinado, com saída de duas classes. FN = falsos negativos. Latência em GPU RTX 3050 (6 GB), medida na mesma sessão para os quatro modelos. Fonte: elaboração própria (2026).

EfficientNet-B0 e ViT-B/16 empatam: mesma acurácia balanceada e mesmo IC 95% (98,32% a 98,64%), sem diferença pelo McNemar exato com correção de Holm ($p = 0,26$). Ambos superam o MobileNetV2 (97,70% a 98,07%) e o ResNet-50 (97,63% a 98,00%), com $p \leq 1,4\times10^{-12}$, e estes não diferem entre si ($p = 0,26$), embora o segundo tenha dez vezes mais parâmetros. O ViT-B/16 comete menos falsos negativos (137 contra 209) e mais falsos positivos (204 contra 154), com 21 vezes mais parâmetros que o EfficientNet-B0 e latência 2,7 vezes maior. Isso responde a Q1 neste teste; com um único treino por modelo, a conclusão não se estende às arquiteturas em geral.

Quanto a Q2, o *temperature scaling* reduziu o ECE na validação de 0,0509 para 0,0027 no EfficientNet-B0 e de 0,0472 para 0,0022 no ViT-B/16. No teste, a confiança calibrada do EfficientNet-B0 separa acertos de erros (0,990 contra 0,874; Mann-Whitney, $p < 0,001$), mas $\tau = 0,85$ intercepta apenas 113 dos 363 erros (31,1%), com

abstenção em 1,2%; no ViT-B/16, 51 dos 341 (15,0%), com abstenção em 0,5%. O ViT-B/16 tem o menor ECE da Tabela 1 e a menor fração de erros interceptados: boa calibração média não garante que os erros fiquem nas confianças baixas.

A Tabela 1 deve ser lida com uma ressalva: o teste é extraído das mesmas seis fontes do treino, de modo que os 98,48% são uma acurácia intra-fonte. No lote de espinafre-de-malabar que o modelo do terceiro ciclo nunca viu, a acurácia balanceada do EfficientNet-B0 foi de 75,4% (N = 484), 23 pontos abaixo, embora as imagens também sejam de folha isolada sobre fundo claro. Incorporado o lote ao treino, o resultado nele subiu para 88,4% (IC 95%: 85,3% a 91,2%; p de Holm = $5{,}9\times10^{-12}$), mas o ganho é intra-fonte: o modelo aprende a aparência das fontes de treino, e isso não informa sobre o campo.

**Tabela 2. Validação exploratória em campo (13 fotografias de alface), por ciclo**

| Ciclo | Correção aplicada | Diagnósticos | Acertos | Proporção | IC 95% (Wilson) |
|---|---|---|---|---|---|
| 1 | Vazamento de dados | 12 de 13 | 11 | 91,7% | [64,6%; 98,5%] |
| 2 | Abstenção; dados de alface | 13 de 13 | 10 | 76,9% | [49,7%; 91,8%] |
| 3 | Rotulagem automática | 11 de 13 | 8 | 72,7% | [43,4%; 90,3%] |
| 4 | Espinafre e míldio no treino | 13 de 13 | 11 | 84,6% | [57,8%; 95,7%] |
| 5 | Alface por foto; amostragem | 12 de 13 | 11 | 91,7% | [64,6%; 98,5%] |
| 4* | ViT-B/16, mesmos dados | 12 de 13 | 12 | 100% | [75,8%; 100%] |

Ciclos 1 a 5: EfficientNet-B0. * ViT-B/16, dados do ciclo 4. Fonte: elaboração própria (2026).

A Tabela 2 mostra por que a análise estatística é central. Em pontos estimados, o desempenho de campo teria piorado nos três primeiros ciclos, mesmo com a correção de defeitos reais, como 3.972 imagens de alface saudável rotuladas como doentes; mas os intervalos de Wilson de todos os ciclos se sobrepõem, e com N = 13 versões e arquiteturas são indistinguíveis. A amostra revelou o defeito de rotulagem, mas não tem poder para decidir entre modelos. Os nove erros emitidos nos quatro primeiros ciclos, concentrados em quatro fotografias, tiveram confiança calibrada entre 0,949 e 0,999: o limiar $\tau$ é ajustado na validação, que compartilha a distribuição do treino, e fora dela o ECE passou de 0,003 para 0,146.

**Tabela 3. Quinto ciclo: acurácia balanceada (%) no teste e por subconjunto**

| Modelo | Teste | Lavoura | Espec. | Sens. | Alface | Retido |
|---|---|---|---|---|---|---|
| EfficientNet-B0 | 97,4 | 86,3 → 88,8 | 76,6 → 83,4 | 96,0 → 94,2 | 96,7 | 87,9 |
| MobileNetV2 | 96,9 | 86,6 → 90,1 | 78,3 → 90,2 | 94,9 → 90,0 | 100 | 88,4 |
| ResNet-50 | 96,9 | 87,8 → 89,6 | 81,4 → 89,0 | 94,2 → 90,2 | 100 | 90,1 |
| ViT-B/16 | 96,9 | 83,4 → 84,5 | 69,8 → 72,1 | 97,0 → 96,9 | 100 | 85,8 |

Teste do ciclo 5: 18.413 imagens, sem variantes de alface. Lavoura: mandioca, arroz, cana e café (N = 4.530), com Espec. e Sens. no mesmo subconjunto; ciclo 4 → ciclo 5, mesmas imagens. Alface: N = 176. Retido: lote de espinafre, N = 574. Fonte: elaboração própria (2026).

Na Tabela 3, a correção agiu onde estavam os erros: nas culturas de lavoura, as três CNNs ganham de 1,8 a 3,5 pontos de acurácia balanceada e de 6,8 a 11,9 de especificidade, ou seja, emitem menos falsos alarmes em folhas sadias; o ViT-B/16 quase não muda (p = 0,66). O custo é a sensibilidade, que cai de 1,8 a 4,9 pontos: por imagem, o quarto ciclo acerta mais ($p \leq 0{,}04$), pois três em cada quatro dessas imagens são anômalas, e o perfil preferível depende do custo de cada erro na horta. No lote retido, os modelos ficam entre 85,8% e 90,1%, cerca de dez pontos abaixo das fontes de

treino; na alface sem variantes, entre 96,7% e 100%, com só 15 doentes. A validação, que põe EfficientNet-B0 e ViT-B/16 à frente (F1 macro de 0,972 contra 0,96), não ordena os modelos como os dados de fora.

Esses resultados são coerentes com o Quadro 1. A queda de 98,48% para 75,4% em uma fonte retida tem a ordem de grandeza dos 73,8% da EfficientNet-B0 em um conjunto externo de videira (Ergün et al., 2026) e, como no estudo com amêndoa, só aparece com a fonte separada (Workneh et al., 2026); o contraste com os 97,3% do espinafre-de-malabar em partição interna (Kabya et al., 2026) indica que a diferença está no protocolo de avaliação, e não na cultura. O ViT-B/16, que empata no teste e é o pior nas culturas de lavoura, confirma a sensibilidade do ViT puro ao ambiente (Shafay et al., 2025), e o ajuste fino completo não reduz o *domain gap* (Nguyen et al., 2026). A literatura atribui a perda à pouca diversidade das condições de captura (Barbedo, 2018), e o próprio teste a reproduz: as culturas fotografadas em lavoura têm 86,3% (IC 95%: 84,5% a 88,0%) no EfficientNet-B0 do quarto ciclo e concentram 81% dos seus erros, contra 99,7% nas demais. Na calibração, o estudo de videira reduz o ECE do conjunto externo de 0,287 para 0,038, com confiança média de 0,55 (Ergün et al., 2026), enquanto aqui o ECE de campo fica em 0,146 após a calibração na validação, o que recomenda reservar fotografias de campo para recalibração.

## 5. Conclusão

No domínio de teste, EfficientNet-B0 e ViT-B/16 empatam e superam as outras duas com significância estatística; suas probabilidades são bem calibradas, mas o limiar de abstenção deixa passar mais de dois terços dos erros. Trocar a CNN por um transformer com 21 vezes mais parâmetros não altera esse quadro, o que indica que o limite do sistema está nos dados, e não na arquitetura. A questão central permanece aberta: o desempenho é de 98,48% nas fontes de treino, foi de 75,4% em uma fonte nunca vista e de 84,6% de acertos em 13 fotografias de campo, com intervalo de 57,8% a 95,7%. O quinto ciclo mostra que parte do erro vinha de atalhos nos dados e que corrigi-los reduz os falsos alarmes em fotografias de lavoura, com alguma perda de sensibilidade.

A próxima etapa é a coleta de campo, com fotografias de fundo real, que responde a Q3 (Seção 3.3): os modelos do quarto e do quinto ciclos, congelados antes dela, serão comparados sobre as mesmas fotografias, separadas por horta em conjuntos de avaliação e de adaptação.

## Referências


ABBASI, R.; MARTINEZ, P.; AHMAD, R. Crop diagnostic system: a robust disease detection and management system for leafy green crops grown in an aquaponics facility. **Artificial Intelligence in Agriculture**, v. 10, p. 1-12, 2023. DOI: 10.1016/j.aiia.2023.09.001.

AGRESTI, A. **Categorical data analysis**. 3. ed. Hoboken: Wiley, 2013.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. **IEEE Access**, v. 11, p. 9042-9057, 2023. DOI: 10.1109/ACCESS.2023.3240100.

BARBEDO, J. G. A. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. **Computers and**

**Electronics in Agriculture**, v. 153, p. 46-53, 2018. DOI: 10.1016/j.compag.2018.08.013.

BRODERSEN, K. H. et al. The balanced accuracy and its posterior distribution. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 20., 2010, Istambul. **Proceedings** [...]. IEEE, 2010. p. 3121-3124. DOI: 10.1109/ICPR.2010.764.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895-1923, 1998. DOI: 10.1162/089976698300017197.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 9., 2021. **Proceedings** [...]. 2021.

EFRON, B.; TIBSHIRANI, R. J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993.

ERGÜN, E. et al. Confidence and uncertainty aware deep learning for reliable grape leaf disease diagnosis under real world field conditions. **Frontiers in Plant Science**, v. 17, 1839652, 2026. DOI: 10.3389/fpls.2026.1839652.

FACELI, K. et al. **Inteligência artificial**: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2023.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. **Proceedings** [...]. 2017.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. **Nature Machine Intelligence**, v. 2, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

GIL, A. C. **Como elaborar projetos de pesquisa**. 5. ed. São Paulo: Atlas, 2010.

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017. **Proceedings** [...]. PMLR, 2017. p. 1321-1330.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016. **Proceedings** [...]. IEEE, 2016. p. 770-778.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Agropecuário 2017**: resultados definitivos. Rio de Janeiro: IBGE, 2019.

KABYA, N. D. et al. Towards practical AI for agriculture: a self-supervised attention framework for spinach leaf disease detection. **PLOS ONE**, v. 21, n. 1, e0340989, 2026. DOI: 10.1371/journal.pone.0340989.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, n. 2, p. 153-157, 1947. DOI: 10.1007/BF02295996.

MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. **Frontiers in Plant Science**, v. 7, 1419, 2016. DOI: 10.3389/fpls.2016.01419.

NAEINI, M. P.; COOPER, G. F.; HAUSKRECHT, M. Obtaining well calibrated probabilities using Bayesian binning. In: AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE, 29., 2015. **Proceedings** [...]. AAAI, 2015. p. 2901-2907.

NEWCOMBE, R. G. Interval estimation for the difference between independent proportions: comparison of eleven methods. **Statistics in Medicine**, v. 17, n. 8, p. 873-890, 1998.

NGUYEN, T. A. et al. From laboratory to field: frozen foundation-model features toward robust plant disease recognition. **Smart Agricultural Technology**, v. 15, 102531, 2026. DOI: 10.1016/j.atech.2026.102531.

RUSSELL, S.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2022.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018. **Proceedings** [...]. IEEE, 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017. **Proceedings** [...]. IEEE, 2017. p. 618-626.

SHAFAY, M. et al. Recent advances in plant disease detection: challenges and opportunities. **Plant Methods**, v. 21, 140, 2025. DOI: 10.1186/s13007-025-01450-0.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019. **Proceedings** [...]. PMLR, 2019. p. 6105-6114.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. **Artificial Intelligence Review**, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927. DOI: 10.2307/2276774.

WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. **Transactions of the ASAE**, v. 38, n. 1, p. 259-269, 1995. DOI: 10.13031/2013.27838.

WORKNEH, A. D. et al. Leakage-aware, calibrated, and explainable deep learning for robust almond disease classification. **Computers and Electronics in Agriculture**, v. 256, 112464, 2026. DOI: 10.1016/j.compag.2026.112464.