Detecção automática de anomalias fitossanitárias em hortaliças folhosas utilizando visão computacional e aprendizado de máquina

José Pedro Vieira Silva, Leanderson André

Bacharelado em Engenharia de Software
Universidade da Região de Joinville (Univille) – Joinville – SC – Brasil

{josepedro, leandersonandre}@univille.br

Abstract. *This work investigates to what extent a phytosanitary screening system for leafy vegetables, trained on public images audited for leakage and equipped with calibration and abstention, remains reliable on photographs taken under real field conditions. Three convolutional networks (EfficientNet-B0, MobileNetV2 and ResNet-50) and a Vision Transformer (ViT-B/16) are compared with paired McNemar tests. On a test set drawn from the same sources as the training data, EfficientNet-B0 and ViT-B/16 tie at 98.48% balanced accuracy (95% CI 98.32–98.64; $p = 0.26$) and outperform the other two ($p < 10^{-11}$), yet the abstention threshold intercepts only 31% and 15% of their errors. On a source never seen in training, an earlier version scored 75.4% ($N = 484$). A fifth cycle that removes data shortcuts cuts false alarms on field-photographed crops, at a cost in sensitivity. On 13 field photographs, versions are indistinguishable, and on the first 10 photographs with real background, all of healthy lettuce, no version raised a false alarm.*

Resumo. *Este trabalho investiga em que medida um sistema de triagem fitossanitária para hortaliças folhosas, treinado com imagens públicas auditadas contra vazamento e dotado de calibração e abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo. Três redes convolucionais (EfficientNet-B0, MobileNetV2 e ResNet-50) e um Vision Transformer (ViT-B/16) são comparados por teste de McNemar pareado. Em teste extraído das mesmas fontes do treino, EfficientNet-B0 e ViT-B/16 empatam em 98,48% de acurácia balanceada (IC 95%: 98,32–98,64; $p = 0,26$) e superam os outros dois ($p < 10^{-11}$), mas o limiar de abstenção intercepta apenas 31% e 15% dos seus erros. Em uma fonte nunca vista no treino, uma versão anterior obteve 75,4% ($N = 484$). Um quinto ciclo, que corrige atalhos nos dados, reduz os falsos alarmes em culturas fotografadas em lavoura, com perda de sensibilidade. Em 13 fotografias de campo, as versões são indistinguíveis e, nas 10 primeiras com fundo real, todas de alface sadia, nenhuma emitiu falso alarme.*

1. Introdução

Na agricultura, uma das aplicações mais estudadas do aprendizado profundo é o diagnóstico de doenças de plantas a partir de fotografias de folhas. O tema é relevante no Brasil, onde 77% dos estabelecimentos rurais pertencem à agricultura familiar (IBGE, 2019), segmento em que o diagnóstico ainda depende de inspeção visual. Hortaliças folhosas como alface, rúcula, espinafre, acelga e couve são culturas de ciclo

curto e alta perecibilidade, nas quais o atraso na identificação de doenças, pragas ou deficiências nutricionais se traduz rapidamente em perda de produção.

Os trabalhos relacionados mostram um contraste entre laboratório e campo. Redes neurais convolucionais (CNNs) treinadas no PlantVillage superam 99% de acurácia (Mohanty; Hughes; Salathé, 2016), mas em imagens de estúdio, com folha isolada e fundo homogêneo. Em fotografias de lavoura a acurácia cai, o chamado *domain gap* (Barbedo, 2018), e uma revisão recente situa o campo entre 70% e 85% (Shafay et al., 2025). Estudos recentes combinam validação sem vazamento, calibração e abstenção (Ergün et al., 2026; Workneh et al., 2026), mas em culturas como videira e amêndoa; para hortaliças folhosas os trabalhos são menos numerosos e avaliados em partições do próprio conjunto (Abbasi; Martinez; Ahmad, 2023; Kabya et al., 2026).

O problema deste trabalho nasce dessa lacuna e de um resultado próprio. Na primeira fase (TCC-I), uma auditoria por *hash* perceptual revelou que 57,35% do conjunto de teste era composto por fotografias quase idênticas a imagens de treino, o que invalidou a acurácia de 99,01% inicialmente obtida. Após a reconstrução do particionamento, o melhor modelo atingiu 98,49% de acurácia balanceada no domínio de teste, mas apenas 73,3% em uma validação exploratória com 13 fotografias de horta real. Como um sistema que erra com aparência de certeza transfere confiança indevida ao produtor, a calibração e a abstenção fazem parte do objeto de estudo.

Diante do exposto, a questão de pesquisa é: em que medida um sistema de triagem fitossanitária para hortaliças folhosas, baseado em *transfer learning*, treinado com imagens públicas auditadas contra vazamento de dados e dotado de calibração de confiança e mecanismo de abstenção, mantém desempenho confiável em fotografias capturadas em condições reais de campo? Ela se desdobra em três perguntas operacionais: (Q1) qual arquitetura apresenta o melhor desempenho no domínio de teste, com significância estatística; (Q2) em que medida as probabilidades calibradas e o limiar de abstenção interceptam os erros do modelo; e (Q3) qual é a magnitude do *domain gap* entre laboratório e campo e se ele varia conforme a cultura, o tipo de manifestação do sintoma e a distância de captura.

O objetivo geral é avaliar o desempenho e a confiabilidade de um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, baseado em *transfer learning* com as redes convolucionais EfficientNet-B0, MobileNetV2 e ResNet-50 e, como arquitetura de contraste, o *Vision Transformer* ViT-B/16, quantificando com rigor estatístico a diferença entre o desempenho em laboratório e em condições reais de campo. Os objetivos específicos são: (a) consolidar o conjunto de dados de treinamento a partir de fontes públicas, com deduplicação e particionamento agrupado, reportando o vazamento residual; (b) comparar as arquiteturas no conjunto de teste, com métricas robustas ao desbalanceamento de classes e teste estatístico pareado; (c) avaliar a calibração das probabilidades e a eficácia da abstenção em interceptar erros; (d) construir um conjunto de validação de campo com gabarito, abrangendo mais de uma cultura, diferentes tipos de sintoma e distâncias de captura; (e) quantificar o *domain gap* entre laboratório e campo, com intervalos de confiança e testes adequados a amostras pequenas; e (f) investigar se o desempenho em campo varia conforme a cultura, o tipo de manifestação do sintoma (cromática ou estrutural) e a distância de captura.

2. Revisão da literatura

2.1 Modelos de aprendizado profundo e transfer learning

As CNNs extraem hierarquias de características visuais por camadas convolucionais e dominam a classificação de imagens (Russell; Norvig, 2022). A ResNet-50 introduziu as conexões residuais (He et al., 2016); a MobileNetV2 usa convoluções separáveis e blocos residuais invertidos (Sandler et al., 2018); e a EfficientNet-B0 equilibra profundidade, largura e resolução por escalonamento composto (Tan; Le, 2019). Os *Vision Transformers* substituem a convolução por autoatenção sobre blocos de 16×16 pixels; o ViT-B/16 tem 86,6 milhões de parâmetros e menos viés indutivo espacial que as CNNs (Dosovitskiy et al., 2021). O *transfer learning* reutiliza pesos aprendidos no ImageNet como ponto de partida (Faceli et al., 2023), com eficácia demonstrada no diagnóstico foliar (Mohanty; Hughes; Salathé, 2016), mas mais dados rendem pouco se a diversidade das condições de captura não aumenta (Barbedo, 2018).

2.2 Validade da avaliação: vazamento, domain gap e calibração

Vazamento de dados designa a presença, no conjunto de avaliação, de informação indisponível na predição real, tipicamente por contaminação a partir do treino (Kaufman et al., 2012). Em imagens, a forma mais comum é a mesma fotografia, com recorte, compressão ou rotação diferentes, no treino e no teste. É um caso de *shortcut learning*: redes profundas exploram qualquer regularidade que reduza a perda, e um teste que compartilhe essa regularidade não a detecta (Geirhos et al., 2020).

O *domain gap* é a discrepância entre o desempenho em condições controladas e de uso: modelos treinados em estúdio podem cair para 31% a 72% de acurácia em fotografias de lavoura, com solo, sombra e iluminação variável (Ahmad; Gamal; Saraswat, 2023; Upadhyay et al., 2025). Aqui o salto é duplo, de estúdio para campo e de espécies-*proxy* para as hortaliças-alvo, ausentes do PlantVillage.

As probabilidades de redes profundas modernas são sistematicamente mal calibradas, o que se corrige com o *temperature scaling*, que divide os *logits* por um escalar T aprendido na validação (Guo et al., 2017). A calibração é medida pelo Erro de Calibração Esperado (ECE), que compara confiança declarada e acurácia observada por faixas (Naeini; Cooper; Hauskrecht, 2015). Sobre um modelo calibrado constrói-se um classificador seletivo, que se abstém abaixo de um limiar τ, trocando cobertura por acurácia seletiva (Geifman; El-Yaniv, 2017), e o índice *Excess Green* ($\mathrm{ExG} = 2g - r - b$) rejeita antes da inferência imagens sem vegetação (Woebbecke et al., 1995).

2.3 Trabalhos relacionados

A busca foi feita na Web of Science, em outubro de 2026 (doença de plantas e aprendizado profundo com generalização em campo, vazamento, calibração e hortaliças folhosas); o Quadro 1 resume os estudos mais próximos. Classificadores que passam de 99% no PlantVillage caem para 26% a 30% no conjunto de campo PlantDoc, sobretudo por atribuírem a folha à cultura errada, e o ajuste fino completo de um modelo de fundação piora a transferência (Nguyen et al., 2026); uma revisão aponta arquiteturas híbridas como mais robustas e o ViT puro como mais sensível ao ambiente (Shafay et al., 2025). Dois estudos têm protocolo semelhante: com amêndoa, a validação agrupada quase não altera o F1 macro, mas um teste com fontes disjuntas o reduz a 0,56

(Workneh et al., 2026); com videira, a EfficientNet-B0 obtém 73,8% em um conjunto externo (Ergün et al., 2026). Não se localizou estudo que reúna, em hortaliças folhosas, auditoria de vazamento, calibração, abstenção e avaliação fora da fonte.

Quadro 1. Trabalhos relacionados e comparação com este trabalho

Trabalho	Cultura	Protocolo de avaliação	Resultado fora da origem
Nguyen et al. (2026)	Várias	PlantVillage → PlantDoc; McNemar	26% a 30%; 51% com DINOv2 congelado
Ergün et al. (2026)	Videira	Conjunto externo; calibração	73,8%; ECE de 0,287 para 0,038
Workneh et al. (2026)	Amêndoa	Validação agrupada; calibração; abstenção	F1 macro de 0,98 para 0,56
Kabya et al. (2026)	Espinafre-de-malabar	Partição do próprio conjunto	97,3% (teste interno)
Este trabalho	Hortaliças folhosas	Deduplicação; calibração; abstenção	75,4% (fonte retida, ciclo 3); 85,8% a 90,1% (lote retido, ciclo 5)

Fonte: elaboração própria (2026), a partir dos trabalhos citados.

3. Procedimentos metodológicos

A pesquisa é quantitativa, exploratória e descritiva quanto aos objetivos e experimental quanto aos procedimentos, pois arquitetura, calibração, limiar de abstenção e domínio de avaliação são manipulados sob condições controladas e reprodutíveis (Gil, 2010); todo o *pipeline* roda por *script*, com semente fixa (42) e registro de cada execução.

3.1 Dados, modelos e treinamento

O dataset binário (saudável × anômalo) reúne seis fontes públicas do Kaggle, entre elas o PlantVillage, como *proxy* visual, e datasets de alface. A rotulagem é automática, pela árvore de diretórios, com cada decisão registrada para auditoria. Contra o vazamento, cada imagem é reduzida a um *hash* perceptual invariante às oito transformações do grupo diedral D4; imagens a distância de Hamming ≤ 4 são agrupadas por união-busca, e cada grupo vai inteiro para uma partição (≈70/15/15, estratificada por classe), descartados os grupos com rótulos contraditórios. Das 176.126 imagens reunidas restam 170.772 (120.861 de treino, 25.944 de validação e 23.967 de teste), com vazamento residual de 0,04% no teste. As partições provêm das mesmas seis fontes, e o teste mede desempenho intra-fonte. O critério não alcança variantes muito alteradas: 23% do teste são variantes de fotografias de alface com outra variante no treino.

Em um quarto ciclo foram incorporados dois lotes preparados com o mesmo protocolo: 3.209 imagens de espinafre-de-malabar (*Basella alba*, e não *Spinacia oleracea*) e 1.142 recortes de 49 fotografias de alface com míldio, particionados pela fotografia de origem, o que eleva o conjunto a 175.123 imagens.

As três CNNs são inicializadas com pesos do ImageNet e ajustadas integralmente por até 30 épocas, com imagens de 224×224 pixels (AdamW, taxa de aprendizado de 10^{-3} com escalonador de cosseno, parada antecipada com paciência 10, entropia cruzada com *label smoothing* de 0,1 e amostragem ponderada pelo inverso da frequência de classe). O ViT-B/16 segue o mesmo protocolo, com taxa de 5×10^{-5}, decaimento de pesos de 0,05, duas épocas de aquecimento e limitação da norma do gradiente. Cada modelo é calibrado por *temperature scaling* na validação, e τ é o menor valor, a partir de 0,85,

que assegura acurácia seletiva de ao menos 98% na validação. Em produção, o sistema devolve um de quatro veredictos: saudável, anômalo, inconclusivo (confiança < τ) ou não é folha (menos de 10% de pixels vegetativos por ExG).

Um quinto ciclo corrige três defeitos achados na auditoria: a alface passa a ser particionada pela fotografia original, com uma por original na validação e no teste (176 no teste, 15 doentes); 8.266 imagens de pastas que a rotulagem deixava de fora, quase todas de dano por praga, entram como anômalas; e a amostragem equilibra os rótulos dentro de cada cultura, sem pesos na perda, porque cultura e rótulo estavam associados (87% da alface de treino era saudável). Um lote de espinafre-de-malabar (574 imagens) fica fora do treino. São 152.057 imagens, 1,7% do teste a distância ≤ 4 do treino, e as demais fontes mantêm a partição, o que permite comparar os ciclos imagem a imagem.

3.2 Coleta dos dados de campo

Os dados de campo são coletados em hortas da região de Joinville (SC), com celular, sob luz natural e sem preparação da cena: de 100 a 300 fotografias, com mínimo de 15 e meta de 25 por cultura, cerca de metade de folhas anômalas e variedade de sintomas (manchas, clorose, míldio, furos, murcha). Para 20% a 30% das folhas há três fotografias em distâncias diferentes (perto, média e ampla), e cada cultura inclui duas ou três imagens sem folha (solo, mão), para testar a guarda de vegetação.

Quatro regras garantem a validade do conjunto: (i) o rótulo é registrado na coleta, antes de qualquer inferência, e fotografias ambíguas são marcadas, e o resultado é reportado com e sem elas; (ii) fotografias de campo nunca entram no treino; (iii) versões do modelo são comparadas sobre as mesmas fotografias; e (iv) as 13 fotografias do TCC-I formam um conjunto histórico, reportado à parte. A coleta começou em 27/10/2026, com 10 fotografias de canteiros de alface sadia, tiradas de cima, com vários pés por quadro; um lote anterior, de um pé colhido e fotografado em casa sobre toalha branca (3 folhas sadias e 7 anômalas), também é reportado à parte, por não ser de campo.

3.3 Análise dos dados

A análise responde às perguntas Q1 a Q3, com $\alpha = 0{,}05$ e a correção sequencial de Holm (1979) nas comparações múltiplas sobre os mesmos dados.

Para o desempenho no domínio de teste (Q1), considerando a classe anômala como positiva, calculam-se a partir da matriz de confusão a acurácia global, a precisão, a revocação, o F1-score por classe e macro, a área sob a curva ROC (AUC) e a latência média de inferência. A **métrica principal é a acurácia balanceada** (Equação 1), média das revocações das duas classes, que não é inflada pelo desbalanceamento de aproximadamente 1,35:1 do dataset (Brodersen et al., 2010):

$$AB = \tfrac{1}{2} \cdot \left[\frac{VP}{(VP + FN)} + \frac{VN}{(VN + FP)} \right] \tag{1}$$

Os falsos negativos — plantas doentes declaradas saudáveis — são reportados à parte, por serem o erro de maior custo agronômico. Os intervalos de confiança de 95% vêm de *bootstrap* estratificado por classe, com 10.000 reamostragens (Efron; Tibshirani, 1993), e, como as arquiteturas são avaliadas sobre as mesmas 23.967 imagens, pares de modelos são comparados pelo teste de McNemar, que considera só as imagens em que os dois discordam (McNemar, 1947; Dietterich, 1998).

Para Q2, a calibração é avaliada pelo ECE com $M = 15$ faixas de igual largura (Equação 2), onde B_m é o conjunto de predições com confiança na faixa m e n é o total de predições, antes e depois do *temperature scaling*, com diagrama de fiabilidade:

$$ECE = \Sigma_m \left(|B_m| / n \right) \cdot | \, \mathrm{acc}(B_m) - \mathrm{conf}(B_m) \, | \qquad (2)$$

O mecanismo de abstenção é avaliado pela cobertura (fração de imagens diagnosticadas), pela acurácia seletiva (acurácia entre elas) e pela fração de erros interceptados (confiança < τ); a curva risco–cobertura, com τ de 0,50 a 0,99, orienta o ponto de operação, e o teste de Mann-Whitney compara a confiança de acertos e erros.

Em campo (Q3), as abstenções têm taxa própria, as métricas de acerto são calculadas sobre os diagnósticos emitidos, e as imagens sem folha medem a guarda de vegetação. Como as amostras são pequenas, toda proporção leva intervalo de Wilson a 95% (Wilson, 1927), e a acurácia balanceada, intervalo por *bootstrap* estratificado. O *domain gap* é a diferença entre a acurácia balanceada no teste e em campo, e versões do modelo são comparadas sobre as mesmas fotografias pelo teste de McNemar exato. Para uma proporção de 80%, o intervalo de Wilson tem mais de 40 pontos com 13 fotografias, 15,5 com 100 e 9,0 com 300, o que define a meta de coleta.

Ainda em Q3, a acurácia de campo é desagregada por três hipóteses exploratórias: o desempenho difere entre culturas, pois só a alface tem dados de treino específicos (H1); é menor em sintomas estruturais, como murcha e perfurações, do que em cromáticos, como manchas e clorose (H2); e diminui com a distância de captura (H3). As três são testadas pelos testes exatos de Fisher (H2) e de Freeman-Halton (H1 e H3) e, em H3, também pelo de Cochran-Armitage (Agresti, 2013); as diferenças de proporções são reportadas com intervalo de Newcombe (1998), e os resultados, interpretados como exploratórios. Cada erro de campo é ainda examinado com mapas Grad-CAM (Selvaraju et al., 2017) e classificado quanto à causa provável.

4. Análise dos dados e discussão dos resultados

Tabela 1. Desempenho no conjunto de teste (23.967 imagens), quarto ciclo

Modelo	Parâm.	Acur. bal.	F1 macro	AUC	ECE	FN	Latência
EfficientNet-B0	4,0 M	98,48%	98,44%	0,9982	0,0039	209	7,2 ms
MobileNetV2	2,2 M	97,89%	97,83%	0,9976	0,0055	294	5,3 ms
ResNet-50	23,5 M	97,82%	97,70%	0,9966	0,0061	352	8,6 ms
ViT-B/16	85,8 M	98,48%	98,53%	0,9976	0,0018	137	19,4 ms

Parâm. = modelo treinado, com saída de duas classes. FN = falsos negativos. Latência em GPU RTX 3050 (6 GB), medida na mesma sessão para os quatro modelos. Fonte: elaboração própria (2026).

EfficientNet-B0 e ViT-B/16 empatam, com IC 95% de 98,32% a 98,64% e sem diferença significativa (p de Holm = 0,26). Ambos superam o MobileNetV2 (97,70% a 98,07%) e o ResNet-50 (97,63% a 98,00%), com $p \leq 1{,}4 \times 10^{-12}$, e estes não diferem (p = 0,26). O ViT-B/16 tem menos falsos negativos (137 contra 209) e mais falsos positivos (204 contra 154), com 21 vezes mais parâmetros e 2,7 vezes a latência.

Em Q2, o *temperature scaling* reduziu o ECE de validação a 0,0027 no EfficientNet-B0 e a 0,0022 no ViT-B/16. No teste, a confiança calibrada do EfficientNet-B0 separa acertos de erros (0,990 contra 0,874; $p < 0{,}001$), mas $\tau = 0{,}85$ intercepta apenas 113 dos 363 erros (31,1%), com abstenção em 1,2%; no ViT-B/16, 51 dos 341 (15,0%), com

abstenção em 0,5%. O ViT-B/16 tem o menor ECE e a menor fração de erros interceptados: boa calibração média não põe os erros em confiança baixa.

A Tabela 1 tem uma ressalva: o teste vem das mesmas seis fontes do treino, e os 98,48% são uma acurácia intra-fonte. No lote de espinafre-de-malabar que o modelo do terceiro ciclo nunca viu, o EfficientNet-B0 teve 75,4% (N = 484), 23 pontos abaixo, embora as imagens também sejam de folha isolada sobre fundo claro. Com o lote no treino, subiu para 88,4%, mas o ganho é intra-fonte e não informa sobre o campo.

Tabela 2. Validação exploratória em campo (13 fotografias de alface), por ciclo

Ciclo	Correção aplicada	Diagnósticos	Acertos	Proporção	IC 95% (Wilson)
1	Vazamento de dados	12 de 13	11	91,7%	[64,6%; 98,5%]
2	Abstenção; dados de alface	13 de 13	10	76,9%	[49,7%; 91,8%]
3	Rotulagem automática	11 de 13	8	72,7%	[43,4%; 90,3%]
4	Espinafre e míldio no treino	13 de 13	11	84,6%	[57,8%; 95,7%]
5	Alface por foto; amostragem	12 de 13	11	91,7%	[64,6%; 98,5%]
4*	ViT-B/16, mesmos dados	12 de 13	12	100%	[75,8%; 100%]

Ciclos 1 a 5: EfficientNet-B0. * ViT-B/16, dados do ciclo 4. Fonte: elaboração própria (2026).

Na Tabela 2, os intervalos de Wilson se sobrepõem, e com N = 13 versões e arquiteturas são indistinguíveis. A amostra revelou um defeito de rotulagem, mas não decide entre modelos. Os nove erros dos quatro primeiros ciclos tiveram confiança calibrada entre 0,949 e 0,999, e o ECE passou de 0,003 na validação para 0,146 em campo.

Tabela 3. Quinto ciclo: acurácia balanceada (%) no teste e por subconjunto

Modelo	Teste	Lavoura	Espec.	Sens.	Alface	Retido
EfficientNet-B0	97,4	86,3 → 88,8	76,6 → 83,4	96,0 → 94,2	96,7	87,9
MobileNetV2	96,9	86,6 → 90,1	78,3 → 90,2	94,9 → 90,0	100	88,4
ResNet-50	96,9	87,8 → 89,6	81,4 → 89,0	94,2 → 90,2	100	90,1
ViT-B/16	96,9	83,4 → 84,5	69,8 → 72,1	97,0 → 96,9	100	85,8

Teste do ciclo 5: 18.413 imagens. Lavoura: mandioca, arroz, cana e café (N = 4.530), também em Espec. e Sens.; ciclo 4 → ciclo 5. Alface: N = 176. Retido: espinafre, N = 574. Fonte: elaboração própria (2026).

Na Tabela 3, a correção agiu onde estavam os erros: nas culturas de lavoura, as três CNNs ganham de 1,8 a 3,5 pontos de acurácia balanceada e de 6,8 a 11,9 de especificidade, isto é, menos falsos alarmes; o ViT-B/16 quase não muda ($p = 0,66$). O custo é a sensibilidade, que cai de 1,8 a 4,9 pontos: por imagem, o quarto ciclo acerta mais ($p \leq 0,04$), pois três em cada quatro dessas imagens são anômalas. No lote retido, os quatro ficam entre 85,8% e 90,1%, dez pontos abaixo das fontes de treino.

Quanto ao Quadro 1, a queda para 75,4% em uma fonte retida é da ordem dos 73,8% da EfficientNet-B0 em um conjunto externo de videira (Ergün et al., 2026) e, como na amêndoa, só aparece com a fonte separada (Workneh et al., 2026); o contraste com os 97,3% do espinafre-de-malabar em partição interna (Kabya et al., 2026) indica que a diferença é de protocolo, não de cultura. A perda vem da pouca diversidade de captura (Barbedo, 2018), e o próprio teste a reproduz: as culturas de lavoura têm 86,3% no ciclo 4 e concentram 81% dos erros, contra 99,7% nas demais. Em videira, o ECE externo chega a 0,038, com confiança média de 0,55 (Ergün et al., 2026); aqui, 0,146 em campo.

No lote de campo, as quatro versões (EfficientNet-B0 e ViT-B/16, ciclos 4 e 5) deram como sadias as 10 fotografias da horta, sem abstenção, com confiança acima de 0,98 (Wilson: 72,2% a 100%), também em recortes centrais com metade e um quarto do lado. Solo, mato e vários pés no quadro não provocaram falso alarme, mas, sem folhas doentes, a sensibilidade em campo e o *domain gap* seguem sem medida. No lote de casa, todas as diagnosticadas saíram anômalas, inclusive as três sadias, com confiança acima de 0,97: com cada lote quase todo em uma classe, folha e cena não se separam.

5. Conclusão

Cumpridos os objetivos (a) a (c), a resposta até aqui é que o desempenho depende mais do protocolo de avaliação que da arquitetura: 98,48% de acurácia balanceada nas fontes de treino, 75,4% numa fonte nunca vista, 84,6% de acertos em 13 fotografias de campo (IC 95%: 57,8% a 95,7%) e nenhum falso alarme em 10 com fundo real.

Em Q1, EfficientNet-B0 e ViT-B/16 empatam e superam as outras duas redes; como o *transformer*, 21 vezes maior, não supera a CNN no teste e é o pior na lavoura, o EfficientNet-B0 é a arquitetura indicada, e o limite está nos dados. Em Q2, as probabilidades são bem calibradas na distribuição de treino, mas o limiar de abstenção deixa passar mais de dois terços dos erros, e em campo os erros vieram com confiança acima de 0,94: a abstenção não protege o produtor onde mais importa.

A coleta com fundo real responde a Q3 só em parte: nenhuma versão deu falso alarme em 10 fotografias de alface sadia, mas, sem folhas doentes, a sensibilidade e o *domain gap* em campo seguem sem medida, e os objetivos (d) a (f), abertos.

A principal contribuição é um protocolo reprodutível (teste intra-fonte, fonte retida e campo com rótulo prévio à inferência, e versões comparadas por testes pareados), que expôs o vazamento dos 99,01% do TCC-I e os limites da calibração fora do treino. Há limites: um treino por modelo, sem variar a semente; a tarefa é binária e não identifica a doença; parte das culturas entra apenas como *proxy* visual; e a evidência de campo se restringe à alface: 13 fotografias históricas e 10 com fundo real, todas de plantas sadias. Como trabalhos futuros, além de completar a coleta com folhas doentes e outras culturas, propõem-se recalibrar com fotografias de campo, testar extratores congelados de modelos de fundação (Nguyen et al., 2026), repetir o treino com várias sementes e definir, com produtores, o custo de cada tipo de erro, que decide entre os dois ciclos.

Referências

ABBASI, R.; MARTINEZ, P.; AHMAD, R. Crop diagnostic system: a robust disease detection and management system for leafy green crops grown in an aquaponics facility. **Artificial Intelligence in Agriculture**, v. 10, p. 1-12, 2023. DOI: 10.1016/j.aiia.2023.09.001.

AGRESTI, A. **Categorical data analysis**. 3. ed. Hoboken: Wiley, 2013.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. **IEEE Access**, v. 11, p. 9042-9057, 2023. DOI: 10.1109/ACCESS.2023.3240100.

BARBEDO, J. G. A. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. **Computers and**

Electronics in Agriculture, v. 153, p. 46-53, 2018. DOI: 10.1016/j.compag.2018.08.013.

BRODERSEN, K. H. et al. The balanced accuracy and its posterior distribution. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION, 20., 2010, Istambul. **Proceedings** [...]. IEEE, 2010. p. 3121-3124. DOI: 10.1109/ICPR.2010.764.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. **Neural Computation**, v. 10, n. 7, p. 1895-1923, 1998. DOI: 10.1162/089976698300017197.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 9., 2021. **Proceedings** [...]. 2021.

EFRON, B.; TIBSHIRANI, R. J. **An introduction to the bootstrap**. New York: Chapman & Hall, 1993.

ERGÜN, E. et al. Confidence and uncertainty aware deep learning for reliable grape leaf disease diagnosis under real world field conditions. **Frontiers in Plant Science**, v. 17, 1839652, 2026. DOI: 10.3389/fpls.2026.1839652.

FACELI, K. et al. **Inteligência artificial**: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2023.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017. **Proceedings** [...]. 2017.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. **Nature Machine Intelligence**, v. 2, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

GIL, A. C. **Como elaborar projetos de pesquisa**. 5. ed. São Paulo: Atlas, 2010.

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017. **Proceedings** [...]. PMLR, 2017. p. 1321-1330.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2016. **Proceedings** [...]. IEEE, 2016. p. 770-778.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Censo Agropecuário 2017**: resultados definitivos. Rio de Janeiro: IBGE, 2019.

KABYA, N. D. et al. Towards practical AI for agriculture: a self-supervised attention framework for spinach leaf disease detection. **PLOS ONE**, v. 21, n. 1, e0340989, 2026. DOI: 10.1371/journal.pone.0340989.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. **ACM Transactions on Knowledge Discovery from Data**, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. **Psychometrika**, v. 12, n. 2, p. 153-157, 1947. DOI: 10.1007/BF02295996.

MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. **Frontiers in Plant Science**, v. 7, 1419, 2016. DOI: 10.3389/fpls.2016.01419.

NAEINI, M. P.; COOPER, G. F.; HAUSKRECHT, M. Obtaining well calibrated probabilities using Bayesian binning. In: AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE, 29., 2015. **Proceedings** [...]. AAAI, 2015. p. 2901-2907.

NEWCOMBE, R. G. Interval estimation for the difference between independent proportions: comparison of eleven methods. **Statistics in Medicine**, v. 17, n. 8, p. 873-890, 1998.

NGUYEN, T. A. et al. From laboratory to field: frozen foundation-model features toward robust plant disease recognition. **Smart Agricultural Technology**, v. 15, 102531, 2026. DOI: 10.1016/j.atech.2026.102531.

RUSSELL, S.; NORVIG, P. **Artificial intelligence**: a modern approach. 4. ed. Hoboken: Pearson, 2022.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2018. **Proceedings** [...]. IEEE, 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017. **Proceedings** [...]. IEEE, 2017. p. 618-626.

SHAFAY, M. et al. Recent advances in plant disease detection: challenges and opportunities. **Plant Methods**, v. 21, 140, 2025. DOI: 10.1186/s13007-025-01450-0.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 36., 2019. **Proceedings** [...]. PMLR, 2019. p. 6105-6114.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. **Artificial Intelligence Review**, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927. DOI: 10.2307/2276774.

WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. **Transactions of the ASAE**, v. 38, n. 1, p. 259-269, 1995. DOI: 10.13031/2013.27838.

WORKNEH, A. D. et al. Leakage-aware, calibrated, and explainable deep learning for robust almond disease classification. **Computers and Electronics in Agriculture**, v. 256, 112464, 2026. DOI: 10.1016/j.compag.2026.112464.