UNIVERSIDADE DA REGIÃO DE JOINVILLE — UNIVILLE
Bacharelado em Engenharia de Software

JOSÉ PEDRO VIEIRA SILVA

DETECÇÃO AUTOMÁTICA DE ANOMALIAS FITOSSANITÁRIAS EM HORTALIÇAS FOLHOSAS UTILIZANDO VISÃO COMPUTACIONAL E APRENDIZADO DE MÁQUINA

Versão revista e consolidada do TCC-I, com relatório de correção metodológica e proposta de trabalho para o TCC-II

Documento submetido à apreciação do **Prof. Leanderson André** como base para consulta sobre orientação do Trabalho de Conclusão de Curso II. Consolida todo o trabalho executado até 31 de julho de 2026, incluindo a retificação de um resultado anteriormente reportado e o plano de execução do próximo semestre. Atualizado em 8 de outubro de 2026 com a nota de atualização e o capítulo 8, que registram o quarto ciclo de treinamento e a revisão crítica dos resultados.

Joinville — SC
2026

SUMÁRIO EXECUTIVO

Este documento apresenta o estado consolidado do FitoVision — sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas por visão computacional — e a proposta de trabalho para o TCC-II. Foi redigido especificamente para permitir uma avaliação rápida e completa do que já foi produzido, do rigor com que foi produzido e do que resta fazer.

O que é o projeto

Um sistema de triagem fitossanitária que classifica uma fotografia de folha como saudável ou anômala (doença, praga ou deficiência nutricional), voltado a pequenos produtores de alface, rúcula, espinafre, acelga e couve. A abordagem é Transfer Learning com fine-tuning de três CNNs pré-treinadas no ImageNet (EfficientNet-B0, MobileNetV2 e ResNet-50), servidas por uma API FastAPI com interface web em React. Todo o pipeline — aquisição, deduplicação, particionamento, treino, calibração e avaliação — é reprodutível por script.

O que já está executado e medido

- **Dataset construído: 170.772** imagens de seis fontes públicas, deduplicadas por hash perceptual e particionadas em treino/validação/teste sem vazamento entre partições (0,04 % residual no conjunto de teste).
- **Três arquiteturas treinadas e comparadas:** EfficientNet-B0 atinge 98,49 % de acurácia balanceada e 98,44 % de F1-score macro em 23.967 imagens de teste sem duplicata no treino, mas extraídas das mesmas fontes, com 8,0 ms de latência por imagem e Erro de Calibração Esperado (ECE) de 0,0047.
- **Mecanismos de confiabilidade implementados:** temperature scaling, limiar de abstenção (o sistema responde inconclusivo quando a confiança calibrada é inferior a 0,85) e guarda de vegetação por índice Excess Green, que rejeita imagens sem folha antes de acionar o classificador.
- **Primeiro teste de campo real:** 13 fotografias de alface tomadas em horta real, com gabarito, medindo pela primeira vez o gap entre laboratório e campo. Resultado: 73,3 % de acurácia balanceada — contra 98,49 % no domínio de teste.
- **Três ciclos de correção metodológica:** três ciclos completos de reconstrução do dataset e retreino dos três modelos, totalizando aproximadamente 57 horas de GPU, cada um motivado por um defeito concreto identificado e documentado.

O ponto mais importante deste documento

Retificação de resultado

A versão anterior deste TCC reportava 99,01 % de acurácia. Esse número foi **retratado**. Uma auditoria por hash perceptual demonstrou que **57,35 % do conjunto de teste original era composto por fotografias quase-idênticas a imagens presentes no treino** — os datasets públicos utilizados redistribuem, entre si e internamente, as mesmas fotografias sob nomes de arquivo diferentes e com pequenas variações de recorte e compressão. O particionamento havia sido feito por arquivo, e não por fotografia distinta. O modelo não estava diagnosticando: estava reencontrando imagens que já havia memorizado. O número honesto, após reconstrução completa do particionamento, é **98,49 % de acurácia balanceada** — e, em fotografias reais de campo, entre 43 % e 90 % (intervalo de confiança de Wilson a 95 %, N = 13).

A decisão de investigar um resultado bom demais, em vez de publicá-lo, é apresentada aqui como o principal resultado metodológico do TCC-I. O trabalho deixou de ser "treinamos três CNNs e obtivemos 99 %" — que a literatura já esgotou — e passou a ser um estudo sobre por que esses 99 % aparecem com tanta frequência na literatura de diagnóstico foliar e o que é preciso fazer para obter um número em que se possa confiar.

O que se propõe para o TCC-II

1. Ampliar o conjunto de validação de campo para 100 a 300 fotografias coletadas em hortas da região de Joinville, com gabarito assistido por literatura fitopatológica. Esta é a etapa bloqueante: a análise estatística demonstrou que a amostra atual (N = 13) não tem poder para distinguir entre versões do modelo.
2. Quantificar formalmente o domain gap com essa amostra e avaliar estratégias de mitigação (fine-tuning com dados de campo, augmentation orientado a condições reais, adaptação de domínio).
3. Incluir o Vision Transformer ViT-B/16 na comparação, inviável no hardware atual (RTX 3050, 6 GB de VRAM).
4. Estender a tarefa para classificação multiclasse das anomalias, condicionada à disponibilidade de dados rotulados por tipo.
5. Testar a hipótese, levantada pela análise de erros, de que o modelo pondera mais pistas de cor do que pistas estruturais ao decidir por anômalo.

O que se pede à orientação

O projeto tem infraestrutura, dados e código funcionando; o que precisa de orientação é o desenho experimental do TCC-II — em particular o protocolo de coleta e rotulagem de campo, o tratamento estatístico adequado a amostras pequenas e desbalanceadas, e o recorte do escopo entre mitigação do domain gap e extensão para multiclasse. As áreas de Visão

Computacional, Aprendizado de Máquina e Ciência de Dados são exatamente as que o trabalho mobiliza.

NOTA DE REVISÃO E ERRATA

Esta é a segunda versão do TCC-I do FitoVision. A primeira versão, apresentada anteriormente, continha um resultado experimental inválido. Esta seção registra, de forma explícita, o que mudou e por quê — em conformidade com a boa prática científica de retificação pública de resultados.

Item	Versão anterior	Esta versão	Motivo da alteração
Acurácia (EfficientNet-B0)	99,01 %	98,49 % (bal.)	Vazamento de dados de 57,35 % no conjunto de teste original
Tamanho do dataset	210.832 imagens	170.772 imagens	Deduplicação e descarte de grupos com rótulo conflitante
Conjunto de teste	31.625 imagens	23.967 imagens	Particionamento agrupado por fotografia distinta
Métrica principal	Acurácia global	Acurácia balanceada	Robustez ao desbalanceamento entre classes
Calibração de confiança	Não avaliada	ECE = 0,0047	Confiança reportada precisa corresponder ao acerto real
Abstenção do modelo	Inexistente	$\tau = 0{,}85$; cobertura 98,9 %	Sistema de triagem deve poder recusar-se a diagnosticar
Validação em campo	Não realizada	N = 13; 73,3 %	Único instrumento capaz de medir o domain gap real
Análise Grad-CAM	Sobre modelo invalidado	Regenerada	Mapas anteriores derivavam de pesos treinados com vazamento
Baseline ingênuo	Declarado atendido	Parcial (trivial)	A CNN treinada do zero não chegou a ser executada

Quadro 1 — Síntese das alterações em relação à versão anterior do TCC-I. *Fonte: elaboração própria (2026).*

Três correções distintas foram necessárias, cada uma originando um ciclo completo de reconstrução do dataset e retreino dos três modelos:

- **Ciclo 1 — vazamento de dados:** as partições de treino, validação e teste foram refeitas agrupando fotografias quase-idênticas por hash perceptual, de modo que um mesmo conteúdo visual nunca apareça em duas partições. O vazamento caiu de 57,35 % para 0,04 %.
- **Ciclo 2 — abstenção inoperante:** descobriu-se que o mecanismo de abstenção implementado nunca era acionado, por um erro no algoritmo de escolha do limiar. Corrigido, e o dataset foi expandido com três fontes adicionais de alface.
- **Ciclo 3 — bug de rotulagem:** a rotina de rotulagem automática classificava como doente uma pasta inteira sempre que o nome do diretório-contêiner continha a palavra disease, sem descer aos subdiretórios. Isso rotulou incorretamente 3.972 imagens de alface

saudável — provenientes da única fonte específica de alface do projeto — desde o primeiro dia.

O terceiro defeito só se tornou visível porque o teste de campo existia. Nenhuma das métricas de laboratório — acurácia, F1, matriz de confusão, AUC — o denunciava, porque o erro era consistente entre treino, validação e teste. Esse é, isoladamente, o argumento mais forte a favor da validação em condições reais que este trabalho produziu.

NOTA DE ATUALIZAÇÃO — OUTUBRO DE 2026

Esta terceira versão acrescenta ao documento de 31 de julho de 2026 o que foi feito no TCC-II até 8 de outubro: um quarto ciclo de treinamento e uma revisão crítica do que os resultados permitem afirmar. O conteúdo novo está no capítulo 8. Os capítulos 1 a 7 foram mantidos como registro do estado de julho, com três correções pontuais indicadas ao final desta nota.

A revisão mudou a leitura central do trabalho. O conjunto de teste, embora livre de duplicatas, é extraído das mesmas seis fontes do treino, nas mesmas proporções. Os 98,49 % medem, portanto, o acerto em fotografias parecidas com as de treino — uma acurácia intra-fonte — e não devem ser lidos como desempenho de laboratório em sentido amplo. Em uma fonte que o modelo nunca havia visto, a acurácia balanceada caiu para 75,4 % (N = 484), e em horta os erros observados foram emitidos com 95 % a 99 % de confiança. O modelo está preso à aparência dos dados de treino; o que falta são fotografias com fundo semelhante ao do uso real.

Correções pontuais nos capítulos anteriores: (i) a seção 3.2.2 descrevia o hash canônico por mínimo lexicográfico, abordagem abandonada por ser instável, e passa a descrever a comparação da órbita completa; (ii) a seção 4.5 afirmava que os mapas Grad-CAM confirmavam a ausência de dependência do fundo, conclusão que os dados não sustentam; (iii) o sumário executivo descrevia o teste como imagens nunca vistas, sem dizer que provêm das mesmas fontes do treino.

NOTA DE ATUALIZAÇÃO — 14 DE OUTUBRO DE 2026

Esta quarta versão acrescenta o capítulo 9, com o que foi feito entre 12 e 14 de outubro de 2026: a comparação entre quatro arquiteturas, com a inclusão de um *Vision Transformer* (ViT-B/16); uma auditoria de consistência, que conferiu cada número do trabalho contra os artefatos de origem (particionamento em disco, registros de treino e previsões por imagem); e um quinto ciclo de treinamento, que corrige os defeitos encontrados pela auditoria. Os capítulos 1 a 8 continuam como registro dos estados de julho e de 8 de outubro.

A auditoria corrigiu números que aparecem nos capítulos anteriores. Para não reescrever o registro, as correções ficam listadas aqui; o capítulo 9 dá os detalhes, e o arquivo docs/FICHA_TECNICA_FITOVISION.md é a fonte única dos números conferidos.

- **Composição do treino (seções 4.5, 8.2 e 8.5):** onde se lê que cerca de 70% do treino deriva do PlantVillage ou é folha isolada sobre fundo homogêneo, leia-se: no máximo 47,7% deriva do PlantVillage. A fonte descrita como reedição do PlantVillage é uma coletânea que inclui mandioca, arroz, cana-de-açúcar e café fotografados em lavoura (17,6% do treino).
- **Número de parâmetros (resumo e tabela da seção 4.3):** 5,3, 3,4 e 25,6 milhões são as arquiteturas originais, de 1.000 classes. Os modelos treinados, com saída de duas classes, têm 4,0 (EfficientNet-B0), 2,2 (MobileNetV2) e 23,5 milhões (ResNet-50); o ViT-B/16 treinado tem 85,8 milhões, 21 vezes o EfficientNet-B0.
- **Tamanho do dataset:** são três etapas, e não versões divergentes: 176.126 imagens reunidas, 170.772 nas partições da base (após o descarte de grupos com rótulos contraditórios) e 175.123 com os lotes do quarto ciclo.
- **Vazamento residual de 0,04%:** vale para o critério de semelhança visual. O critério não alcança variantes muito alteradas da mesma fotografia: 23% do teste da base são rotações, recortes e filtros de fotografias de alface com outra variante no treino (seção 9.2). O quinto ciclo corrige isso.
- **Fotografias de campo (seção 4.6):** nenhuma das 13 fotografias do conjunto histórico tem metadados EXIF de telefone celular, e uma delas é de câmera digital de 2014, editada; a procedência de cada uma ainda será registrada. A auditoria confirmou que nenhuma é duplicata de imagem de treino.

NOTA DE ATUALIZAÇÃO — 16 DE OUTUBRO DE 2026

Esta quinta versão acrescenta a seção 9.6. Os trabalhos relacionados tinham sido lidos pelos resumos indexados na Web of Science; em 16 de outubro, sete deles foram lidos na íntegra, e a leitura corrigiu duas afirmações. A revisão de Shafay et al. (2025) não diverge do resultado do ViT-B/16: ela aponta as arquiteturas híbridas como mais robustas e o ViT puro como mais sensível ao ambiente, o que concorda com o desempenho do ViT-B/16 nas fotografias de lavoura. E a queda de 98,7% para cerca de 31% atribuída a Gerz e Jelali (2026) é de mAP50 em detecção de objetos, e não de acurácia. O artigo passou à versão 8 com essas correções.

NOTA DE ATUALIZAÇÃO — 27 DE OUTUBRO DE 2026

Esta sexta versão acrescenta a seção 9.7, com o primeiro lote de fotografias de campo com fundo real: 10 fotografias de canteiros de alface sadia, tiradas em uma horta em 27 de outubro. As quatro versões avaliadas (o EfficientNet-B0 e o ViT-B/16 do quarto e do quinto ciclos) classificaram as 10 como sadias, e solo, mato e vários pés no quadro não provocaram falso alarme. Como não houve folhas doentes nesse lote, a sensibilidade em campo e o *domain gap* ainda não puderam ser medidos. O artigo passou à versão 11, reduzida a 10 páginas a pedido do orientador; a conclusão da versão 9 foi a entregue na disciplina em 27 de outubro.

RESUMO

A detecção precoce de anomalias fitossanitárias em hortaliças folhosas é um desafio relevante para a agricultura familiar brasileira, que responde por 77 % dos estabelecimentos agropecuários do país e raramente dispõe de assistência agronômica regular. Este trabalho propõe, implementa e avalia um sistema de triagem fitossanitária automatizada para alface, rúcula, espinafre, acelga e couve, baseado em Transfer Learning com fine-tuning de três arquiteturas de redes neurais convolucionais pré-treinadas no ImageNet: EfficientNet-B0, MobileNetV2 e ResNet-50. Um dataset binário de 170.772 imagens foi construído a partir de seis fontes públicas e submetido a deduplicação por hash perceptual invariante a rotações, com particionamento agrupado por fotografia distinta — procedimento adotado após a constatação, por auditoria, de que um particionamento ingênuo por arquivo produzia 57,35 % de vazamento entre treino e teste e inflava artificialmente as métricas. No conjunto de teste corrigido, o EfficientNet-B0 obteve 98,49 % de acurácia balanceada, 98,44 % de F1-score macro e AUC de 0,9984, com 8,0 ms de latência por imagem e apenas 5,3 milhões de parâmetros, superando o ResNet-50 (25,6 milhões) em todas as métricas. As probabilidades foram calibradas por temperature scaling, reduzindo o Erro de Calibração Esperado de 0,0495 para 0,0024, e o sistema foi dotado de um mecanismo de classificação seletiva que devolve resposta inconclusiva abaixo de 0,85 de confiança, além de uma guarda de vegetação baseada no índice Excess Green. Uma validação exploratória com 13 fotografias de alface capturadas em horta real registrou 73,3 % de acurácia balanceada, evidenciando um domain gap substancial em relação ao desempenho de laboratório; a análise por intervalo de confiança de Wilson demonstra, contudo, que a amostra não tem poder estatístico para comparar versões do modelo, o que estabelece a ampliação do conjunto de campo como pré-requisito metodológico do TCC-II. O sistema completo, incluindo API FastAPI e interface web em React, encontra-se operacional. A contribuição principal deste trabalho é metodológica: um protocolo reprodutível de detecção, quantificação e correção de vazamento de dados, rotulagem automática defeituosa e otimismo de calibração em pipelines de diagnóstico foliar — classe de defeitos raramente reportada na literatura da área, ainda que plausivelmente frequente.

Palavras-chave: visão computacional; aprendizado profundo; redes neurais convolucionais; transfer learning; hortaliças folhosas; detecção de anomalias fitossanitárias; vazamento de dados; calibração de confiança; classificação seletiva; domain gap.

ABSTRACT

Early detection of phytosanitary anomalies in leafy vegetables is a relevant challenge for Brazilian family farming, which accounts for 77 % of the country's agricultural establishments and rarely has access to regular agronomic assistance. This work proposes, implements and evaluates an automated phytosanitary screening system for lettuce, arugula, spinach, chard and kale, based on transfer learning with fine-tuning of three ImageNet-pretrained convolutional neural network architectures: EfficientNet-B0, MobileNetV2 and ResNet-50. A binary dataset of 170,772 images was built from six public sources and subjected to perceptual-hash deduplication with rotation invariance, using a grouped split by distinct photograph — a procedure adopted after an audit revealed that a naive per-file split produced 57.35 % train-test leakage and artificially inflated all metrics. On the corrected test set, EfficientNet-B0 achieved 98.49 % balanced accuracy, 98.44 % macro F1-score and 0.9984 AUC, with 8.0 ms inference latency and only 5.3 million parameters, outperforming ResNet-50 (25.6 million) across every metric. Output probabilities were calibrated by temperature scaling, reducing Expected Calibration Error from 0.0495 to 0.0024, and the system was equipped with a selective classification mechanism that returns an inconclusive verdict below 0.85 confidence, together with an Excess Green vegetation guard. An exploratory field validation with 13 lettuce photographs captured in a real garden recorded 73.3 % balanced accuracy, evidencing a substantial domain gap; Wilson confidence interval analysis nevertheless shows the sample lacks statistical power to compare model versions, establishing field-set expansion as a methodological prerequisite for the second phase. The complete system, including a FastAPI backend and a React web interface, is operational. The main contribution is methodological: a reproducible protocol for detecting, quantifying and correcting data leakage, faulty automatic labelling and calibration overconfidence in leaf-diagnosis pipelines — a class of defects seldom reported in the field's literature, though plausibly common.

Keywords: computer vision; deep learning; convolutional neural networks; transfer learning; leafy vegetables; phytosanitary anomaly detection; data leakage; confidence calibration; selective classification; domain gap.

LISTA DE ABREVIATURAS E SIGLAS

AMP	Automatic Mixed Precision
API	Application Programming Interface
AUC	Area Under the ROC Curve
BFS	Breadth-First Search (busca em largura)
CNN	Convolutional Neural Network (rede neural convolucional)
CV	Computer Vision (visão computacional)
ECE	Expected Calibration Error (erro de calibração esperado)
ExG	Excess Green Index (índice de excesso de verde)
F1	F1-Score (média harmônica entre precisão e revocação)
FN	Falso Negativo
FP	Falso Positivo
GPU	Graphics Processing Unit
Grad-CAM	Gradient-weighted Class Activation Mapping
IA	Inteligência Artificial
IBGE	Instituto Brasileiro de Geografia e Estatística
IC	Intervalo de Confiança
LSH	Locality-Sensitive Hashing
ML	Machine Learning (aprendizado de máquina)
MVP	Minimum Viable Product (produto mínimo viável)
OOM	Out of Memory
ROC	Receiver Operating Characteristic
TCC	Trabalho de Conclusão de Curso
ViT	Vision Transformer
VRAM	Video Random Access Memory
XAI	Explainable Artificial Intelligence (IA explicável)

SUMÁRIO

SUMÁRIO EXECUTIVO
NOTA DE REVISÃO E ERRATA
NOTA DE ATUALIZAÇÃO — OUTUBRO DE 2026
NOTA DE ATUALIZAÇÃO — 14 DE OUTUBRO DE 2026
NOTA DE ATUALIZAÇÃO — 16 DE OUTUBRO DE 2026
NOTA DE ATUALIZAÇÃO — 27 DE OUTUBRO DE 2026
1 DEFINIÇÃO DO PROJETO
1.1 Tema
1.2 Justificativa
1.3 Questão de pesquisa
1.4 Objetivo geral
1.5 Objetivos específicos
2 REVISÃO DA LITERATURA
2.1 Visão computacional e IA aplicadas à agricultura
2.2 Fundamentos de aprendizado profundo
2.3 Redes neurais convolucionais
2.4 Transfer learning
2.5 Vision Transformers e modelos híbridos
2.6 Vazamento de dados e validade experimental
2.7 O problema da generalização (domain gap)
2.8 Calibração de confiança e classificação seletiva
2.9 IA explicável e Grad-CAM
2.10 Anomalias em hortaliças folhosas e datasets disponíveis
2.11 Trabalhos relacionados
3 PROCEDIMENTOS METODOLÓGICOS
3.1 Delineamento da pesquisa
3.2 Pipeline metodológico
3.3 Ambiente experimental
3.4 Protocolo de validação em campo
3.5 Técnicas de análise de dados
4 RESULTADOS
4.1 Definição do MVP
4.2 Auditoria de vazamento e reconstrução do dataset
4.3 Desempenho no conjunto de teste
4.4 Calibração e classificação seletiva
4.5 Explicabilidade — Grad-CAM
4.6 Validação em campo e análise de poder estatístico

4.7 Sistema em operação
4.8 Critérios de validação do MVP
5 DISCUSSÃO
5.1 Três defeitos e o que cada um ensina
5.2 Por que o teste de laboratório não bastou
5.3 Comparação com a literatura
6 LIMITAÇÕES E TRABALHO FUTURO
6.1 Limitações reconhecidas
6.2 Proposta de execução do TCC-II
6.3 Cronograma
7 CONSIDERAÇÕES FINAIS
8 ATUALIZAÇÃO DO TCC-II: QUARTO CICLO E REVISÃO CRÍTICA
8.1 Quarto ciclo de treinamento
8.2 O que o conjunto de teste mede
8.3 Ganho do quarto ciclo e correção de uma pseudo-replicação
8.4 Confiança em campo
8.5 Hipótese do fundo e ajustes propostos
8.6 Registro consolidado de erros e ajustes
9 ATUALIZAÇÃO DE OUTUBRO DE 2026: QUATRO ARQUITETURAS, AUDITORIA E QUINTO CICLO
9.1 Quatro arquiteturas
9.2 Auditoria de consistência
9.3 Quinto ciclo: o que foi corrigido
9.4 Quinto ciclo: resultados
9.5 O que muda
9.6 O que a literatura lida na íntegra acrescenta
9.7 Primeiro lote de campo com fundo real
REFERÊNCIAS
APÊNDICE A — ÍNDICE DE ARTEFATOS EXPERIMENTAIS

1 DEFINIÇÃO DO PROJETO

Este capítulo apresenta a definição do projeto de pesquisa: o tema, sua justificativa, a questão de pesquisa central e os objetivos que norteiam o trabalho. Os objetivos foram revistos em relação à primeira versão do TCC-I para incorporar as três frentes metodológicas que emergiram durante a execução — controle de vazamento de dados, calibração de confiança e validação em condições reais.

1.1 Tema

O projeto situa-se na interseção entre Inteligência Artificial, Visão Computacional e Ciência de Dados aplicadas ao agronegócio. O tema central é a detecção automática de anomalias fitossanitárias — doenças, deficiências nutricionais e danos por pragas — em hortaliças folhosas, por meio de algoritmos de aprendizado de máquina aplicados a imagens digitais.

A escolha de hortaliças folhosas como objeto de estudo justifica-se por sua relevância econômica na agricultura familiar da região de Joinville e do Sul do Brasil, e pela existência de um nicho sub-representado na literatura: a quase totalidade dos trabalhos de diagnóstico foliar automatizado concentra-se em culturas de grande escala — tomate, milho, batata, uva —, para as quais existem datasets públicos abundantes.

1.2 Justificativa

1.2.1 Delimitação

O estudo delimita-se à detecção de anomalias visuais em folhas de alface (Lactuca sativa), rúcula (Eruca vesicaria), espinafre (Spinacia oleracea), acelga (Beta vulgaris var. cicla) e couve (Brassica oleracea var. acephala). As anomalias-alvo compreendem doenças fúngicas como míldio e oídio, deficiências nutricionais manifestadas como clorose, danos por pragas e estresse hídrico. A tarefa é de classificação binária — saudável versus anômalo — caracterizando um sistema de triagem, não de diagnóstico etiológico.

Delimita-se também o que o sistema explicitamente não faz: não identifica a espécie de patógeno, não prescreve tratamento e não substitui a avaliação agronômica. Sua função é priorizar a atenção humana, sinalizando quais plantas merecem inspeção.

1.2.2 Relevância científica e acadêmica

A aplicação de aprendizado profundo ao diagnóstico fitossanitário é um campo em expansão acelerada. Mohanty, Hughes e Salathé (2016) demonstraram que CNNs treinadas no dataset PlantVillage atingem acurácias superiores a 99 % em condições controladas, estabelecendo um marco para a área. A generalização para condições reais de campo, contudo, permanece uma lacuna reconhecida (Ahmad; Gamal; Saraswat, 2023; Barbedo, 2018).

A execução deste trabalho revelou uma segunda lacuna, menos discutida e possivelmente mais consequente: a fragilidade dos protocolos de validação empregados. Ao auditar o próprio conjunto de teste por hash perceptual, constatou-se que 57,35 % dele era composto por fotografias visualmente quase-idênticas a imagens do conjunto de treino — resultado direto de os datasets públicos redistribuírem, entre si e internamente, o mesmo material sob nomes de arquivo distintos. Um particionamento por arquivo, procedimento padrão e raramente questionado, é suficiente para produzir esse vazamento. Este trabalho contribui, portanto, em duas frentes: aplica e compara três arquiteturas de transfer learning no domínio de hortaliças folhosas, e documenta um protocolo reprodutível de auditoria e correção de vazamento aplicável a qualquer pipeline da área.

1.2.3 Relevância social

Segundo o Censo Agropecuário de 2017 (IBGE, 2019), 77 % dos estabelecimentos rurais brasileiros são de agricultura familiar, e apenas cerca de 20 % dos produtores familiares dispõem de acesso regular a assistência técnica especializada. Esses produtores dependem de inspeção visual manual para o diagnóstico fitossanitário — processo lento, inconsistente e dependente de experiência acumulada. Uma ferramenta computacional acessível, executável a partir de um telefone celular, pode reduzir perdas de produção e democratizar o acesso a tecnologia de precisão.

Essa mesma relevância social impõe uma exigência técnica: um sistema que erra silenciosamente é pior que a ausência de sistema, porque transfere confiança indevida ao usuário. Daí a ênfase deste trabalho em calibração de confiança e em mecanismos de abstenção — o sistema precisa ser capaz de responder “não sei”.

1.2.4 Relevância para a formação acadêmica

O desenvolvimento do trabalho consolida competências centrais para um engenheiro de software: construção de pipelines de dados reprodutíveis, treinamento e avaliação de

modelos de aprendizado de máquina, versionamento de experimentos, análise estatística de resultados e escrita científica. A natureza interdisciplinar do projeto — Engenharia de Software, Inteligência Artificial e Agronomia — estimula o pensamento sistêmico e a aplicação de conhecimento técnico a um problema real.

1.2.5 Viabilidade

O projeto é tecnicamente viável: os datasets necessários são públicos e gratuitos; os frameworks de aprendizado profundo são de código aberto e amplamente documentados; o treinamento foi conduzido em GPU local NVIDIA RTX 3050 (6 GB de VRAM, CUDA 12.3) e é reproduzível em Google Colab. O sistema completo — pipeline de dados, três modelos treinados, API e interface web — encontra-se implementado e operacional, o que remove o risco de viabilidade técnica do escopo do TCC-II.

1.2.6 Questão de pesquisa

Questão de pesquisa

Como automatizar a detecção precoce de anomalias fitossanitárias em hortaliças folhosas por meio de visão computacional e aprendizado de máquina, de modo a produzir diagnósticos **cuja confiabilidade seja mensurável e honestamente reportada**, apoiando decisões de manejo de pequenos e médios produtores rurais?

A formulação difere da versão anterior pela inclusão explícita da cláusula sobre confiabilidade mensurável. Essa alteração não é retórica: decorre da constatação empírica de que a métrica originalmente reportada era inválida e de que o desempenho real em campo é substancialmente inferior ao de laboratório. Medir bem passou a ser parte da pergunta, e não apenas do método.

1.3 Objetivo geral

Desenvolver e avaliar um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas utilizando visão computacional e aprendizado de máquina, com ênfase na comparação entre três arquiteturas de redes neurais convolucionais com transfer learning — EfficientNet-B0, MobileNetV2 e ResNet-50 — e no estabelecimento de um protocolo de avaliação livre de vazamento de dados, com confiança calibrada e validação em condições reais de campo, de modo a contribuir com um framework metodológico extensível a outras culturas agrícolas.

1.4 Objetivos específicos

a. Realizar revisão da literatura sobre detecção de doenças e anomalias em plantas por visão computacional e aprendizado de máquina, incluindo a literatura sobre vazamento de dados, calibração de confiança e generalização entre domínios;

b. Construir um dataset binário de imagens de folhas a partir de fontes públicas, com procedimento explícito de deduplicação e particionamento agrupado por fotografia distinta;

c. Auditar quantitativamente o vazamento entre partições e reportar a métrica de vazamento residual junto com as métricas de desempenho;

d. Implementar pipeline de pré-processamento com redimensionamento, normalização e data augmentation compatível com o sinal a detectar;

e. Treinar e comparar modelos de classificação baseados em transfer learning — EfficientNet-B0, MobileNetV2 e ResNet-50 —, com o Vision Transformer ViT-B/16 previsto para o TCC-II;

f. Avaliar os modelos por acurácia balanceada, precisão, revocação, F1-score macro, AUC e matriz de confusão, reportando a acurácia balanceada como métrica principal;

g. Calibrar as probabilidades de saída por temperature scaling e quantificar o Erro de Calibração Esperado antes e depois;

h. Implementar e avaliar um mecanismo de classificação seletiva (abstenção) e uma guarda de domínio que rejeite imagens sem vegetação;

i. Aplicar Grad-CAM para verificar se as regiões de ativação correspondem a áreas patologicamente relevantes;

j. Coletar e avaliar um conjunto de fotografias de campo, com gabarito, quantificando o domain gap e o poder estatístico da amostra;

k. Analisar a extensibilidade da metodologia proposta a outras culturas agrícolas;

l. Produzir monografia e artigo científico documentando metodologia, experimentos e resultados, incluindo a retificação do resultado anteriormente reportado.

Os objetivos c, g, h e j são acréscimos desta versão. Todos decorrem de problemas encontrados durante a execução, e não de planejamento prévio — o que é, em si, um registro honesto do processo de pesquisa.

2 REVISÃO DA LITERATURA

Este capítulo apresenta os fundamentos teóricos e o estado da arte que sustentam a pesquisa. Além das seções usuais sobre visão computacional, aprendizado profundo e arquiteturas de rede, foram incorporadas duas seções novas — vazamento de dados (2.6) e calibração de confiança e classificação seletiva (2.8) — cuja necessidade só se tornou evidente durante a execução experimental.

2.1 Visão computacional e inteligência artificial aplicadas à agricultura

A Inteligência Artificial e a Visão Computacional consolidaram-se como tecnologias habilitadoras da agricultura de precisão, permitindo monitoramento automatizado de culturas com redução de custos operacionais e de dependência de especialistas humanos (Jafar et al., 2024; Upadhyay et al., 2025). Na perspectiva de Russell e Norvig (2022), um sistema de IA pode ser compreendido como um agente que percebe seu ambiente por sensores e age sobre ele por atuadores; no contexto agrícola, a câmera de um telefone celular atua como sensor, captando imagens foliares em ambiente parcialmente observável.

O trabalho de Mohanty, Hughes e Salathé (2016) demonstrou que redes neurais convolucionais treinadas no PlantVillage classificam 26 doenças em 14 espécies com acurácia superior a 99 %, marcando o início de intensa produção científica na área, que desde então incorporou drones, sensores IoT, imagens multiespectrais e aplicativos móveis (Dhanya et al., 2022; Jafar et al., 2024). É relevante notar que os próprios autores desse trabalho seminal reportaram queda acentuada de desempenho ao avaliar os modelos em imagens obtidas em condições distintas das do treinamento — advertência que boa parte da literatura subsequente não incorporou.

2.2 Fundamentos de aprendizado profundo para classificação de imagens

O aprendizado profundo constitui um subconjunto do aprendizado de máquina baseado em redes neurais artificiais com múltiplas camadas de representação. Conforme Russell e Norvig (2022, cap. 18), uma rede feed-forward multicamadas é composta por camada de entrada, camadas ocultas e camada de saída, nas quais cada neurônio computa uma soma ponderada das entradas seguida de função de ativação não linear. O treinamento minimiza uma função de perda por backpropagation, que propaga os gradientes do erro da saída até a entrada, ajustando os pesos pela descida do gradiente.

Faceli et al. (2023, cap. 7) detalham o formalismo desse ajuste, demonstrando que a convergência depende criticamente da taxa de aprendizado, do tamanho do lote e de técnicas de regularização como dropout e early stopping. Os mesmos autores enfatizam que a estimativa de erro de generalização só é válida se o conjunto de teste for genuinamente independente do conjunto de treino — condição cuja verificação prática é o objeto da seção 2.6.

2.3 Redes neurais convolucionais

As redes neurais convolucionais constituem a arquitetura dominante para classificação de imagens. Diferentemente das redes densas, exploram a estrutura espacial bidimensional por meio de camadas convolucionais, que aplicam filtros aprendíveis para extrair mapas de características; camadas de pooling, que reduzem a dimensionalidade preservando as características mais salientes; e camadas totalmente conectadas, que realizam a classificação final (Russell; Norvig, 2022, cap. 18).

ResNet-50 (He et al., 2016) introduziu as conexões residuais, que permitem o treinamento eficaz de redes com dezenas ou centenas de camadas ao mitigar o problema do gradiente desvanecente. A arquitetura de 50 camadas e 25,6 milhões de parâmetros tornou-se referência em classificação e é amplamente utilizada como backbone em domínios agrícolas (Saleem et al., 2020).

MobileNetV2 (Sandler et al., 2018) foi projetada para dispositivos com recursos limitados, utilizando convoluções separáveis em profundidade e blocos residuais invertidos para reduzir o número de parâmetros a 3,4 milhões mantendo acurácia competitiva. Essa eficiência viabiliza inferência em tempo real em telefones celulares — aspecto crucial para o cenário de edge AI na agricultura familiar (Ahmed; Reddy, 2021; Gajjar et al., 2021).

EfficientNet-B0 (Tan; Le, 2019) propôs o escalonamento composto, que equilibra sistematicamente profundidade, largura e resolução da rede, alcançando a melhor relação acurácia por parâmetro de sua geração com apenas 5,3 milhões de parâmetros. Os resultados deste trabalho corroboram empiricamente essa tese, como se detalha no capítulo 4.

2.4 Transfer learning

A transferência de aprendizado consiste na reutilização de pesos aprendidos em uma tarefa-fonte — tipicamente a classificação das mil categorias do ImageNet — como ponto de partida para uma tarefa-alvo com dados escassos (Faceli et al., 2023, cap. 7). O procedimento

pode envolver o congelamento das camadas iniciais e o ajuste apenas das finais, ou o ajuste fino de toda a rede. Mohanty, Hughes e Salathé (2016) demonstraram que CNNs pré-treinadas no ImageNet e ajustadas no PlantVillage atingem 99,35 % de acurácia na classificação de doenças em 14 espécies.

Neste trabalho adotou-se ajuste fino completo, viável dado o volume de dados disponível (mais de 120 mil imagens de treino). Barbedo (2018) observa que o benefício do transfer learning em diagnóstico foliar é maior justamente quando o conjunto-alvo é pequeno ou pouco diverso, e que o aumento do volume de dados tem retorno decrescente se a diversidade não aumentar junto — observação diretamente relevante para o resultado da seção 4.6.

2.5 Vision Transformers e modelos híbridos

Os Vision Transformers, introduzidos por Dosovitskiy et al. (2021), representam uma mudança de paradigma ao substituir operações convolucionais pelo mecanismo de self-attention, capturando dependências globais desde as primeiras camadas. Modelos híbridos CNN+ViT têm se mostrado eficazes no diagnóstico foliar, atingindo acurácias entre 98 % e 100 % em milho, uva e tomate (Ghosh et al., 2025; Aboelenin et al., 2025; Thakur et al., 2023).

A avaliação do ViT-B/16 está prevista para o TCC-II. A arquitetura, com 86 milhões de parâmetros, é inviável no hardware atual: estima-se entre 45 e 75 horas por execução de 30 épocas na RTX 3050 de 6 GB, com risco de esgotamento de memória mesmo com lotes de 8 imagens. Cabe registrar que os resultados desta classe de modelos reportados na literatura são, em geral, obtidos sobre o PlantVillage com particionamento por arquivo, e portanto sujeitos à mesma ressalva metodológica discutida a seguir.

2.6 Vazamento de dados e validade experimental

Vazamento de dados (data leakage) designa a presença, no conjunto de avaliação, de informação que não estaria disponível no momento da predição real — tipicamente por contaminação a partir do conjunto de treino. Kaufman et al. (2012) formalizam o conceito e argumentam que o vazamento é a causa mais frequente de resultados irreprodutíveis em mineração de dados, precisamente porque produz métricas excelentes que passam despercebidas: ninguém investiga um número bom.

No domínio de imagens, a forma mais comum de vazamento é a duplicação quase-exata. Dois arquivos distintos podem conter a mesma fotografia com recorte, compressão, rotação ou redimensionamento diferentes. Um particionamento aleatório por arquivo distribui essas cópias entre treino e teste, e o modelo — que memoriza com facilidade — reencontra no teste imagens que já viu. Geirhos et al. (2020) descrevem o fenômeno mais amplo do shortcut learning: redes profundas exploram preferencialmente qualquer regularidade que reduza a perda, ainda que não corresponda ao conceito que se pretende ensinar.

O risco é agravado em datasets agregados de fontes públicas. Datasets de doenças de plantas no Kaggle frequentemente redistribuem o PlantVillage, integral ou parcialmente, às vezes já com augmentation aplicado — de modo que a mesma fotografia original pode aparecer dezenas de vezes, sob nomes diferentes, em fontes aparentemente independentes. O procedimento adotado neste trabalho para mitigar o problema, descrito na seção 3.2, baseia-se em hash perceptual com agrupamento por união-busca, e o vazamento residual é reportado como métrica de primeira classe junto às métricas de desempenho.

2.7 O problema da generalização (domain gap)

Um dos desafios mais críticos da literatura em diagnóstico foliar automatizado é a discrepância entre o desempenho em condições controladas de laboratório e o desempenho em condições reais de campo — fenômeno denominado domain gap (Ahmad; Gamal; Saraswat, 2023). Modelos treinados exclusivamente no PlantVillage, cujas imagens apresentam folha única sobre fundo homogêneo e iluminação controlada, atingem entre 95 % e 99 % em seu próprio conjunto de teste; avaliados em imagens capturadas em lavoura, a acurácia pode cair para a faixa de 31 % a 72 % (Mohanty; Hughes; Salathé, 2016; Upadhyay et al., 2025; Ahmad; Gamal; Saraswat, 2023).

As causas são bem identificadas: fotografias de campo contêm solo, sombra, folhas sobrepostas, oclusão parcial, iluminação natural variável e múltiplas plantas por quadro. Barbedo (2018) acrescenta que a diversidade de condições de captura importa mais que o volume bruto de imagens, e que ampliar um dataset homogêneo tende a produzir ganhos marginais no domínio-alvo.

Este trabalho enfrenta ainda uma dificuldade adicional: o PlantVillage não contém alface, rúcula, espinafre, acelga ou couve. As culturas-alvo são representadas apenas por fontes específicas de alface, e o conhecimento do modelo sobre as demais é inteiramente transferido de tomate, batata, milho e mandioca. Trata-se de um duplo salto de domínio — de

estúdio para campo e de espécie proxy para espécie-alvo —, o que torna a validação em campo não uma formalidade, mas o único instrumento capaz de estimar a utilidade real do sistema.

2.8 Calibração de confiança e classificação seletiva

Uma rede neural de classificação produz, via softmax, um vetor de probabilidades. Guo et al. (2017) demonstraram que essas probabilidades são sistematicamente mal calibradas em redes profundas modernas: um modelo que reporta 99 % de confiança tipicamente acerta bem menos que 99 % das vezes. Os autores mostram que o problema se agravou com o aumento de capacidade das arquiteturas e propõem o temperature scaling — divisão dos logits por um escalar T aprendido no conjunto de validação — como correção eficaz e que não altera a classe predita, apenas a confiança reportada.

A qualidade da calibração é medida pelo Erro de Calibração Esperado (ECE), que particiona as predições em faixas de confiança e acumula a diferença absoluta média entre confiança declarada e acurácia observada em cada faixa. ECE igual a zero indica calibração perfeita.

Sobre um modelo calibrado é possível construir um classificador seletivo. Geifman e El-Yaniv (2017) formalizam o arcabouço de classificação com opção de rejeição: o modelo pode abster-se quando a confiança fica abaixo de um limiar τ, trocando cobertura por acurácia seletiva. Em um sistema de triagem fitossanitária destinado a usuários sem formação técnica, essa é uma propriedade desejável — é preferível responder "inconclusivo, procure inspeção" a emitir um diagnóstico errado com aparência de certeza.

Complementarmente, adota-se neste trabalho uma guarda de domínio anterior ao classificador, baseada no índice Excess Green ($ExG = 2g - r - b$ sobre canais RGB normalizados), proposto por Woebbecke et al. (1995) para segmentação de vegetação. Imagens cuja fração de pixels vegetativos é insuficiente são rejeitadas antes de qualquer inferência, evitando que o sistema emita diagnóstico fitossanitário sobre uma fotografia que sequer contém uma planta.

2.9 Inteligência artificial explicável e Grad-CAM

A explicabilidade de modelos profundos constitui exigência científica e prática para a adoção de sistemas de diagnóstico automatizado. Conforme Faceli et al. (2023, cap. 10), a

interpretabilidade é critério de avaliação tão relevante quanto a acurácia, especialmente quando as decisões impactam produção e segurança alimentar.

A técnica adotada é o Gradient-weighted Class Activation Mapping, proposta por Selvaraju et al. (2017). O Grad-CAM calcula os gradientes do escore da classe predita em relação aos mapas de características de uma camada convolucional, ponderando-os para gerar um mapa de calor sobreposto à imagem original. No contexto desta pesquisa cumpre dupla função: validação científica, verificando se os modelos focam regiões de lesão foliar; e diagnóstico de falhas, revelando quando a decisão se apoia em artefatos irrelevantes.

Registre-se uma limitação prática da técnica, encontrada durante a execução e relatada na seção 4.5: a escolha da camada-alvo afeta drasticamente o resultado. Para o EfficientNet-B0, a última camada de features — uma convolução de projeção 1×1 — produz mapas degenerados, concentrados em uma única célula da grade 7×7. A camada correta para a análise é o último bloco MBConv.

2.10 Anomalias em hortaliças folhosas e datasets disponíveis

As hortaliças folhosas investigadas são culturas de ciclo curto, alta perecibilidade e expressiva importância na agricultura familiar do Sul do Brasil (IBGE, 2019). As principais anomalias incluem doenças fúngicas como míldio e oídio, deficiências nutricionais manifestadas como clorose foliar, e danos mecânicos causados por pragas.

O dataset mais utilizado na literatura é o PlantVillage, com mais de 54 mil imagens de folhas de 14 espécies (Mohanty; Hughes; Salathé, 2016), capturadas em condições laboratoriais com fundo homogêneo. Para as culturas-alvo deste trabalho, o levantamento de fontes públicas produziu um resultado que se registra por rigor: existem datasets de doenças de alface no Kaggle, mas

não foi localizado nenhum dataset público de doenças foliares especificamente para rúcula, espinafre, acelga ou couve. Trata-se de uma lacuna real de dados públicos, e não de insuficiência de busca — o que restringe, no estado atual, a validade das conclusões às culturas efetivamente representadas, sobretudo a alface.

Tentou-se ainda aproveitar 20 datasets da plataforma Roboflow. Todos se revelaram datasets de detecção de objetos, com anotações em caixas delimitadoras e não rótulos de classificação; a conversão para o formato binário foi implementada e retornou zero imagens aproveitáveis. Esse resultado negativo é reportado por integridade metodológica.

2.11 Trabalhos relacionados

O Quadro 2 sintetiza os trabalhos mais relevantes identificados na revisão, confrontados com o presente trabalho. Note-se que as acurácias reportadas na literatura raramente vêm acompanhadas de descrição do procedimento de particionamento ou de auditoria de duplicatas, o que dificulta a comparação direta.

Autores	Cultura	Dataset	Arquitetura	Acurácia	Validação de campo
Mohanty et al. (2016)	26 culturas	PlantVillage	AlexNet, GoogLeNet	99,35 %	Sim (queda relatada)
Too et al. (2019)	Múltiplas	PlantVillage	Fine-tuning CNNs	98,8 %	Não
Islam et al. (2023)	Folhosas	LeafyVclassify7BD	ResNet, YOLOv5	~91 %	Não
Thakur et al. (2023)	Múltiplas	PlantVillage	ViT + CNN híbrido	~98 %	Não
Ghosh et al. (2025)	Tomate	Próprio	Swin + EfficientNetV2	~98 %	Não
FitoVision (este TCC)	**Folhosas**	**Multifonte (170.772)**	**EfficientNet-B0**	**98,49 % (bal.)**	**Sim — 73,3 % (N = 13)**

Quadro 2 — Comparação entre trabalhos relacionados e o presente trabalho. *Fonte: elaboração própria (2026).*

O diferencial deste trabalho não está na acurácia — que é comparável, e nominalmente inferior à de vários trabalhos do quadro. Está em quatro aspectos: foco em hortaliças folhosas, nicho sub-representado; auditoria explícita e quantificada de vazamento entre partições; reporte conjunto de calibração, cobertura e acurácia seletiva, e não apenas de acurácia bruta; e validação em fotografias de campo com análise de poder estatístico. Um número menor, obtido sob protocolo verificável, é preferível a um número maior de procedência não auditada.

3 PROCEDIMENTOS METODOLÓGICOS

3.1 Delineamento da pesquisa

O trabalho caracteriza-se como pesquisa quantitativa, dado que os resultados são expressos por métricas numéricas objetivas e submetidos a análise estatística comparativa. Quanto aos objetivos, é exploratório-descritiva: exploratória na investigação de qual arquitetura apresenta melhor desempenho no domínio específico de hortaliças folhosas, e descritiva na documentação sistemática do comportamento de cada modelo sob diferentes configurações.

A estratégia é a de pesquisa experimental computacional, na qual os modelos são implementados, treinados e avaliados sob condições controladas e reprodutíveis, com registro protocolar de todos os parâmetros de entrada e métricas de saída. Adotou-se, adicionalmente, uma postura de auditoria adversarial sobre os próprios resultados: toda métrica anômala — em particular, anomalamente boa — é tratada como hipótese a investigar antes de ser aceita como resultado. Essa postura, e não um planejamento inicial, foi o que revelou os três defeitos descritos no capítulo 5.

3.2 Pipeline metodológico

O pipeline organiza-se em oito estágios sequenciais, integralmente automatizados por script e retomáveis em caso de interrupção.

3.2.1 Estágio 1 — Aquisição e organização dos dados

As imagens são obtidas de fontes públicas do Kaggle e organizadas em uma hierarquia de três níveis: um diretório de dados brutos, jamais modificado; um diretório de staging, com cópias organizadas por rótulo; e o diretório de partições finais. A separação garante que todo o processo possa ser reexecutado do zero a partir dos arquivos originais.

A rotulagem é automática, por busca em largura sobre a árvore de diretórios de cada dataset, associando nomes de pasta a rótulos por meio de listas de palavras-chave. Um mapa de auditoria registra a proveniência de cada decisão pasta-para-rótulo, permitindo verificação posterior — recurso que se revelou essencial, pois foi exatamente nessa rotina que se encontrou o defeito descrito na seção 5.1.

3.2.2 Estágio 2 — Deduplicação por hash perceptual

Cada imagem é reduzida a um hash perceptual, uma assinatura compacta que permanece estável sob recompressão, redimensionamento e pequenas alterações de recorte. Para tornar a assinatura invariante a rotações de 90° e espelhamentos, calcula-se o hash sobre as oito transformações do grupo diedral D4 e guarda-se a órbita completa: duas imagens são consideradas variantes quando alguma orientação de uma está próxima de alguma orientação da outra. Uma primeira versão reduzia a órbita ao mínimo lexicográfico, mas esse seletor é descontínuo — um único bit perturbado troca a orientação escolhida — e foi abandonado depois de falhar em teste sintético.

Imagens cuja distância de Hamming entre hashes é menor ou igual a 4 são consideradas a mesma fotografia. O agrupamento emprega união-busca sobre candidatos obtidos por Locality-Sensitive Hashing, evitando a comparação quadrática de todos os pares — inviável na escala de 176 mil imagens. Os hashes são persistidos em cache, de modo que uma reexecução do pipeline não repete o custo do cálculo.

3.2.3 Estágio 3 — Particionamento agrupado

O particionamento é feito sobre **grupos de fotografias distintas, e não sobre arquivos**. Um grupo inteiro é atribuído a treino, validação ou teste, jamais dividido entre partições. Utiliza-se semente fixa (42) e proporção aproximada de 70/15/15 sobre os grupos, com estratificação por classe. Grupos cujos membros possuem rótulos conflitantes — indício de rotulagem inconsistente entre fontes — são descartados integralmente.

Ao final do estágio, uma auditoria independente recalcula o vazamento residual: a fração de imagens do conjunto de teste que possui alguma vizinha, dentro do limiar de Hamming, no conjunto de treino. Essa métrica é reportada junto com os resultados e funciona como critério de aceitação do particionamento.

3.2.4 Estágio 4 — Pré-processamento e data augmentation

Todas as imagens são redimensionadas para 224×224 pixels e normalizadas com média e desvio-padrão do ImageNet. Ao conjunto de treino aplicam-se espelhamento horizontal e vertical, rotação de até 30°, variação moderada de brilho, contraste e saturação, e desfoque gaussiano ocasional. Validação e teste recebem apenas redimensionamento e normalização.

A intensidade das transformações de cor foi deliberadamente limitada. Augmentation cromático agressivo é contraproducente neste domínio, porque o sinal a detectar — clorose, necrose, manchas — é, em grande parte, justamente uma alteração de cor. Uma variação de saturação suficientemente forte transforma uma folha clorótica em uma folha saudável e vice-versa, introduzindo ruído de rótulo.

3.2.5 Estágio 5 — Treinamento com transfer learning

As três arquiteturas são inicializadas com pesos pré-treinados no ImageNet e submetidas a ajuste fino completo por 30 épocas. Utiliza-se o otimizador AdamW (Loshchilov; Hutter, 2019) com decaimento de peso desacoplado de 1×10^{-4}, escalonador CosineAnnealingLR, early stopping com paciência de 10 épocas e precisão mista automática em float16. A função de perda é a entropia cruzada com label smoothing de 0,1 (Müller; Kornblith; Hinton, 2019).

O desbalanceamento entre classes é tratado por amostragem ponderada, na qual a probabilidade de sorteio de cada imagem é inversamente proporcional à frequência de sua classe, complementada por pesos de classe na função de perda. Sem esse tratamento, um classificador que respondesse sempre "anômalo" obteria 58,7 % de acurácia global sem aprender nada.

3.2.6 Estágio 6 — Calibração e classificação seletiva

Após o treinamento, cada modelo é calibrado por temperature scaling sobre o conjunto de validação: otimiza-se um único escalar T que minimiza a entropia cruzada dos logits divididos por T, sem alterar as classes preditas. Registram-se o ECE antes e depois da calibração e a temperatura obtida.

Em seguida seleciona-se o limiar de abstenção τ, definido como o menor limiar que atinge a acurácia seletiva desejada, respeitando um piso mínimo. O piso é necessário por uma razão específica ao caso binário: a confiança máxima de um softmax de duas classes nunca é inferior a 0,5, de modo que um algoritmo que busque o menor τ a partir de 0,5 encontra sempre 0,5 quando a acurácia global já é elevada, produzindo cobertura de 100 % e abstenção inoperante. Esse foi, precisamente, o defeito descrito na seção 5.1.

3.2.7 Estágio 7 — Avaliação

Cada modelo é avaliado no conjunto de teste por acurácia global, acurácia balanceada, precisão, revocação e F1-score — macro e por classe —, AUC, ECE, matriz de confusão e

latência média de inferência. Adota-se a acurácia balanceada como métrica principal, por ser insensível ao desbalanceamento entre classes. Reporta-se separadamente a contagem de falsos negativos, erro mais crítico no contexto agronômico, pois corresponde a uma planta doente declarada sadia.

3.2.8 Estágio 8 — Explicabilidade e validação em campo

Geram-se mapas Grad-CAM para amostras representativas de cada classe e modelo, incluindo falsos negativos. Por fim, o modelo em produção é avaliado sobre um conjunto de fotografias capturadas em condições reais, descrito na seção 3.4.

3.3 Ambiente experimental

Componente	Especificação
GPU	NVIDIA RTX 3050 Laptop — 6 GB VRAM, driver 546.18, CUDA 12.3
Sistema operacional	Windows 11 Education
Linguagem	Python 3.12
Framework de ML	PyTorch 2.5.1+cu121, torchvision
Augmentation	Albumentations
Métricas	scikit-learn, NumPy
Explicabilidade	pytorch-grad-cam
Backend	FastAPI + Uvicorn
Frontend	React 19 + TypeScript + Vite 6
Persistência	SQLite assíncrono via SQLAlchemy
Visualização	Matplotlib, Seaborn

Quadro 3 — Ambiente experimental. *Fonte: elaboração própria (2026).*

O treinamento dos três modelos, repetido em três ciclos completos de correção, consumiu aproximadamente 57 horas de GPU. A limitação de 6 GB de VRAM determinou o tamanho de lote (64 imagens) e é a razão pela qual o ViT-B/16 foi adiado para o TCC-II.

3.4 Protocolo de validação em campo

A validação em campo é o único instrumento capaz de estimar o desempenho real do sistema, e por isso recebeu protocolo próprio. As diretrizes adotadas são as seguintes.

- **Condições de captura:** fotografias capturadas com telefone celular, em horta real, sob luz natural, sem preparação da cena — sem remover a folha da planta, sem fundo artificial, sem controle de iluminação.

- **Gabarito independente:** cada fotografia recebe rótulo saudável ou anômalo antes de qualquer inferência do modelo, e imagens visualmente ambíguas são excluídas do conjunto e o motivo da exclusão é registrado.
- **Isolamento estrito:** o conjunto de campo jamais é utilizado para treinamento. Violar essa regra reintroduziria, entre campo e campo, exatamente o tipo de vazamento que motivou toda a reconstrução do dataset.
- **Conjunto fixo para comparação:** comparações entre versões do modelo são feitas sobre exatamente o mesmo conjunto de fotografias. Acrescentar imagens entre avaliações invalidaria a comparação.
- **Tratamento das abstenções:** a abstenção é contabilizada separadamente dos acertos e erros. Uma resposta inconclusiva não é um erro — é o comportamento pretendido diante de incerteza.
- **Reporte com incerteza:** toda proporção estimada sobre a amostra é acompanhada de intervalo de confiança de Wilson a 95 % (Wilson, 1927), método adequado a amostras pequenas, para o qual a aproximação normal é inválida.

O conjunto atualmente disponível é de 13 fotografias de alface, insuficiente para comparação entre modelos, conforme demonstrado na seção 4.6. A ampliação para 100 a 300 fotografias é o objetivo prioritário do TCC-II.

3.5 Técnicas de análise de dados

A análise segue abordagem estatística quantitativa: métricas de classificação calculadas pelo scikit-learn; matrizes de confusão e diagramas de fiabilidade visualizados com Matplotlib e Seaborn; curvas de aprendizado por época para diagnóstico de sobreajuste; mapas Grad-CAM para validação qualitativa; e intervalos de confiança de Wilson para toda proporção estimada sobre amostras pequenas. Todos os hiperparâmetros e métricas de cada execução são registrados em JSON estruturado, e cada ciclo de correção preserva os artefatos do ciclo anterior para comparação.

4 RESULTADOS

Este capítulo apresenta os resultados experimentais do sistema em seu estado atual, correspondente ao terceiro e último ciclo de reconstrução do dataset. Todos os números foram obtidos com o conjunto de teste corrigido e são rastreáveis aos artefatos listados no Apêndice A.

4.1 Definição do MVP

O MVP consiste em um pipeline computacional funcional e validado para classificação binária de anomalias em imagens de folhas de hortaliças, servido por API e interface web. A escolha da tarefa binária como produto mínimo justifica-se por três razões: reduz a complexidade inicial, permitindo validar a integridade do pipeline; corresponde à primeira decisão que um sistema de triagem fitossanitária precisa tomar; e serve de linha de base quantitativa para medir o ganho incremental da classificação multiclasse no TCC-II.

Ao escopo original acrescentaram-se, durante a execução, dois componentes que hoje se consideram parte do mínimo viável e não extensões opcionais: a calibração das probabilidades de saída e o mecanismo de abstenção. Um sistema de triagem que não pode declarar incerteza não é minimamente viável para uso por produtores sem formação técnica.

4.2 Auditoria de vazamento e reconstrução do dataset

A auditoria por hash perceptual foi aplicada primeiro ao particionamento original, construído por sorteio aleatório de arquivos. O resultado motivou a reconstrução completa do dataset.

Métrica	Particionamento original	Particionamento corrigido
Imagens totais	210.832	170.772
Fotografias distintas	106.403	97.830
Redundância interna	49,5 %	44,5 %
Vazamento no conjunto de teste	**57,35 %**	**0,04 %**
Vazamento no conjunto de validação	57,08 %	0,05 %
Veredicto da auditoria	GRAVE	OK

Tabela 1 — Auditoria de vazamento antes e depois da reconstrução do particionamento. Vazamento = fração de imagens do conjunto que possui fotografia quase-idêntica no conjunto de treino (distância de Hamming ≤ 4). *Fonte: elaboração própria (2026).*

Mais da metade do conjunto de teste original já havia sido vista durante o treinamento, sob outro nome de arquivo. A acurácia de 99,01 % anteriormente reportada não media

capacidade de diagnóstico: media memorização. O particionamento agrupado reduziu o vazamento a 0,04 %, valor compatível com o ruído esperado de qualquer método de deduplicação por similaridade.

O dataset reconstruído provém de seis fontes públicas do Kaggle. A composição final, após deduplicação e descarte de uma imagem corrompida e de 167 grupos com rótulos conflitantes entre fontes, é apresentada na Tabela 2.

Partição	Saudável	Anômalo	Total	Grupos distintos
Treino	52.393	68.468	120.861	68.365
Validação	10.300	15.644	25.944	14.649
Teste	9.908	14.059	23.967	14.649
Total	**72.601**	**98.171**	**170.772**	**97.663**

Tabela 2 — Composição do dataset após reconstrução. O particionamento é feito sobre grupos de fotografias distintas, nunca sobre arquivos individuais. *Fonte: elaboração própria (2026).*

O desbalanceamento resultante é de aproximadamente 1,35 para 1 em favor da classe anômala — mais favorável que a proporção de 2 para 1 do dataset original, consequência da correção de rotulagem descrita na seção 5.1. Ainda assim, o tratamento por amostragem ponderada foi mantido, e a acurácia balanceada é reportada como métrica principal.

4.3 Desempenho no conjunto de teste

Os três modelos foram treinados por 30 épocas e avaliados sobre as 23.967 imagens do conjunto de teste, jamais utilizadas durante treinamento, validação ou calibração. A Tabela 3 apresenta os resultados.

Modelo	Parâm.	Acurácia	Acur. bal.	F1 macro	AUC	ECE	FN	FP	Latência
EfficientNet-B0 ★	**5,3 M**	**98,49 %**	**98,49 %**	**98,44 %**	**0,9984**	**0,0047**	**212**	**150**	**8,0 ms**
MobileNetV2	3,4 M	98,11 %	98,18 %	98,05 %	0,9981	0,0044	314	140	5,1 ms
ResNet-50	25,6 M	97,72 %	97,73 %	97,66 %	0,9965	0,0071	325	221	5,8 ms

Tabela 3 — Desempenho no conjunto de teste de 23.967 imagens. ★ Modelo em produção. FN = falsos negativos (folha doente declarada sadia); FP = falsos positivos. Latência medida em GPU RTX 3050. *Fonte: elaboração própria (2026).*

O EfficientNet-B0 obteve o melhor desempenho em todas as métricas de qualidade e foi escolhido como modelo de produção. O achado mais relevante da comparação é que o ResNet-50, com 4,8 vezes mais parâmetros que o EfficientNet-B0, ficou em último lugar em todas as métricas — corroborando empiricamente a tese de Tan e Le (2019) de que o

escalonamento composto é mais eficiente do que o simples aumento de profundidade ou de número de parâmetros.

A análise dos falsos negativos é especialmente relevante no contexto agronômico: um falso negativo corresponde a uma planta doente declarada sadia, permitindo o alastramento da doença. O EfficientNet-B0 registrou 212 falsos negativos em 14.059 imagens anômalas (1,51 %), contra 314 do MobileNetV2 (2,23 %) e 325 do ResNet-50 (2,31 %). Note-se, contudo, que o MobileNetV2 obteve o menor número de falsos positivos (140), o que o torna preferível caso o custo de uma inspeção desnecessária fosse considerado mais alto que o de uma doença não detectada — o que não é o caso neste domínio.

A Tabela 4 detalha o desempenho por classe do modelo em produção.

Classe	Precisão	Revocação	F1-score	Suporte
Saudável	97,87 %	98,49 %	98,18 %	9.908
Anômalo	98,93 %	98,49 %	98,71 %	14.059
Média macro	**98,40 %**	**98,49 %**	**98,44 %**	**23.967**

Tabela 4 — Desempenho por classe do EfficientNet-B0 no conjunto de teste. *Fonte: elaboração própria (2026).*

A revocação idêntica nas duas classes (98,49 %) indica que o tratamento do desbalanceamento foi eficaz: o modelo não privilegia a classe majoritária. Um classificador trivial que respondesse sempre "anômalo" obteria 58,66 % de acurácia global, 50,00 % de acurácia balanceada e 36,97 % de F1 macro — referência que confirma que as métricas obtidas refletem aprendizado efetivo, e não exploração do desbalanceamento.

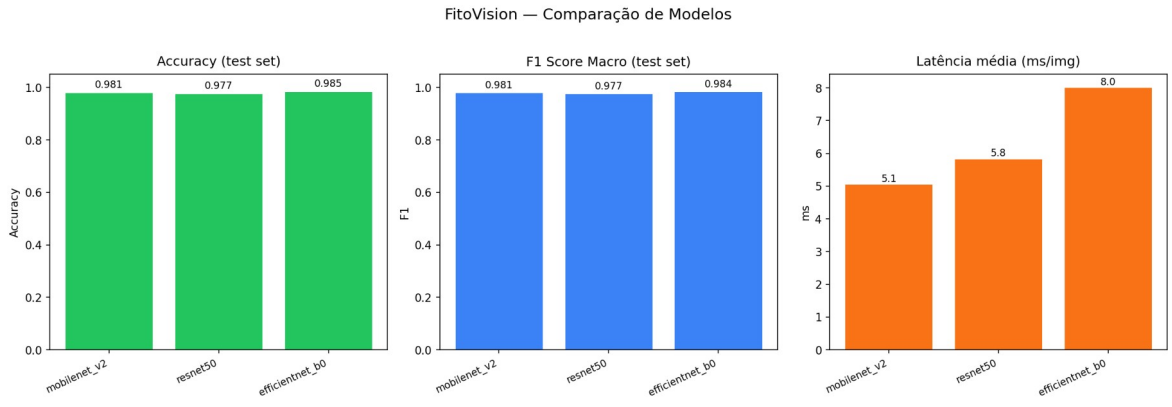


Figura 1 — Comparação das três arquiteturas no conjunto de teste. *Fonte: elaboração própria (2026).*

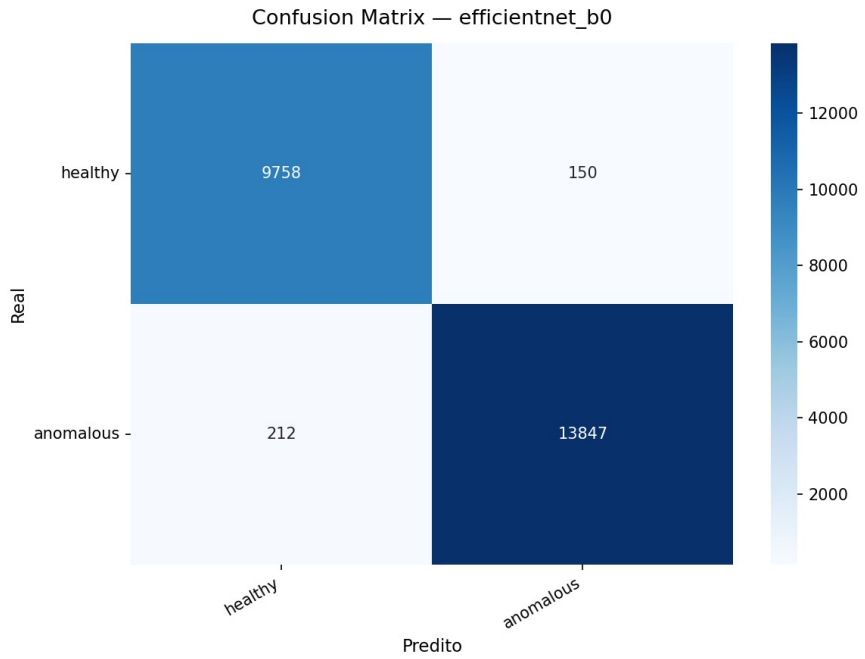


Figura 2 — Matriz de confusão do EfficientNet-B0 no conjunto de teste de 23.967 imagens. *Fonte: elaboração própria (2026).*

4.4 Calibração e classificação seletiva

As probabilidades de saída dos três modelos foram calibradas por temperature scaling sobre o conjunto de validação. A Tabela 5 apresenta os resultados.

Modelo	Temperatura T	ECE antes	ECE depois	Limiar τ	Cobertura	Acur. seletiva
EfficientNet-B0 ★	**0,5515**	**0,0495**	**0,0024**	**0,85**	**98,92 %**	**99,16 %**
MobileNetV2	0,5455	0,0524	0,0047	0,85	98,17 %	99,07 %
ResNet-50	0,5547	0,0475	0,0031	0,85	97,73 %	99,07 %

Tabela 5 — Calibração por temperature scaling e limiar de abstenção. Cobertura = fração de imagens para as quais o sistema emite diagnóstico; acurácia seletiva = acurácia entre as imagens efetivamente diagnosticadas. Valores medidos no conjunto de validação. *Fonte: elaboração própria (2026).*

A calibração reduziu o ECE do modelo em produção de 0,0495 para 0,0024, uma melhora de vinte vezes. Um aspecto merece registro por ser contraintuitivo: a temperatura aprendida é inferior a 1 nos três modelos. Como o temperature scaling divide os logits por T, um valor abaixo de 1

aumenta a confiança reportada — ou seja, os modelos estavam *sub*confiantes no conjunto de validação limpo, e não superconfiantes como é usual na literatura (Guo et al., 2017). A explicação mais provável é o label smoothing de 0,1 empregado no treinamento, que limita deliberadamente a confiança máxima alcançável a cerca de 0,95. A consequência prática é

relevante para o desenho do sistema: a calibração torna o modelo mais confiante e, portanto, *reduz* a frequência com que a abstenção é acionada.

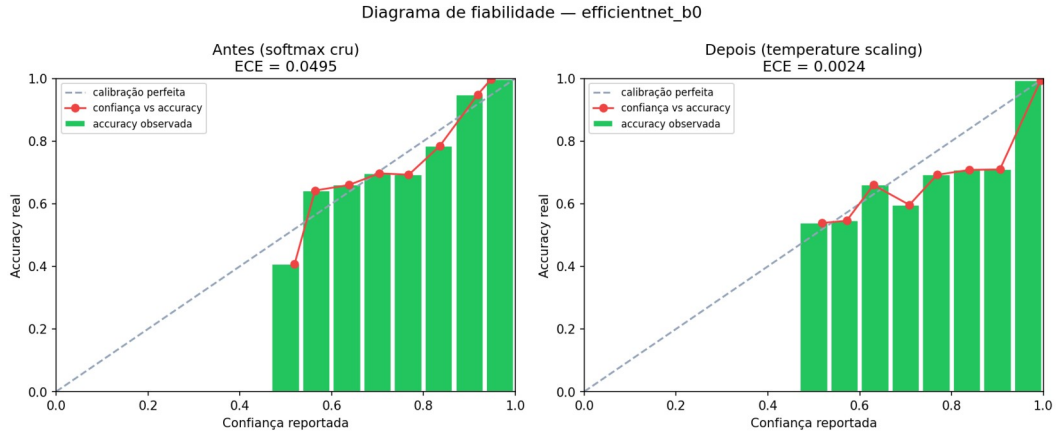


Figura 3 — Diagrama de fiabilidade do EfficientNet-B0 antes e depois da calibração por temperature scaling. *Fonte: elaboração própria (2026).*

O limiar de abstenção foi fixado em $\tau = 0{,}85$. Abaixo desse valor de confiança calibrada o sistema devolve o veredicto inconclusivo em vez de arriscar um diagnóstico. Para quantificar a utilidade do mecanismo, mediu-se, sobre todo o conjunto de teste, que fração dos erros do modelo em produção cai abaixo do limiar e é, portanto, interceptada antes de chegar ao usuário.

Nessa verificação, o modelo comete 404 erros. Desses, 138 — ou 34,2 % — apresentam confiança calibrada inferior a τ e são convertidos em resposta inconclusiva antes de chegar ao usuário. A abstenção é acionada em 1,4 % das imagens, e a acurácia entre as efetivamente diagnosticadas sobe de 98,31 % para 98,87 %. Entre os falsos negativos, 95 dos 263 são interceptados; entre os falsos positivos, 43 dos 141.

O sinal que o mecanismo explora é a diferença de confiança entre acertos e erros: 0,991 de confiança calibrada média nos acertos contra 0,866 nos erros. A separação é real mas parcial — dois terços dos erros permanecem acima do limiar e são emitidos com aparência de certeza. Elevar τ interceptaria mais erros ao custo de mais abstenções, e a escolha do ponto de operação é, em última análise, uma decisão de projeto sobre o custo relativo de errar e de não responder. Registre-se que a temperatura inferior a 1 discutida acima trabalha contra o mecanismo, ao deslocar as confianças para cima.

Esta medição foi realizada em passagem independente sobre o conjunto de teste, com redimensionamento direto para 224×224; a pequena diferença de acurácia em relação à Tabela 3 (98,31 % contra 98,49 %) decorre dessa variante de pré-processamento e não afeta as proporções relatadas.

Complementarmente, uma guarda de domínio baseada no índice Excess Green (Woebbecke et al., 1995) é aplicada antes da inferência: imagens cuja fração de pixels vegetativos é insuficiente recebem o veredicto “não é folha” sem acionar o classificador. Esse mecanismo evita a situação — observada nos testes iniciais do sistema — em que uma fotografia de um objeto qualquer recebia um diagnóstico fitossanitário confiante.

4.5 Explicabilidade — Grad-CAM

Mapas Grad-CAM foram gerados para as três arquiteturas sobre amostras do conjunto de teste: quatro folhas saudáveis corretamente classificadas, quatro folhas anômalas corretamente classificadas e dois falsos negativos por modelo, totalizando 30 mapas.

Registra-se, antes dos resultados, um achado de natureza técnica. A primeira geração dos mapas utilizou, para o EfficientNet-B0, a última camada do bloco de features — uma convolução de projeção 1×1 para 1.280 canais, escolha sugerida pela documentação da biblioteca empregada. Os mapas resultantes eram degenerados: exatamente uma célula da grade 7×7 ficava acima da metade da intensidade em todas as imagens testadas, produzindo um ponto quente fixo e não informativo. Substituída a camada-alvo pelo último bloco MBConv, os mapas passaram a ser espacialmente distribuídos e interpretáveis. O episódio é relatado porque a versão anterior deste trabalho apresentava conclusões sobre explicabilidade que, além de derivarem de pesos treinados com vazamento, poderiam estar apoiadas em mapas degenerados.

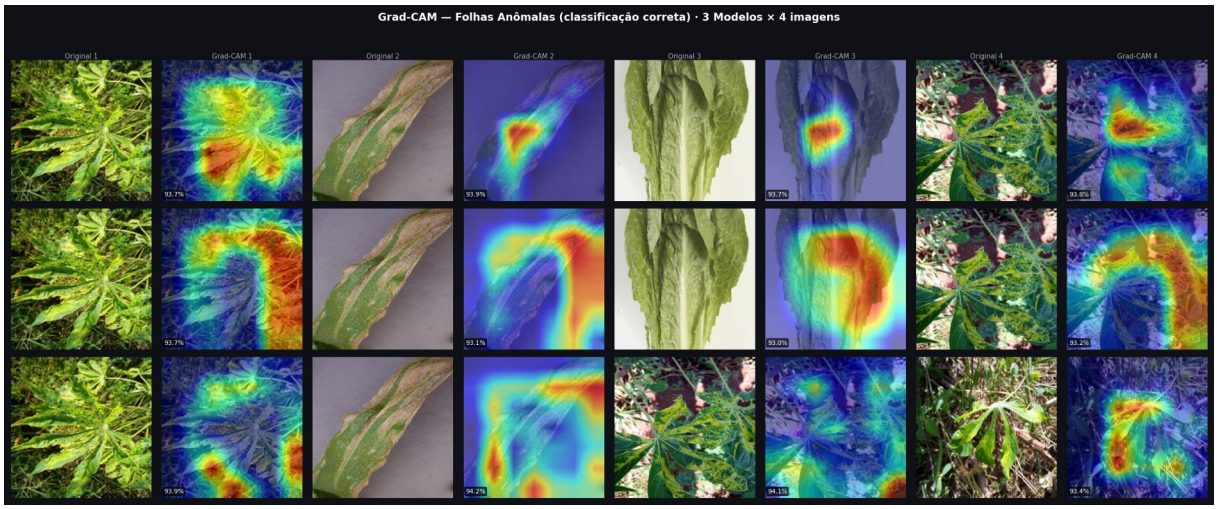


Figura 4 — Mapas Grad-CAM para folhas anômalas corretamente classificadas. Linhas: EfficientNet-B0, MobileNetV2 e ResNet-50. Os valores indicam a confiança bruta da predição. *Fonte: elaboração própria (2026).*

O EfficientNet-B0 (primeira linha) concentra as ativações sobre as lesões foliares de forma localizada: na segunda coluna, sobre a região necrosada da folha alongada; na terceira,

precisamente sobre a mancha escura central da alface romana. O MobileNetV2 (segunda linha) apresenta ativações em faixas amplas, que cobrem a região foliar mas com localização menos precisa. O ResNet-50 (terceira linha) produz mapas mais fragmentados. A ordenação qualitativa dos três é coerente com a ordenação quantitativa de falsos negativos apresentada na Tabela 3.

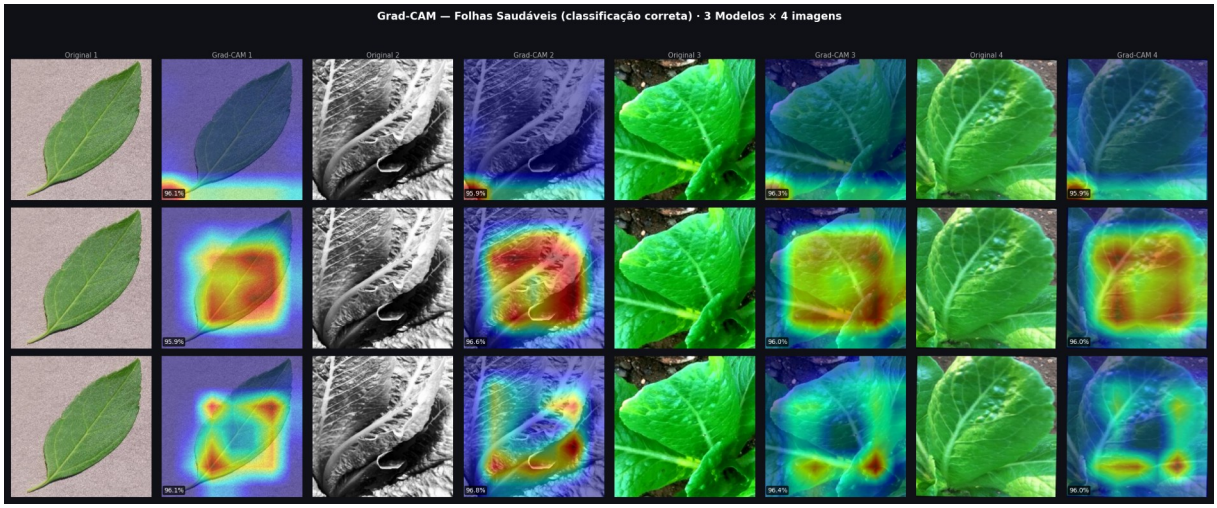


Figura 5 — Mapas Grad-CAM para folhas saudáveis corretamente classificadas. A ativação difusa sobre o limbo foliar é o comportamento esperado na ausência de lesões localizadas. *Fonte: elaboração própria (2026).*

Nas folhas saudáveis os mapas são mais difusos e distribuídos sobre o limbo foliar, comportamento esperado: sem lesão localizada, não há região específica a destacar. O resultado é compatível com uma decisão apoiada em textura e coloração foliar, mas não exclui dependência do fundo ou de viés de aquisição — risco concreto, dado que cerca de 70 % das imagens de treino têm fundo homogêneo de estúdio. Mapas qualitativos sobre imagens do próprio domínio não bastam para descartá-la; o teste direto está proposto na seção 8.5.

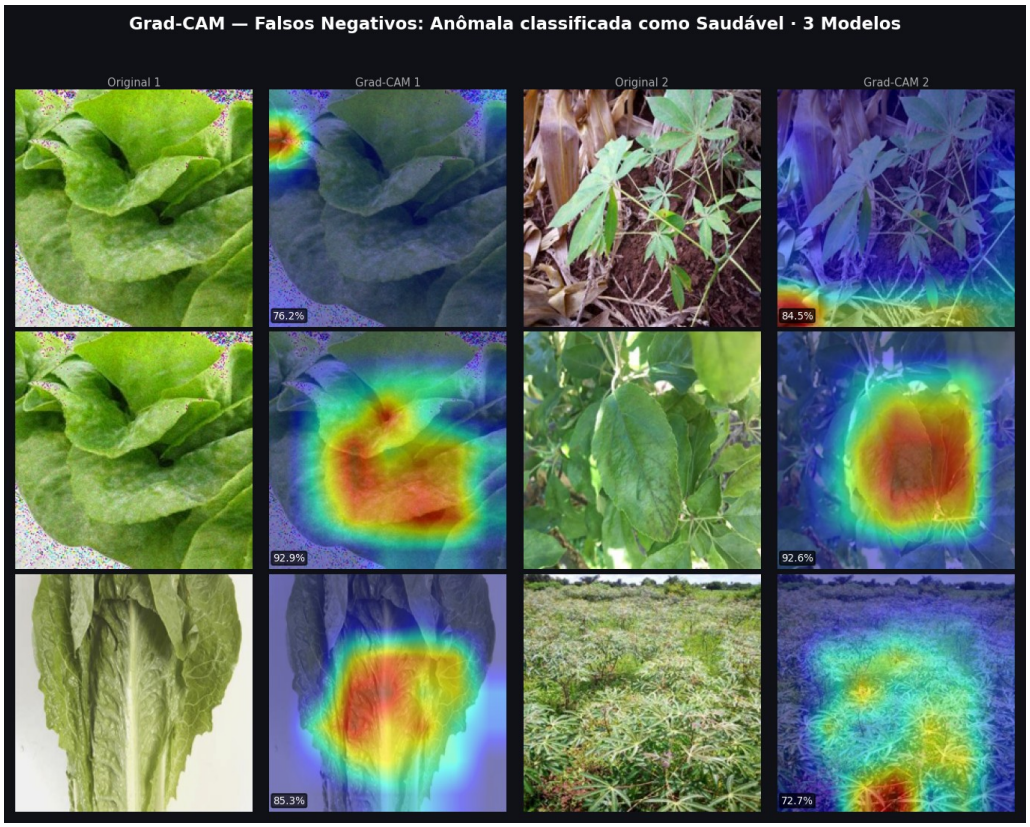


Figura 6 — Mapas Grad-CAM para falsos negativos: folhas anômalas classificadas como saudáveis. *Fonte: elaboração própria (2026).*

A análise dos falsos negativos é a mais informativa. Duas observações se destacam. Primeiro, a confiança nesses casos tende a ser menor que nas classificações corretas — 76,2 % e 84,5 % para o EfficientNet-B0, contra 93 % a 96 % nos acertos —, e é precisamente esse diferencial que o mecanismo de abstenção explora. A tendência, porém, não é universal: os dois falsos negativos do MobileNetV2 registram 92,9 % e 92,6 % de confiança, indistinguíveis de um acerto. Isso ilustra concretamente a limitação quantificada na seção 4.4 — a abstenção intercepta cerca de um terço dos erros, não todos. Segundo, as imagens que geram falsos negativos são, em sua maioria, fotografias de contexto amplo — plantas inteiras vistas de longe, com solo, folhas secas e vegetação de fundo no enquadramento — ou imagens com artefatos de compressão acentuados. São, em outras palavras, exatamente as imagens mais próximas das condições reais de campo. A análise de explicabilidade cumpre, assim, dupla função: valida os acertos e fornece justificativa empírica direta para a prioridade atribuída à coleta de campo no TCC-II.

4.6 Validação em campo e análise de poder estatístico

Foram capturadas 20 fotografias de alface em horta real, com telefone celular, sob luz natural e sem preparação da cena. Após triagem, 13 foram consideradas utilizáveis como

gabarito — 5 saudáveis e 8 anômalas. As sete excluídas o foram por motivos registrados: uma provinha de banco de dados fitopatológico com identificador de catálogo sobreposto, uma continha texto sobre a imagem, e cinco apresentavam coloração ambígua, que tanto poderia ser sintoma quanto pigmentação natural da variedade.

Conjunto	Acurácia balanceada	Abstenções	Condições
Teste (domínio de treino)	98,49 %	1,4 %	Estúdio, fundo homogêneo, folha isolada
Campo (horta real)	73,3 %	2 de 13	Luz natural, solo visível, folhas sobrepostas

Tabela 6 — Desempenho do modelo em produção no domínio de teste e em fotografias de campo. *Fonte: elaboração própria (2026).*

A queda de aproximadamente 25 pontos percentuais confirma empiricamente o domain gap descrito na seção 2.7, situando-se dentro da faixa reportada pela literatura para modelos treinados predominantemente em imagens de estúdio (Ahmad; Gamal; Saraswat, 2023; Upadhyay et al., 2025). É o primeiro dado real do projeto sobre desempenho em uso, e não uma estimativa por analogia.

O mesmo conjunto de 13 fotografias foi avaliado ao final de cada um dos três ciclos de correção, permitindo comparação direta. Os resultados são apresentados na Tabela 7 e exigem interpretação cuidadosa.

Ciclo	Correção aplicada	Acur. de campo	Abstenções	Acur. domínio de teste
1	Vazamento de dados corrigido	87,5 %	1 de 13	98,59 %
2	Abstenção corrigida; dataset expandido	77,5 %	0 de 13	98,42 %
3	Rotulagem corrigida	73,3 %	2 de 13	98,49 %

Tabela 7 — Evolução do desempenho ao longo dos três ciclos de correção, sobre o mesmo conjunto de 13 fotografias de campo. Acurácia de domínio: acurácia balanceada do EfficientNet-B0. *Fonte: elaboração própria (2026).*

O resultado é contraintuitivo: corrigir defeitos reais e bem documentados — em particular a rotulagem incorreta de quase quatro mil imagens de alface saudável — não melhorou, e no ponto estimado piorou, o desempenho em campo. Diante disso, a reação metodologicamente correta é desconfiar do instrumento de medição antes de desconfiar do modelo.

Calculou-se o intervalo de confiança de Wilson a 95 % (Wilson, 1927) para a proporção de diagnósticos corretos em cada ciclo, método adequado a proporções estimadas sobre amostras pequenas, para as quais a aproximação normal é inválida. O intervalo incide sobre a proporção bruta de acertos entre os diagnósticos efetivamente emitidos — excluindo

as abstenções, de modo uniforme nos três ciclos — e não sobre a acurácia balanceada, que, por ser média de duas proporções, exigiria tratamento distinto.

Ciclo	Diagnósticos emitidos	Acertos	Proporção	IC 95 % (Wilson)	Amplitude
1	12 de 13	11	91,7 %	[64,6 % ; 98,5 %]	33,9 pp
2	13 de 13	10	76,9 %	[49,7 % ; 91,8 %]	42,1 pp
3	11 de 13	8	72,7 %	[43,4 % ; 90,3 %]	46,8 pp

Tabela 8 — Intervalos de confiança de Wilson para a proporção de diagnósticos corretos em campo, nos três ciclos. A diferença entre os diagnósticos emitidos e as 13 fotografias corresponde às abstenções. *Fonte: elaboração própria (2026).*

Conclusão central da validação de campo

Os três intervalos se sobrepõem na faixa de 64,6 % a 90,3 %. Com N = 13, os ciclos são **estatisticamente indistinguíveis** entre si: a diferença observada pode ser inteiramente ruído amostral, e não deterioração real do modelo. Nenhum intervalo tem amplitude inferior a 33 pontos percentuais — a amostra simplesmente não resolve diferenças dessa ordem. O conjunto de campo atual já cumpriu um papel importante, ao expor o defeito de rotulagem invisível a toda métrica de laboratório, mas **não possui poder estatístico para decidir entre versões do modelo**. Ampliar a amostra deixou de ser um aprimoramento desejável e passou a ser pré-requisito para qualquer decisão de modelo subsequente.

Com base nessa análise, decidiu-se manter o ciclo 3 em produção — a versão sem defeitos conhecidos e com a melhor média no domínio de teste — em vez de reverter para o ciclo 1. A decisão contrasta deliberadamente com a tomada ao final do ciclo 2, quando houve reversão: naquele caso existia uma causa concreta e comprovada (rótulos demonstravelmente errados); neste, existe apenas um número de campo que a estatística não distingue do ruído. Reverter com base nele seria otimizar sobre ruído.

4.6.1 Hipótese sobre a natureza dos erros de campo

A inspeção qualitativa dos erros de campo do ciclo 3 sugere um padrão que se registra como hipótese, não como achado: as duas fotografias anômalas classificadas como saudáveis apresentam dano predominantemente estrutural — murcha e perfurações por praga — em folhas que permanecem majoritariamente verdes. As fotografias anômalas corretamente classificadas apresentam sinal cromático evidente: manchas escuras, revestimento esbranquiçado ou bordas necrosadas.

A hipótese é que o modelo pondere mais pistas de cor do que pistas estruturais ao decidir por anômalo — o que seria coerente com a composição do dataset, dominado por

doenças fúngicas e bacterianas de manifestação cromática, e com escassa representação de dano mecânico por praga. Se confirmada com uma amostra de campo maior, a hipótese teria consequência prática direta: o próximo ciclo de expansão de dados deveria privilegiar exemplos de dano estrutural em vez de mais exemplos de doença cromática.

4.7 Sistema em operação

O sistema completo encontra-se implementado e funcional. O backend, em FastAPI, expõe um endpoint de predição que recebe uma imagem por multipart/form-data, aplica a guarda de vegetação, executa a inferência com os pesos e a calibração do modelo em produção, aplica o limiar de abstenção e devolve um dos quatro veredictos possíveis: saudável, anômalo, inconclusivo ou não é folha, acompanhado das probabilidades calibradas de cada classe. O modelo é mantido em memória entre requisições e utiliza GPU quando disponível.

O frontend, em React 19 com TypeScript, permite o envio de uma fotografia e apresenta o resultado com indicação visual do grau de confiança. Um banco SQLite registra o histórico de diagnósticos. A latência de inferência de 8,0 ms torna a resposta indistinguível de instantânea para o usuário final, sendo o tempo de upload da imagem o fator dominante na experiência de uso.

4.8 Critérios de validação do MVP

Critério	Meta	Resultado	Situação
F1-score macro no conjunto de teste	≥ 0,85	0,9844	Atendido (+13,4 pp)
Vazamento residual no conjunto de teste	< 1 %	0,04 %	Atendido
Erro de calibração esperado (ECE)	< 0,05	0,0047	Atendido
Superação de classificador trivial (F1)	≥ +0,10	+0,61	Atendido
Superação de CNN treinada do zero	≥ +0,10	não executado	Pendente — TCC-II
Grad-CAM sobre regiões relevantes	confirmação qualitativa	confirmado (EfficientNet-B0)	Atendido
Sistema end-to-end operacional	API + interface	operacional	Atendido
Validação em campo com poder estatístico	N ≥ 100	N = 13	Pendente — TCC-II

Tabela 9 — Critérios de validação do MVP e situação atual. *Fonte: elaboração própria (2026).*

Dois critérios não foram atendidos e são declarados como tal. O primeiro é a comparação com uma CNN treinada do zero: a rede ingênua chegou a ser especificada, mas não foi implementada nem treinada, e a versão anterior deste trabalho declarava esse critério atendido sem respaldo experimental — erro aqui corrigido. A comparação disponível é apenas com o classificador trivial de classe majoritária, cujo F1 macro é 0,3697. O segundo é a validação em campo com poder estatístico adequado, objeto central do TCC-II.

5 DISCUSSÃO

5.1 Três defeitos e o que cada um ensina

A execução deste trabalho produziu três correções sucessivas, cada uma originando um ciclo completo de reconstrução do dataset e retreinamento dos três modelos. Descrevê-las é, provavelmente, a contribuição mais transferível do trabalho, porque nenhuma delas é específica deste projeto.

5.1.1 Vazamento de dados

O particionamento original foi feito por sorteio aleatório de arquivos, procedimento padrão e raramente questionado. A auditoria por hash perceptual revelou que 57,35 % do conjunto de teste possuía fotografia quase-idêntica no conjunto de treino. A causa é a natureza dos datasets públicos agregados: eles redistribuem material entre si — o mesmo PlantVillage aparece, integral ou parcialmente, em múltiplas fontes aparentemente independentes — e internamente incluem versões já transformadas da mesma fotografia.

O sintoma que motivou a investigação não foi um número ruim, mas um número bom demais acompanhado de comportamento ruim: 99 % no papel, diagnósticos erráticos em fotografias novas. A pergunta produtiva não foi "por que o modelo é ruim?", mas "por que o número é tão bom?". A lição é procedimental: uma métrica excepcional deve ser tratada como hipótese a investigar, não como resultado a comemorar.

5.1.2 Abstenção inoperante

Implementado o mecanismo de classificação seletiva, o sistema continuava emitindo diagnósticos confiantes para qualquer imagem. A causa era um defeito de raciocínio no algoritmo de escolha do limiar: buscava-se o menor τ, a partir de 0,50, cuja acurácia seletiva atingisse a meta. Ocorre que 0,50 é o piso matemático da confiança de um softmax binário — a confiança da classe vencedora nunca é menor que isso —, de modo que, com acurácia global já elevada no conjunto de validação, o algoritmo parava na primeira iteração e devolvia $\tau = 0{,}50$ com cobertura de 100 %. O mecanismo estava implementado, testado quanto à execução, e completamente inoperante quanto ao efeito.

A lição é que testar se o código executa não é testar se o mecanismo funciona. O defeito só apareceu ao inspecionar o valor de cobertura no arquivo de calibração — um artefato que só existe porque se decidiu registrá-lo.

5.1.3 Rotulagem automática defeituosa

A rotulagem dos datasets é automática, por busca em largura sobre a árvore de diretórios, associando nomes de pasta a rótulos por palavras-chave. A rotina interrompia a descida assim que o nome de um diretório correspondia a uma palavra-chave, sem verificar se havia subdiretórios com rótulo próprio. O dataset que constituía a única fonte específica de alface do projeto está organizado como um diretório chamado Lettuce_disease_datasets contendo subpastas Healthy, Bacterial, Downy_mildew e outras. A palavra disease no nome do contêiner correspondeu à lista de anomalias, e a pasta inteira — inclusive Healthy — foi rotulada como doente.

O resultado foi que **3.972 imagens de alface saudável estiveram rotuladas como doentes desde o primeiro dia do projeto**. A única fonte de que o modelo dispunha para aprender o que é uma alface saudável estava etiquetada ao contrário. A correção da rotina recuperou essas imagens e, como efeito colateral não previsto, removeu da classe anômala 3.831 imagens de erva daninha que o mesmo defeito fazia escapar ao filtro de descarte.

A lição mais importante: esse defeito estava presente desde o primeiro commit e sobreviveu a toda a fase de resultados excelentes. Nenhuma métrica de laboratório o denunciava, porque o erro era perfeitamente consistente entre treino, validação e teste — um rótulo sistematicamente errado é, para o classificador, apenas outra convenção de rotulagem. Só o teste de campo o expôs.

5.2 Por que o teste de laboratório não bastou

Os três defeitos têm em comum a invisibilidade às métricas usuais. O vazamento as inflava; a abstenção inoperante não as alterava; a rotulagem errada era consistente entre partições. Acurácia, F1, AUC e matriz de confusão permaneceram em faixa estreita — entre 97,2 % e 98,6 % — ao longo dos três ciclos, apesar de cada ciclo corrigir um defeito real.

Isso ilumina um limite estrutural do protocolo de avaliação dominante na literatura de diagnóstico foliar. Um conjunto de teste extraído da mesma distribuição do conjunto de treino mede consistência interna, não capacidade de diagnóstico. Se a distribuição inteira estiver contaminada — por duplicatas, por rótulos errados, ou simplesmente por ser homogênea demais em relação ao uso real —, a métrica permanece alta e silenciosa. Geirhos et al. (2020) formulam o ponto em termos gerais: uma rede aprende qualquer regularidade que reduza a perda, e um conjunto de teste que compartilhe essa regularidade não a detecta.

A implicação prática é que a validação fora de distribuição não é uma etapa final de confirmação, mas um instrumento de diagnóstico do próprio pipeline. Treze fotografias de horta — amostra insuficiente para comparar modelos, como a análise de Wilson demonstrou — foram, ainda assim, suficientes para revelar um defeito de rotulagem que 170 mil imagens de laboratório não revelaram.

5.3 Comparação com a literatura

Confrontado com o Quadro 2, o resultado deste trabalho é nominalmente inferior ao de vários trabalhos publicados. Duas ressalvas são pertinentes.

A primeira é que os trabalhos comparados raramente descrevem o procedimento de particionamento ou reportam auditoria de duplicatas. Dado que o PlantVillage e seus derivados são a base de quase toda essa literatura, e que este trabalho mediu 49,5 % de redundância interna em um agregado dessas mesmas fontes, é razoável supor que parte dos resultados publicados esteja sujeita ao mesmo tipo de inflação aqui documentado. Não se afirma que estejam — afirma-se que não é possível saber a partir do que é reportado, e que essa impossibilidade é ela própria um problema da área.

A segunda é que a única comparação diretamente informativa seria em condições de campo, e a maioria dos trabalhos não a realiza. Mohanty, Hughes e Salathé (2016) — que a realizam — reportam queda acentuada, coerente com a aqui observada. A conclusão razoável é que o desempenho de laboratório desta classe de sistemas está saturado e deixou de ser informativo: a fronteira relevante é a generalização para o campo, e é nela que este trabalho pretende contribuir no TCC-II.

6 LIMITAÇÕES E TRABALHO FUTURO

6.1 Limitações reconhecidas

- **Amostra de campo insuficiente:** o conjunto de campo tem 13 fotografias, todas de alface, todas de uma mesma horta e capturadas em ocasião única. Não sustenta comparação entre modelos nem generalização para outras culturas ou regiões. É a limitação mais séria do trabalho e o objeto prioritário do TCC-II.
- **Cobertura desigual das culturas-alvo:** das cinco culturas declaradas no escopo, apenas a alface está representada no dataset por fontes específicas. Não existe dataset público de doenças foliares para rúcula, espinafre, acelga ou couve. O conhecimento do modelo sobre essas culturas é inteiramente transferido de espécies proxy, e as conclusões devem ser lidas como válidas primariamente para alface.
- **Ausência de baseline treinado do zero:** a comparação com uma CNN treinada do zero não foi executada. A referência disponível é o classificador trivial de classe majoritária, que é um piso fraco.
- **Ausência do Vision Transformer:** o ViT-B/16 não foi treinado por limitação de memória de vídeo (6 GB), de modo que a comparação de arquiteturas cobre apenas CNNs.
- **Granularidade do diagnóstico:** a tarefa é binária. O sistema indica que há um problema, não qual problema — informação de utilidade limitada para decisão de manejo.
- **Hipótese cor versus estrutura não testada:** a hipótese de que o modelo pondera mais cor que estrutura (seção 4.6.1) é uma observação sobre duas fotografias. Não constitui evidência.
- **Explicabilidade não quantificada:** o Grad-CAM é qualitativo e sensível à escolha da camada-alvo, como a seção 4.5 documenta. Não substitui uma métrica objetiva de fidelidade da explicação.

6.2 Proposta de execução do TCC-II

As frentes abaixo estão ordenadas por dependência real, e não por facilidade. A primeira é bloqueante: sem ela, as demais não podem ser avaliadas.

Frente 1 — Ampliação e formalização do conjunto de validação de campo

Coleta de 100 a 300 fotografias em hortas produtivas da região de Joinville, seguindo o protocolo da seção 3.4. O desenho da amostra deve cobrir deliberadamente os eixos que hoje são pontos cegos: dano estrutural além de dano cromático; distâncias e enquadramentos variados; diferentes horários e condições de luz; e, se viável, mais de uma cultura. O gabarito

deve ser estabelecido com apoio de literatura fitopatológica e, idealmente, verificação independente. Todo resultado sobre esse conjunto será reportado com intervalo de confiança.

Frente 2 — Quantificação e mitigação do domain gap

Com uma amostra de poder adequado, torna-se possível medir o domain gap com precisão útil e avaliar estratégias de mitigação: ajuste fino com uma parcela dos dados de campo — mantendo estrita separação entre a parcela de treino e a de teste —, augmentation orientado às condições reais observadas, e técnicas de adaptação de domínio. A comparação entre estratégias será feita por teste estatístico, não por comparação de pontos estimados.

Frente 3 — Inclusão do Vision Transformer

Treinamento e avaliação do ViT-B/16 em ambiente com GPU de maior capacidade (Google Colab Pro ou servidor institucional), completando a comparação de arquiteturas com um representante da família de modelos de atenção.

Frente 4 — Extensão para classificação multiclasse

Expansão da tarefa binária para múltiplas classes de anomalia — míldio, oídio, clorose nutricional, dano por praga —, condicionada à disponibilidade de dados rotulados por tipo em volume suficiente. Caso a disponibilidade se confirme insuficiente para as culturas-alvo, a alternativa é uma taxonomia reduzida de três a quatro categorias de manifestação visual, que preserva utilidade prática para o produtor.

Frente 5 — Teste da hipótese cor versus estrutura

Com a amostra ampliada, verificar se o desempenho difere sistematicamente entre anomalias de manifestação cromática e de manifestação estrutural. Se confirmado, direcionar a expansão de dados para a categoria sub-representada, e não para o aumento indiscriminado de volume — que, como o ciclo 2 demonstrou, não produz ganho por si só.

Frente 6 — Consolidação e disseminação

Redação da monografia final e de artigo científico. Sugere-se que o artigo tenha como objeto principal a contribuição metodológica — o protocolo de auditoria de vazamento e a demonstração de que a validação fora de distribuição atua como instrumento de diagnóstico do pipeline —, por ser o aspecto de maior originalidade e transferibilidade.

6.3 Cronograma

Atividade	Ago	Set	Out	Nov
Coleta e rotulagem de campo (Frente 1)	■	■		
Quantificação e mitigação do domain gap (Frente 2)		■	■	
Treinamento do ViT-B/16 (Frente 3)		■		
Classificação multiclasse (Frente 4)			■	■
Teste da hipótese cor/estrutura (Frente 5)			■	
Redação da monografia	■	■	■	■
Redação do artigo científico			■	■
Revisão final e preparação da defesa				■

Quadro 4 — Cronograma proposto para o TCC-II (2026/2). *Fonte: elaboração própria (2026).*

O cronograma concentra a coleta de campo no início do semestre deliberadamente: é a atividade de maior risco de execução, por depender de acesso a hortas produtivas e de condições climáticas, e todas as demais frentes dependem dela.

7 CONSIDERAÇÕES FINAIS

Este trabalho partiu de um objetivo convencional — treinar e comparar arquiteturas de redes convolucionais para diagnóstico foliar — e obteve, na primeira execução, um resultado convencionalmente excelente: 99,01 % de acurácia. Esse resultado era inválido, e a demonstração de sua invalidade tornou-se o eixo do trabalho.

O que resta, depois da correção, é um sistema com desempenho honestamente medido — 98,49 % de acurácia balanceada em um conjunto de teste com 0,04 % de vazamento residual, probabilidades calibradas com erro de calibração de 0,0047, mecanismo de abstenção operante e guarda de domínio — e uma medida realista de sua utilidade em campo, entre 43 % e 90 % com a amostra disponível. O segundo número é desconfortável e é reportado com a mesma ênfase que o primeiro, porque é ele que descreve o sistema em uso.

As três correções realizadas — vazamento de dados, abstenção inoperante e rotulagem automática defeituosa — compartilham uma propriedade que se julga ser a contribuição mais útil deste trabalho: nenhuma delas era detectável pelas métricas usuais de avaliação. Todas foram encontradas por auditoria deliberada do pipeline e por confronto com dados fora da distribuição de treino. Em uma área na qual acurácias acima de 98 % são rotina e nas quais os procedimentos de particionamento raramente são descritos, esse achado tem alcance que ultrapassa o caso particular das hortaliças folhosas.

O trabalho está, portanto, em condição de avançar. A infraestrutura funciona, os dados estão auditados, o protocolo de medição está estabelecido, e a próxima pergunta está formulada com precisão: quanto vale este sistema em uma horta real — e o que é preciso fazer para que valha mais.

A atualização de outubro de 2026, apresentada no capítulo 8, torna essa pergunta mais precisa: o desempenho medido até aqui vale para as fontes de treino, e a etapa seguinte precisa de fotografias com fundo real, tanto para medir quanto para aproximar o treino das condições de uso.

8 ATUALIZAÇÃO DO TCC-II: QUARTO CICLO E REVISÃO CRÍTICA

Este capítulo registra o trabalho executado entre agosto e outubro de 2026. Tem duas partes: o quarto ciclo de treinamento, que incorporou duas culturas ao dataset, e uma revisão crítica, feita durante a preparação do segundo seminário do TCC-II, sobre o que os números obtidos permitem afirmar. Todos os valores são rastreáveis aos artefatos acrescentados ao Apêndice A.

8.1 Quarto ciclo de treinamento

Em setembro de 2026 foram incorporados ao dataset dois lotes preparados com o mesmo protocolo de deduplicação: 3.209 imagens de espinafre-de-malabar, de duas fontes do Mendeley Data, e 1.142 imagens de alface com míldio, da plataforma Roboflow. Declara-se uma ressalva de espécie: o espinafre desses lotes é *Basella alba*, e não *Spinacia oleracea*, a espécie do escopo original. Os lotes foram acrescentados às partições existentes sem refazer o particionamento, de modo que o teste do terceiro ciclo ficou contido no do quarto e a comparação entre ciclos é feita sobre as mesmas imagens. O dataset resultante tem 175.123 imagens, com vazamento residual de 0,04 % no teste.

A preparação revelou um quarto defeito de particionamento. Os 1.142 arquivos de míldio são recortes de anotação e variantes de apenas 49 fotografias originais, e 45 delas tinham recortes em mais de uma partição. A deduplicação por hash perceptual não detecta esse caso, porque recortes de regiões diferentes da mesma fotografia não são visualmente duplicados. O critério correto, aqui, é a proveniência, e não a semelhança: o lote foi reparticionado pela fotografia de origem, com 32, 12 e 5 fotografias em treino, validação e teste. Para efeito de tamanho de amostra, esse lote contribui com 49 fotografias independentes, não com 1.142.

O ciclo foi treinado antes da coleta de campo, o que revoga a diretriz anterior de não retreinar sem ampliar a amostra de campo. A razão é que as fotografias de campo se destinam à avaliação e, portanto, o treino não dependia delas; e treinar antes deixa o modelo congelado quando as fotografias novas chegarem, o que torna a avaliação cega. No teste original de 23.967 imagens o resultado foi de empate: 98,48 % de acurácia balanceada para o EfficientNet-B0, contra 98,49 % no terceiro ciclo. Aprender as culturas novas não custou desempenho nas antigas.

8.2 O que o conjunto de teste mede

O particionamento agrupado por hash perceptual garante que a mesma fotografia não aparece em duas partições. Não torna o teste diferente do treino. Treino, validação e teste são fatias das mesmas seis fontes públicas, em proporções quase idênticas: as duas fontes derivadas do PlantVillage — folha isolada, fundo homogêneo, iluminação controlada — respondem por 70,1 % do treino, 72,2 % da validação e 72,0 % do teste. As fotografias de teste compartilham com as de treino o fundo, a luz e o enquadramento. Os 98,49 % medem o acerto dentro dessas fontes, e por isso passam a ser chamados, neste trabalho, de acurácia intra-fonte.

O quarto ciclo forneceu, sem que isso tivesse sido planejado, uma medida fora das fontes de treino. O modelo do terceiro ciclo nunca havia visto os lotes de espinafre, e foi avaliado nas 484 imagens de teste desse material. A Tabela 10 reúne as três medidas hoje disponíveis.

Situação	Acurácia balanceada	N	O que mede
Intra-fonte: teste das fontes de treino	98,49 %	23.967	Acerto em fotografias parecidas com as de treino
Fonte retida: espinafre, modelo do terceiro ciclo	75,4 %	484	Acerto fora das fontes, ainda em fotografia de estúdio
Campo: 13 fotografias, modelo do quarto ciclo	83,8 %	13	Indício do uso real, sem poder estatístico

Tabela 10 — Três medidas de desempenho do EfficientNet-B0, conforme a relação entre as imagens avaliadas e as de treino. *Fonte: elaboração própria (2026).*

A queda de 23 pontos percentuais na fonte retida é o resultado mais informativo desta revisão, por duas razões. A amostra é suficiente, com 484 fotografias independentes; e não se trata de fotografia de campo, pois o material de espinafre é de folha isolada sobre fundo claro. Bastou mudar de fonte, mantendo o estilo de estúdio, para o desempenho cair para a casa dos 75 %. Os outros dois modelos se comportam da mesma forma: 77,6 % para o ResNet-50 e 74,3 % para o MobileNetV2. Registra-se a ressalva de que mudam ao mesmo tempo a fonte e a espécie, e os dois efeitos não são separáveis com esse dado.

8.3 Ganho do quarto ciclo e correção de uma pseudo-replicação

A primeira análise do quarto ciclo comparou os dois ciclos sobre 657 imagens das culturas novas e obteve valores de p da ordem de 10^{-13}. Essa análise continha um erro: 173 das 657 imagens são recortes de apenas cinco fotografias de míldio. Recortes da mesma fotografia não são observações independentes, e o teste de McNemar, aplicado imagem a imagem, trata-os como se fossem — o que infla a significância. A comparação foi refeita apenas com o espinafre, cujas fotografias são independentes (Tabela 11).

Modelo	Terceiro ciclo	Quarto ciclo	p (Holm)
EfficientNet-B0	75,4 %	88,4 %	$5{,}9\times10^{-12}$
ResNet-50	77,6 %	86,2 %	$1{,}9\times10^{-7}$
MobileNetV2	74,3 %	87,4 %	$1{,}9\times10^{-7}$

Tabela 11 — Acurácia balanceada no teste de espinafre (484 imagens) antes e depois da incorporação do lote ao treino. Teste de McNemar exato, pareado, com correção de Holm. *Fonte: elaboração própria (2026).*

O ganho, de 9 a 13 pontos percentuais, permanece significativo nos três modelos, com valores de p mais modestos que os inicialmente reportados. É o primeiro ganho do projeto que resiste a um teste de significância. Sua leitura, porém, deve ser a da seção anterior: quando a fonte entra no treino, o teste dessa fonte sobe. Trata-se de um ganho intra-fonte, que confirma que o modelo aprende a aparência das fontes de treino e nada informa sobre o desempenho em horta. O lote de míldio, cujo teste tem cinco fotografias, fica registrado apenas como indicação.

8.4 Confiança em campo

As mesmas 13 fotografias de campo foram avaliadas com o modelo do quarto ciclo: 83,8 % de acurácia balanceada e 11 acertos em 13 diagnósticos (84,6 %; intervalo de Wilson de 57,8 % a 95,7 %). O teste de McNemar exato entre ciclos resulta em p = 1,00 em todos os pares: com 13 fotografias, a diferença em relação aos ciclos anteriores continua indistinguível do ruído, como a seção 4.6 já havia demonstrado. A Tabela 12 mostra um aspecto que a análise anterior não havia examinado.

Ciclo	Confiança média	Abstenções	Erros emitidos	Confiança dos erros
1	0,963	1 de 13	1	0,981
2	0,986	0 de 13	3	0,999; 0,949; 0,983
3	0,937	2 de 13	3	0,997; 0,992;

				0,993
4	0,992	0 de 13	2	0,997; 0,991

Tabela 12 — Confiança calibrada nas 13 fotografias de campo, por ciclo. Erros emitidos são diagnósticos incorretos que chegaram ao usuário, isto é, não interceptados pela abstenção. *Fonte: elaboração própria (2026).*

Os nove erros emitidos em campo ao longo dos quatro ciclos tiveram confiança calibrada entre 0,949 e 0,999. No quarto ciclo, todas as fotografias receberam confiança igual ou superior a 0,967 e o sistema não se absteve nenhuma vez. O erro de calibração esperado, de 0,003 na validação, é de 0,146 em campo. A causa é estrutural: a temperatura e o limiar τ são ajustados na validação, que compartilha a distribuição do treino, e a calibração vale para essa distribuição. Fora dela, o mecanismo de abstenção não conteve nenhum dos erros observados. Com 13 fotografias isso é um indício, e não uma medida; mas contraria a expectativa, registrada na seção 4.4, de que a confiança separaria acertos de erros também em uso, e precisa ser verificado na amostra ampliada.

Registra-se ainda uma pendência sobre o próprio conjunto histórico: a procedência de cada uma das 13 fotografias não foi anotada quando o conjunto foi reunido e será documentada antes da entrega final. O conjunto novo é coletado com planilha de metadados preenchida no momento da captura, incluindo a horta de origem.

8.5 Hipótese do fundo e ajustes propostos

A explicação proposta para a queda em horta é o fundo da imagem. Cerca de 70 % do treino é folha isolada sobre fundo homogêneo; a fotografia de horta contém solo, sombra e folhas sobrepostas. A literatura sustenta a suspeita: Noyan (2022) obteve 49 % de acurácia no PlantVillage usando apenas oito pixels do fundo, sem que a folha fosse vista pelo classificador. A análise de falsos negativos da seção 4.5 aponta no mesmo sentido. Este trabalho, contudo, ainda não mediu a dependência do fundo de forma direta: o resultado da seção 8.2 mostra dependência da fonte e não isola o fundo, pois o espinafre também tem fundo claro. A afirmação permanece como hipótese, e os ajustes abaixo incluem o experimento que a decide.

- **Três medidas, três nomes:** reportar separadamente a acurácia intra-fonte, a de fonte retida e a de campo, em todo o texto.
- **Coleta com fundo real, em dois conjuntos:** separar as fotografias de campo por horta, e não por fotografia, em um conjunto de avaliação, que nunca é usado em treino, e um conjunto de adaptação. A separação por horta evita repetir, entre campo e campo, o vazamento por proveniência da seção 8.1.

- **Medir antes de adaptar:** o modelo do quarto ciclo, congelado, é avaliado às cegas em todas as fotografias novas. Só depois o conjunto de adaptação entra em um novo ciclo, e a medição é repetida no conjunto de avaliação.
- **Fundo real no treino:** conjunto de adaptação, bases públicas fotografadas em campo, como o PlantDoc (Singh et al., 2020), e augmentation de fundo.
- **Teste direto da hipótese do fundo:** avaliar as mesmas imagens com o fundo removido e com a folha removida. Se o modelo continuar acertando sem a folha, a decisão vem do fundo.
- **Calibração no domínio de uso:** reportar erro de calibração, cobertura e erros interceptados em campo, e não apenas na validação.

O uso de fotografias de campo em treino altera a diretriz de isolamento estrito da seção 3.4. A proposta é mantê-la integralmente para o conjunto de avaliação e constituir o conjunto de adaptação à parte. A alteração depende de validação da orientação; até lá, nenhuma fotografia de campo é usada em treino.

8.6 Registro consolidado de erros e ajustes

O Quadro 6 reúne, em ordem de descoberta, os erros de método identificados ao longo do trabalho, inclusive os desta revisão. Quase todos têm em comum não terem sido denunciados pelas métricas usuais de avaliação: foram encontrados por auditoria do pipeline, por testes das próprias correções ou pelo confronto com dados de fora das fontes de treino.

Erro ou achado	Como foi descoberto	Ajuste	Quando
Particionamento por arquivo: 57,35 % do teste repetia fotografias do treino	99,01 % no papel, erros em fotografias novas	Particionamento por grupos de hash perceptual	Ciclo 1
Hash canônico por mínimo lexicográfico era instável	Falha em teste sintético da correção	Comparação da órbita D4 completa	Ciclo 1
Desbalanceamento não tratado; modelo escolhido por acurácia global	Leitura do código	Amostragem ponderada, pesos na perda, seleção por F1 macro	Ciclo 1
Pré-processamento diferente entre treino e inferência; augmentation de cor apagava o sintoma	Comparação das transformações	Transformações consistentes; cor menos perturbada	Ciclo 1
Imagens	Leitura do código	Descartadas no	Ciclo 1

corrompidas viravam quadrados pretos rotulados		particionamento	
Abstenção nunca era acionada ($\tau = 0{,}50$)	Cobertura de 100 % no arquivo de calibração	Piso de 0,85 para o limiar	Ciclo 2
3.972 imagens de alface saudável rotuladas como doentes	Piora no teste de campo	Rotulagem desce aos subdiretórios	Ciclo 3
Comparação de campo com critérios diferentes de abstenção entre ciclos	Revisão da análise	Abstenções excluídas de forma uniforme	Jul. 2026
Grad-CAM calculado na camada errada do EfficientNet-B0	Mapas concentrados em uma única célula	Último bloco MBConv como camada-alvo	Jul. 2026
Critério do MVP declarado atendido sem ter sido executado	Revisão do TCC-I	Declarado pendente	Jul. 2026
Particionamento por recorte: 1.142 imagens de 49 fotografias	Conferência dos nomes de arquivo	Particionamento pela fotografia de origem	Ciclo 4
Teste intra-fonte lido como prova de generalização	Revisão para o segundo seminário	Reportar fonte retida e campo como medidas distintas	Out. 2026
Pseudo-replicação no teste estatístico do quarto ciclo	Reanálise por lote	Comparação apenas com fotografias independentes	Out. 2026
Calibração e limiar validados apenas intra-fonte	Erros de campo com confiança acima de 0,94	Verificar calibração e abstenção em campo	Out. 2026
Procedência das 13 fotografias de campo não registrada	Inspeção dos arquivos	Metadados obrigatórios na coleta nova	Out. 2026

Quadro 6 — Registro consolidado de erros de método, forma de descoberta e ajuste adotado. *Fonte: elaboração própria (2026).*

A lição desta última revisão soma-se às do capítulo 5: um teste sem vazamento ainda é um teste da mesma distribuição. Remover as duplicatas torna a métrica verdadeira, mas não a

transforma em medida de generalização. Para isso é preciso reter uma fonte inteira ou ir a campo — e é com fotografias de fundo real que o trabalho prossegue.

9 ATUALIZAÇÃO DE OUTUBRO DE 2026: QUATRO ARQUITETURAS, AUDITORIA E QUINTO CICLO

Este capítulo registra três etapas executadas entre 12 e 14 de outubro de 2026. A primeira completa a resposta à pergunta Q1 com uma quarta arquitetura. A segunda é uma auditoria que conferiu cada número do trabalho contra os artefatos de origem e encontrou, dentro do próprio conjunto de teste, onde estão os erros do modelo. A terceira é o quinto ciclo de treinamento, que corrige os defeitos encontrados e mostra o que muda quando um atalho dos dados é removido.

9.1 Quatro arquiteturas

O ViT-B/16 foi treinado em GPU L4, no Google Colab, com os mesmos dados, a mesma perda, o mesmo critério de seleção e a mesma calibração das CNNs; mudaram apenas os hiperparâmetros de otimização, ajustados ao que é usual no ajuste fino de *transformers* (taxa de aprendizado de 5×10^{-5}, decaimento de pesos de 0,05, duas épocas de aquecimento e limitação da norma do gradiente). A Tabela 13 reúne as quatro arquiteturas no conjunto de teste da base, com o modelo do quarto ciclo.

Modelo	Parâm.	Acur. bal.	F1 macro	AUC	ECE	FN	Latência
EfficientNet-B0	4,0 M	98,48%	98,44%	0,9982	0,0039	209	7,2 ms
MobileNetV2	2,2 M	97,89%	97,83%	0,9976	0,0055	294	5,3 ms
ResNet-50	23,5 M	97,82%	97,70%	0,9966	0,0061	352	8,6 ms
ViT-B/16	85,8 M	98,48%	98,53%	0,9976	0,0018	137	19,4 ms

Tabela 13 — Desempenho das quatro arquiteturas no conjunto de teste da base (23.967 imagens), quarto ciclo. Parâmetros dos modelos treinados, com saída de duas classes; FN = falsos negativos; latência em GPU RTX 3050, medida na mesma sessão. *Fonte: elaboração própria (2026).*

EfficientNet-B0 e ViT-B/16 empatam: mesma acurácia balanceada, mesmo intervalo de confiança de 95% (98,32% a 98,64%) e nenhuma diferença pelo teste de McNemar exato com correção de Holm ($p = 0,26$). Ambos superam MobileNetV2 e ResNet-50 ($p \leq 1,4\times10^{-12}$). O ViT-B/16 comete menos falsos negativos e mais falsos positivos, tem 21 vezes mais parâmetros e é 2,7 vezes mais lento. Na abstenção, intercepta só 15% dos seus erros, contra 31% do EfficientNet-B0, embora tenha o menor ECE da tabela: boa calibração média

não garante que os erros fiquem nas confianças baixas. Um transformer muito maior chega ao mesmo lugar, o que reforça a leitura de que o limite do sistema está nos dados (Dosovitskiy et al., 2021).

9.2 Auditoria de consistência

Antes da escrita final, cada número citado nos documentos do projeto foi conferido no artefato que o produz, com um *script* próprio (backend/auditoria_consistencia.py). A auditoria trouxe três achados de método, além das correções listadas na nota de atualização.

Onde estão os erros do teste. As previsões por imagem, agrupadas por fonte e por cultura, mostram que a média de 98,48% junta situações muito diferentes (Tabela 14). Dentro da mesma coletânea, as culturas fotografadas em lavoura — mandioca, arroz, cana-de-açúcar e café — têm acurácia balanceada de 86,3% e concentram 81% dos erros do EfficientNet-B0 (295 de 363), enquanto as demais culturas, fotografadas em estúdio, chegam a 99,7%. A mandioca sozinha fica em 80,9%. Nas culturas de lavoura, as quatro arquiteturas ficam entre 83,4% e 87,8%, e o ViT-B/16 é o pior.

Subconjunto do teste da base	N	Acurácia balanceada
Coletânea, culturas fotografadas em estúdio	10.061	99,7%
Coletânea, culturas fotografadas em lavoura	4.530	86,3% (84,5% a 88,0%)
Só mandioca	3.150	80,9%
Teste inteiro	23.967	98,48% (98,32% a 98,64%)

Tabela 14 — Acurácia balanceada do EfficientNet-B0 (quarto ciclo) por subconjunto do conjunto de teste da base, com intervalo de confiança de 95% por bootstrap. *Fonte: elaboração própria (2026).*

Vazamento por proveniência. A maior fonte de alface é feita de 17 transformações (rotações de ângulo livre, recortes e filtros de borda) de cada uma de 1.231 fotografias. Essas variantes não ficam parecidas com a original para o *hash* perceptual, de modo que o particionamento por semelhança as espalhou pelas três partições: 99,6% das variantes de alface do teste têm outra variante da mesma fotografia no treino, o equivalente a 23% do teste. É o mesmo defeito corrigido no quarto ciclo para os 49 originais de míldio, aplicado agora à fonte inteira. Sem essas variantes, o teste dá 97,8%, e a conclusão sobre as arquiteturas se mantém.

Cultura associada ao rótulo e pastas fora do dataset. A alface responde por 29,9% do treino, mas 86,6% dela é saudável e ela vem de apenas 1.231 fotografias originais, 108 doentes; várias culturas da coletânea têm um só rótulo. Uma rede que aprende "alface tende a

ser saudável" ou "foto de lavoura tende a ser doente" acerta muito no teste e erra fora dele — o padrão de *shortcut learning* descrito por Geirhos et al. (2020). A auditoria também encontrou pastas de dano por praga que a rotulagem automática não reconheceu e deixou fora do dataset.

Na calibração, a temperatura ajustada na validação é menor que 1 nos quatro modelos (0,546 a 0,620), isto é, deixa as probabilidades mais confiantes. Nas 13 fotografias de campo isso piora a calibração: o ECE é de 0,146 com a temperatura e de 0,094 sem ela. Dos nove erros de campo dos quatro ciclos, quatro vêm de uma mesma fotografia rotulada como saudável que mostra manchas na folha; o rótulo será reavaliado.

9.3 Quinto ciclo: o que foi corrigido

O quinto ciclo foi montado em um particionamento novo, sem alterar nada do quarto ciclo, que permanece como modelo servido. As correções foram:

- **Alface por fotografia original.** O identificador no nome do arquivo e o hash juntam as variantes de cada fotografia; as 1.231 fotografias formam 1.172 unidades, repartidas inteiras. Validação e teste recebem uma fotografia por original, sem as variantes filtradas: o teste de alface passa a ter 176 fotografias, 15 doentes.
- **Pastas de praga rotuladas.** Entram como anômalas 8.266 imagens de pastas que a rotulagem deixava de fora, quase todas de dano por praga; as da coletânea seguem a partição de qualquer quase-duplicata já existente.
- **Amostragem por cultura.** Cada cultura mantém a sua fatia do treino, mas dentro dela saudável e anômala são sorteadas meio a meio; a perda deixa de ter pesos de classe, para não compensar a classe duas vezes.
- **Lote retido.** Um lote de espinafre-de-malabar (574 imagens) fica fora do treino e da validação. Outro lote da mesma espécie continua no treino: a medida é de troca de lote, mais branda que a de fonte nunca vista do terceiro ciclo.
- **Mesma partição no resto.** A coletânea e o PlantVillage mantêm a partição do quarto ciclo, o que permite comparar os dois ciclos imagem a imagem nas mesmas fotografias.

O conjunto tem 152.057 imagens: 112.458 de treino, 20.612 de validação, 18.413 de teste e 574 retidas. A auditoria de quase-duplicatas encontrou 1,7% do teste a distância de órbita ≤ 4 de alguma imagem de treino, contra 23% de variantes no quarto ciclo; parte desses pares são colisões entre culturas diferentes, de modo que o valor é um teto. As quatro arquiteturas foram treinadas em GPU L4, no Google Colab, com as mesmas receitas do quarto ciclo, em cerca de 12 horas.

9.4 Quinto ciclo: resultados

Modelo	Teste	Lavoura	Espec.	Sens.	Alface	Retido
EfficientNet-B0	97,4	86,3 → 88,8	76,6 → 83,4	96,0 → 94,2	96,7	87,9
MobileNetV2	96,9	86,6 → 90,1	78,3 → 90,2	94,9 → 90,0	100	88,4
ResNet-50	96,9	87,8 → 89,6	81,4 → 89,0	94,2 → 90,2	100	90,1
ViT-B/16	96,9	83,4 → 84,5	69,8 → 72,1	97,0 → 96,9	100	85,8

Tabela 15 — Quinto ciclo: acurácia balanceada (%) no teste do ciclo (18.413 imagens, sem as variantes de alface; não comparável à Tabela 13). Lavoura, Espec. e Sens.: acurácia balanceada, especificidade e sensibilidade nas culturas fotografadas em lavoura (N = 4.530), quarto ciclo → quinto ciclo, mesmas imagens. Alface: uma fotografia por original (N = 176). Retido: lote de espinafre fora do treino (N = 574). *Fonte: elaboração própria (2026).*

A correção agiu onde estavam os erros. Nas culturas fotografadas em lavoura, as três CNNs ganham de 1,8 a 3,5 pontos de acurácia balanceada e de 6,8 a 11,9 pontos de especificidade: passam a emitir bem menos falsos alarmes em folhas sadias. O MobileNetV2, que declarava doente quase tudo o que vinha de lavoura (especificidade de 78,3%, sensibilidade de 94,9%), fica equilibrado em 90,2% e 90,0%. O ViT-B/16 quase não muda (McNemar, $p = 0{,}66$).

O ganho tem custo. A sensibilidade nas culturas de lavoura cai de 1,8 a 4,9 pontos nas CNNs e, contado imagem a imagem, o quarto ciclo acerta mais: o McNemar exato favorece o quarto ciclo no EfficientNet-B0 (126 contra 94 imagens, $p = 0{,}04$) e, com folga, no MobileNetV2 e no ResNet-50 ($p < 10^{-11}$), porque três em cada quatro imagens desse subconjunto são anômalas e cada acerto conta igual. A acurácia balanceada pesa as duas classes por igual e sobe. As duas leituras são verdadeiras e precisam ser citadas juntas: o quinto ciclo não é melhor em tudo, é outro ponto de operação. Qual dos dois serve melhor depende do custo de cada erro na horta — um falso alarme custa uma inspeção; uma doença perdida pode custar o canteiro.

No lote de espinafre retido, os quatro modelos ficam entre 85,8% e 90,1%, cerca de dez pontos abaixo das fontes de treino, mesmo com outro lote da espécie no treino; é a medida de mudança de fonte mais limpa que o trabalho tem, e a ordem de grandeza é a mesma da queda por fonte disjunta descrita para amêndoa por Workneh et al. (2026). Nas 176 fotografias de alface sem variantes, os modelos acertam de 96,7% a 100%, mas há apenas 15 doentes, e o limite inferior do intervalo chega a 90%: a pergunta sobre a cultura-alvo continua dependendo do campo.

Dois resultados merecem registro à parte. Primeiro, a validação não ordena os modelos pelo que importa: ela põe EfficientNet-B0 e ViT-B/16 à frente (F1 macro de 0,972, contra

0,960 e 0,961), e na lavoura e no lote retido a ordem se inverte. Segundo, nas 13 fotografias do conjunto histórico, o EfficientNet-B0 do quinto ciclo acerta 11 dos 12 diagnósticos que emite, com uma abstenção, e empata com o quarto ciclo (cada um acerta uma fotografia que o outro erra; p = 1): com essa amostra, as versões continuam indistinguíveis.

9.5 O que muda

O modelo servido continua o EfficientNet-B0 do quarto ciclo até a avaliação em campo. Os modelos do quarto e do quinto ciclos foram congelados antes da coleta e serão comparados, às cegas, sobre as mesmas fotografias; se a horta mostrar o padrão da lavoura — falsos alarmes em folhas sadias —, o EfficientNet-B0 do quinto ciclo é o candidato, com a perda de sensibilidade dita explicitamente. Um sexto ciclo, com fotografias de horta no treino, depende da separação por horta em conjuntos de avaliação e de adaptação proposta na seção 8.5.

As lições desta etapa somam-se às do capítulo 5 e da seção 8.6. Uma média esconde onde o modelo erra: os 98,48% juntavam 99,7% em estúdio e 86% em lavoura, e as previsões por imagem já estavam salvas. Uma lição aprendida em um lote precisa ser aplicada ao dataset inteiro: o particionamento por proveniência feito para o míldio faltava na fonte de alface. Documentos precisam ser conferidos contra os artefatos, e não uns contra os outros. E corrigir um atalho muda o ponto de operação, e não só a acurácia: por isso especificidade e sensibilidade são reportadas lado a lado.

9.6 O que a literatura lida na íntegra acrescenta

Sete dos trabalhos relacionados foram lidos na íntegra em 16 de outubro de 2026 (os de Workneh et al., 2026, e Tian et al., 2024, aguardam acesso ao texto completo). A leitura reforça a interpretação deste trabalho em quatro pontos e acrescenta ressalvas a três resultados citados.

- **A queda é de fonte, não só de fundo.** No estudo com videira, o treino já é de fotografias de campo, e mesmo assim a acurácia cai de 99,6% para 72% a 74% em folhas de outro vinhedo, outro país e outro celular (Ergün et al., 2026). Isso fortalece o lote retido como medida de generalização: a mudança de fonte, sozinha, já custa pontos.
- **O atalho pela cultura tem mecanismo descrito.** Treinadas no PlantVillage e testadas em fotografias de campo, as CNNs atribuem a folha à cultura errada antes de olhar o sintoma: só 21% a 34% das folhas de macieira ficam na cultura certa, contra 92% com um modelo auto-supervisionado congelado (Nguyen et al., 2026). É o mesmo atalho

encontrado pela auditoria, em que a cultura decide o rótulo, e a razão da amostragem por cultura do quinto ciclo.

- **O ViT puro converge com a literatura.** A revisão de Shafay et al. (2025) aponta arquiteturas híbridas como mais robustas em campo e o ViT puro como mais sensível ao ambiente, apesar da vantagem em laboratório. O ViT-B/16 deste trabalho empata no teste e é o pior nas fotografias de lavoura nos dois ciclos. A arquitetura híbrida (Swin) não foi testada aqui. O ajuste fino completo, usado em todos os modelos deste trabalho, pode piorar a transferência: com o backbone congelado, um modelo de fundação chega a 50,6% no PlantDoc, e ajustado por inteiro cai para 29,4% (Nguyen et al., 2026).
- **O vazamento por proveniência tem nome.** A literatura separa o vazamento induzido pelo processo, quando os dados são aumentados antes da divisão, do inerente aos dados, quando o conjunto público já traz duplicatas ou a versão aumentada (Gerz; Jelali, 2026). A maior fonte de alface deste trabalho é o segundo caso: um conjunto publicado com 17 transformações de cada foto.

As ressalvas. No estudo com videira, a calibração reduz o ECE externo de 0,287 para 0,038, mas a confiança média cai para 0,55 num problema binário, e não se reporta acurácia seletiva; o intervalo de confiança da acurácia externa (±0,7 ponto com 500 imagens) parece calculado sobre as médias dos cinco *folds*, e as folhas ambíguas foram excluídas (Ergün et al., 2026). A temperatura vai no sentido oposto ao deste trabalho (8,34 lá, de 0,55 a 0,68 aqui), e as duas situações mostram que a calibração ajustada na validação não vale fora dela. Nos dois trabalhos com hortaliças folhosas, os resultados são intra-fonte: 97,3% num teste de cerca de 105 imagens, sem teste externo (Kabya et al., 2026), e 94,1% na validação, com imagens coletadas da web e aumento de dados aparentemente anterior à divisão (Abbasi; Martinez; Ahmad, 2023). E a queda de 98,7% para cerca de 31% em Gerz e Jelali (2026) é de mAP50 em detecção de objetos; o próprio artigo traz 32,77% no resumo e 30,64% na tabela.

Duas consequências para a coleta de campo. Como no estudo com videira, as fotografias serão separadas por local e rotuladas no campo antes de qualquer inferência; diferentemente dele, as folhas ambíguas serão marcadas, e não descartadas, para que o resultado não fique otimista. E nenhum dos trabalhos lidos mede se a abstenção intercepta os erros fora da fonte; Nguyen et al. (2026) apontam a rejeição de imagens fora da distribuição como trabalho futuro. Essa medida, com as fotografias de campo, é uma contribuição própria deste trabalho.

9.7 Primeiro lote de campo com fundo real

Em 27 de outubro de 2026, às 16h35, foram tiradas 10 fotografias numa horta, todas de alface crespa sadia segundo a avaliação feita no local. A horta tinha poucos pés, encostados uns nos outros, e as fotografias foram tiradas de cima, com vários pés por quadro, sobre solo com mato e trevo. O rótulo foi registrado antes de qualquer inferência; em duas fotografias, um furo pequeno numa folha foi anotado como dúvida, sem mudar o rótulo. Um lote anterior, de 18 de outubro, com um pé colhido na chuva e fotografado em casa sobre toalha branca (3 folhas sadias e 7 anômalas), não é de campo e é reportado à parte.

Os modelos rodaram às cegas, sem nenhum ajuste. As quatro versões deram como sadias as 10 fotografias da horta, sem abstenção e com confiança acima de 0,98; a proporção de acertos é de 10 em 10, com intervalo de Wilson de 72,2% a 100%. Para verificar se o resultado dependia de haver vários pés no quadro, cada fotografia foi recortada no centro, com metade e com um quarto do lado: os recortes também saíram sadios, nas quatro versões. No lote de casa, todas as fotografias diagnosticadas saíram anômalas, inclusive as três rotuladas como sadias, com confiança acima de 0,97, e os erros continuaram nos recortes, que excluem a toalha das bordas.

- **O que o lote mostra.** Fundo real não gera falso alarme em alface sadia. Era o risco mais direto do domain gap — o modelo foi treinado sobretudo com folhas isoladas — e não apareceu em nenhuma versão nem em nenhum enquadramento.
- **O que o lote não mostra.** Sem folhas doentes na horta, não há sensibilidade em campo, acurácia balanceada de campo nem domain gap. A acurácia balanceada que o relatório calcula para as 20 fotografias juntas não deve ser usada: todas as anômalas são do lote de casa e quase todas as sadias são da horta, de modo que a métrica mistura a classe com a cena. Pelo mesmo motivo, a tendência com a distância (H3) que o teste aponta é um artefato.
- **Folha ou cena.** Os modelos dizem sadia para tudo na horta e anômala para tudo em casa. Com cada lote quase todo em uma classe, não se separa o efeito da folha do efeito da cena (luz, folha molhada e machucada pela colheita). Uma das três folhas de casa rotuladas como sadias mostra, na revisão posterior, pontos escuros e a base amarronzada; o rótulo da coleta é mantido, e a dúvida fica registrada.
- **Calibração.** Os erros do lote de casa têm confiança acima do limiar de abstenção, como os do conjunto histórico: fora da distribuição de treino, o limiar não os intercepta. A recalibração com dados de campo não foi feita, porque exige uma horta de adaptação separada da de avaliação e as duas classes.

Para responder a Q3, falta fotografar folhas doentes na horta (no mínimo 15), uma segunda horta para a adaptação, imagens sem folha para a guarda de vegetação e uma segunda cultura, como a couve, para a hipótese H1.

REFERÊNCIAS

ABBASI, R.; MARTINEZ, P.; AHMAD, R. Crop diagnostic system: a robust disease detection and management system for leafy green crops grown in an aquaponics facility. **Artificial Intelligence in Agriculture**, v. 10, p. 1-12, 2023. DOI: 10.1016/j.aiia.2023.09.001.

ABOELENIN, S. et al. A hybrid framework for plant leaf disease detection and classification using convolutional neural networks and vision transformer. Complex & Intelligent Systems, v. 11, 2025. DOI: 10.1007/s40747-024-01764-x.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. IEEE Access, v. 11, p. 9042-9057, 2023. DOI: 10.1109/access.2023.3240100.

AHMAD, A.; SARASWAT, D.; GAMAL, A. A survey on using deep learning techniques for plant disease diagnosis and recommendations for development of appropriate tools. Smart Agricultural Technology, 2022. DOI: 10.1016/j.atech.2022.100083.

AHMED, A.; REDDY, G. A mobile-based system for detecting plant leaf diseases using deep learning. AgriEngineering, v. 3, p. 30-32, 2021. DOI: 10.3390/agriengineering3030032.

BARBEDO, J. G. A. Factors influencing the use of deep learning for plant disease recognition. Biosystems Engineering, v. 172, p. 84-91, 2018. DOI: 10.1016/j.biosystemseng.2018.05.013.

BARBEDO, J. G. A. Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. Computers and Electronics in Agriculture, v. 153, p. 46-53, 2018. DOI: 10.1016/j.compag.2018.08.013.

DEMILIE, W. Plant disease detection and classification techniques: a comparative study of the performances. Journal of Big Data, v. 11, p. 1-43, 2024. DOI: 10.1186/s40537-023-00863-9.

DHANYA, V. et al. Deep learning based computer vision approaches for smart agricultural applications. Artificial Intelligence in Agriculture, 2022. DOI: 10.1016/j.aiia.2022.09.007.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2021.

ERGÜN, E. et al. Confidence and uncertainty aware deep learning for reliable grape leaf disease diagnosis under real world field conditions. **Frontiers in Plant Science**, v. 17, 1839652, 2026. DOI: 10.3389/fpls.2026.1839652.

FACELI, K. et al. Inteligência artificial: uma abordagem de aprendizado de máquina. 2. ed. Rio de Janeiro: LTC, 2023.

GAJJAR, R. et al. Real-time detection and identification of plant leaf diseases using convolutional neural networks on an embedded platform. The Visual Computer, v. 38, p. 2923-2938, 2021. DOI: 10.1007/s00371-021-02164-9.

GEIFMAN, Y.; EL-YANIV, R. Selective classification for deep neural networks. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2017.

GEIRHOS, R. et al. Shortcut learning in deep neural networks. Nature Machine Intelligence, v. 2, p. 665-673, 2020. DOI: 10.1038/s42256-020-00257-z.

GERZ, F.; JELALI, M. Towards reliable data augmentation in machine learning: practices to prevent data leakage. **Smart Agricultural Technology**, v. 15, 102462, 2026. DOI: 10.1016/j.atech.2026.102462.

GHOSH, H. et al. Advanced neural network architectures for tomato leaf disease diagnosis in precision agriculture. Discover Sustainability, v. 6, 2025. DOI: 10.1007/s43621-025-01149-1.

GIL, A. C. Como elaborar projetos de pesquisa. 5. ed. São Paulo: Atlas, 2010.

GUO, C. et al. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 2017. p. 1321-1330.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016. p. 770-778.

IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Censo Agropecuário 2017: resultados definitivos. Rio de Janeiro: IBGE, 2019. ISSN 0103-6157.

ISLAM, A. et al. A deep learning approach for classification and segmentation of leafy vegetables and diseases. In: INTERNATIONAL CONFERENCE ON NEXT-GENERATION COMPUTING, IOT AND MACHINE LEARNING (NCIM), 2023. p. 1-6. DOI: 10.1109/ncim59001.2023.10212506.

JAFAR, A. et al. Revolutionizing agriculture with artificial intelligence: plant disease detection methods, applications, and their limitations. Frontiers in Plant Science, v. 15, 2024. DOI: 10.3389/fpls.2024.1356260.

JOSEPH, D.; PAWAR, P.; CHAKRADEO, K. Real-time plant disease dataset development and detection of plant disease using deep learning. IEEE Access, v. 12, p. 16310-16333, 2024. DOI: 10.1109/access.2024.3358333.

KABYA, N. D. et al. Towards practical AI for agriculture: a self-supervised attention framework for spinach leaf disease detection. **PLOS ONE**, v. 21, n. 1, e0340989, 2026. DOI: 10.1371/journal.pone.0340989.

KAUFMAN, S. et al. Leakage in data mining: formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, v. 6, n. 4, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2019.

MOHANTY, S.; HUGHES, D.; SALATHÉ, M. Using deep learning for image-based plant disease detection. Frontiers in Plant Science, v. 7, 2016. DOI: 10.3389/fpls.2016.01419.

MÜLLER, R.; KORNBLITH, S.; HINTON, G. When does label smoothing help? In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2019.

NGUGI, H. et al. Revolutionizing crop disease detection with computational deep learning: a comprehensive review. Environmental Monitoring and Assessment, v. 196, 2024. DOI: 10.1007/s10661-024-12454-z.

NGUGI, L.; ABELWAHAB, M.; ABO-ZAHHAD, M. Recent advances in image processing techniques for automated leaf pest and disease recognition: a review. Information Processing in Agriculture, 2020. DOI: 10.1016/j.inpa.2020.04.004.

NGUYEN, T. A. et al. From laboratory to field: frozen foundation-model features toward robust plant disease recognition. **Smart Agricultural Technology**, v. 15, 102531, 2026. DOI: 10.1016/j.atech.2026.102531.

NOYAN, M. A. Uncovering bias in the PlantVillage dataset. arXiv preprint arXiv:2206.04374, 2022.

PAÇAL, I.; IŞIK, G. Utilizing convolutional neural networks and vision transformers for precise corn leaf disease identification. Neural Computing and Applications, v. 37, p. 2479-2496, 2024. DOI: 10.1007/s00521-024-10769-z.

PAYMODE, A.; MALODE, V. Transfer learning for multi-crop leaf disease image classification using convolutional neural networks VGG. Artificial Intelligence in Agriculture, 2022. DOI: 10.1016/j.aiia.2021.12.002.

RUSSELL, S.; NORVIG, P. Artificial intelligence: a modern approach. 4. ed. Upper Saddle River: Pearson, 2022.

SALEEM, M. et al. Image-based plant disease identification by deep learning meta-architectures. Plants, v. 9, 2020. DOI: 10.3390/plants9111451.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2017. p. 618-626.

SHAFAY, M. et al. Recent advances in plant disease detection: challenges and opportunities. **Plant Methods**, v. 21, 140, 2025. DOI: 10.1186/s13007-025-01450-0.

SHAFIK, W. et al. A novel hybrid inception-xception convolutional neural network for efficient plant disease classification and detection. Scientific Reports, v. 15, 2025. DOI: 10.1038/s41598-024-82857-y.

SHAFIK, W. et al. Using transfer learning-based plant disease classification and detection for sustainable agriculture. BMC Plant Biology, v. 24, 2024. DOI: 10.1186/s12870-024-04825-y.

SINGH, D. et al. PlantDoc: a dataset for visual plant disease detection. In: ACM IKDD CODS AND COMAD, 7., 2020. p. 249-253. DOI: 10.1145/3371158.3371196.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 2019. p. 6105-6114.

THAKUR, P. et al. Vision transformer meets convolutional neural network for plant disease classification. Ecological Informatics, v. 77, 102245, 2023. DOI: 10.1016/j.ecoinf.2023.102245.

TOO, E. C. et al. A comparative study of fine-tuning deep learning models for plant disease identification. Computers and Electronics in Agriculture, v. 161, p. 272-279, 2019. DOI: 10.1016/j.compag.2018.03.032.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. Artificial Intelligence Review, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WANG, S. et al. Advances in deep learning applications for plant disease and pest detection: a review. Remote Sensing, v. 17, n. 4, 698, 2025. DOI: 10.3390/rs17040698.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. Journal of the American Statistical Association, v. 22, n. 158, p. 209-212, 1927. DOI: 10.2307/2276774.

WOEBBECKE, D. M. et al. Color indices for weed identification under various soil, residue, and lighting conditions. Transactions of the ASAE, v. 38, n. 1, p. 259-269, 1995. DOI: 10.13031/2013.27838.

WORKNEH, A. D. et al. Leakage-aware, calibrated, and explainable deep learning for robust almond disease classification. **Computers and Electronics in Agriculture**, v. 256, 112464, 2026. DOI: 10.1016/j.compag.2026.112464.

APÊNDICE A — ÍNDICE DE ARTEFATOS EXPERIMENTAIS

Todos os números apresentados neste documento são rastreáveis aos artefatos abaixo, gerados pelo pipeline e versionados no repositório do projeto. Cada ciclo de correção preserva os artefatos do ciclo anterior, permitindo auditoria da evolução.

Evidência	Artefato
Auditoria de vazamento — particionamento original (57,35 %)	results/leakage_report_old_split.json
Auditoria de vazamento — particionamento atual (0,04 %)	results/leakage_report.json
Metadados do particionamento (grupos, fontes, contagens)	data/split_metadata.json
Mapa auditável de rotulagem (proveniência pasta→rótulo)	data/label_map_audit.json
Métricas de teste — ciclo 3 (atual)	results/metrics_comparison.csv
Métricas detalhadas por classe e matrizes de confusão	results/metrics_full.json
Métricas de teste — ciclo 1	results/pre_lettuce_expansion/
Métricas de teste — ciclo 2	results/ciclo2_labelbug/
Calibração dos três modelos	weights/*_binary_calibration.json
Diagramas de fiabilidade	results/calibration_*.png
Matrizes de confusão	results/cm_*.png
Comparação entre arquiteturas	results/model_comparison.png
Mapas Grad-CAM (30 mapas, 3 modelos)	results/gradcam/
Teste de campo — ciclos 1, 2 e 3	results/campo_resultados{,_v2,_v3}.csv
Fotografias de campo com gabarito	campo/{healthy,anomalous}/
Investigação técnica completa das correções	docs/CORRECOES_METODOLOGICAS.md
Protocolo de teste de campo	docs/GUIA_TESTE_DE_CAMPO.md
Narrativa cronológica completa do projeto	docs/HISTORICO_COMPLETO_TCC.md
Teste de campo — ciclo 4	results/campo_resultados_v4.csv
Quarto ciclo: teste original, teste novo e comparação pareada	results/ciclo4/
Proveniência das imagens incorporadas no quarto ciclo	data/ciclo4_merge_manifest.csv
Reanálise de outubro: fontes por partição, ganho por lote, confiança em campo	results/ciclo4/reanalise_por_lote.json
Comparação das quatro arquiteturas (capítulo 9.1)	results/arquiteturas/ comparacao_arquiteturas.md
Auditoria de consistência (capítulo 9.2)	results/auditoria/auditoria_13out.{json,md}; docs/FICHA_TECNICA_FITOVISION.md
Quinto ciclo: particionamento e auditoria	data_c5/split_metadata.json; results/ciclo5/leakage_report.json
Quinto ciclo: avaliação por subconjunto e quarto × quinto ciclo	results/ciclo5/avaliacao_ciclo5.md; results/ciclo5/ciclo4_x_ciclo5.md
Quinto ciclo: pesos e calibração	weights/ciclo5/

Quadro 5 — Índice de artefatos experimentais. *Fonte: elaboração própria (2026).*

O código-fonte completo — pipeline de dados, treinamento, calibração, avaliação, API e interface web — está versionado em repositório Git, com sementes fixas, arquivo de dependências e scripts de reprodução. O pipeline de correção é retomável: uma execução interrompida salta as etapas já concluídas por meio de marcadores em disco, e os hashes perceptuais são persistidos em cache.