SEMINÁRIO 2 · TCC-II · ENGENHARIA DE SOFTWARE

Detecção de anomalias fitossanitárias em hortaliças utilizando visão computacional e aprendizado de máquina



José Pedro Vieira Silva

Orientador: Prof. Leanderson André · Univille · 15/10/2026

Do laboratório ao campo

~~99,01%~~

Resultado inicial, invalidado

57,35% do teste repetia fotos quase idênticas às do treino.

98,49%

Teste sem vazamento

Acurácia balanceada com split por hash perceptual, nas mesmas fontes do treino.

73,3%

Horta real

Ciclo 3, em 13 fotos de alface de horta.

A pergunta deixa de ser se a rede classifica folhas e passa a ser quanto o sistema vale em uso real.

O sistema em estudo

1

Foto da folha

Celular, luz natural, sem preparar a cena.

→

2

Guarda de vegetação

Índice rejeita imagens sem folha.

→

3

Rede com transfer learning

Três CNNs e um ViT-B/16, comparados.

→

4

Confiança calibrada

Abaixo de τ = 0,85, o sistema se abstém.

QUATRO VEREDICTOS

Saudável **Anômalo** **Inconclusivo** **Não é folha**

Treinado com cerca de 175 mil imagens públicas, deduplicadas por hash perceptual e particionadas em grupos para não vazar entre treino e teste.

Objetivo

GERAL

Avaliar o desempenho e a confiabilidade do sistema, quantificando com rigor estatístico a diferença entre laboratório e campo.

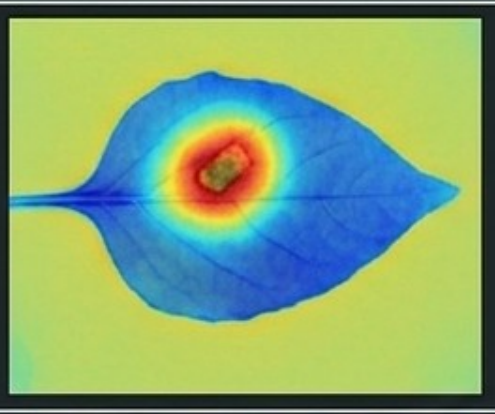
ESPECÍFICOS

a	*Dataset auditado, sem vazamento*	**Concluído**
b	*Comparar quatro arquiteturas, com o ViT*	**Concluído**
c	*Avaliar calibração e abstenção*	**Concluído**
d	*Montar o conjunto de campo*	**Coleta em 16/10**
e	*Quantificar o domain gap*	**Depende da coleta**
f	*Testar cultura, sintoma e distância*	**Depende da coleta**

Erros de método e ajustes

O que estava errado	Como apareceu	Ajuste
57,35% do teste repetia fotos do treino	*99,01% no papel, erros em fotos novas*	*Split por grupos de hash perceptual*
Abstenção nunca disparava (τ = 0,50)	*Toda foto recebia diagnóstico confiante*	*Piso de 0,85 no limiar*
3.972 alfaces saudáveis rotuladas como doentes	*Campo piorou depois de somar dados*	*Rotulagem refeita e auditada por pasta*
Variantes da mesma foto de alface no treino e no teste	*Auditoria de 13/10: 23% do teste*	*Split pela foto original (ciclo 5)*
Cultura associada ao rótulo	*81% dos erros em 19% do teste (lavoura)*	*Amostragem por cultura (ciclo 5)*
Teste lido como prova de generalização	*Fonte nunca vista: 23 pontos a menos*	*Avaliar por fonte retida e em campo*

Anatomia dos Erros (Grad-CAM)

	Acertos	Erros / Falsos Negativos
Folha Isolada (Lab)		Raro
Contexto Amplo (Campo)		

A decisão do modelo depende excessivamente do fundo homogêneo.

Gemini Notebook

O teste se parece com o treino

98,5%

Fontes vistas no treino

23.967 imagens das mesmas seis fontes, nas mesmas proporções.

75,4%

Fonte nunca vista

Espinafre em fundo branco, 484 imagens, antes de entrar no treino.

83,8%

Horta real

13 fotos de alface, ciclo 4. Intervalo de confiança de 58% a 96%.

Sem vazamento, o teste mede o quanto o modelo acerta fotos parecidas com as do treino.

Quatro arquiteturas, com o ViT

CICLO 4 · ACURÁCIA BALANCEADA (%) · 23.967 IMAGENS

Modelo	Parâm.	Teste	Lavoura	Latência
EfficientNet-B0	*4,0 M*	*98,48*	*86,3*	*7,2 ms*
ViT-B/16	*85,8 M*	*98,48*	*83,4*	*19,4 ms*
MobileNetV2	*2,2 M*	*97,89*	*86,6*	*5,3 ms*
ResNet-50	*23,5 M*	*97,82*	*87,8*	*8,6 ms*

Lavoura: mandioca, arroz, cana e café da coletânea (N = 4.530). Latência na RTX 3050. O ViT foi treinado no Colab (GPU L4, 6,1 h).

p = 0,26

ViT × EfficientNet-B0 no teste

Empate, com 21 vezes mais parâmetros.

86,3% × 99,7%

Lavoura × estúdio, na mesma fonte

81% dos erros estão em 19% do teste. Ali, o ViT é o pior.

O que o ciclo 4 mostrou

ESPINAFRE · 484 IMAGENS DE TESTE

Modelo	Ciclo 3	Ciclo 4	p (Holm)
EfficientNet-B0	*0,754*	*0,884*	$5{,}9\times10^{-12}$
ResNet-50	*0,776*	*0,862*	$1{,}9\times10^{-7}$
MobileNetV2	*0,743*	*0,874*	$1{,}9\times10^{-7}$

Acurácia balanceada, McNemar exato pareado. Os 173 recortes de míldio ficaram fora do teste estatístico: vêm de só 5 fotos. No domínio antigo houve empate: 0,9849 no ciclo 3 e 0,9848 no ciclo 4.

73,3% → 83,8%

Campo, 13 fotos históricas

McNemar p = 1,00. A amostra não distingue as versões.

99%

Confiança nos 2 erros de campo

Nenhuma rejeição em 13 fotos. ECE de 0,003 na validação e 0,146 em campo.

Ciclo 5: o pipeline corrigido

LAVOURA (N = 4.530) E FONTE RETIDA (N = 574) · %

Modelo	Lavoura c4 → c5	Especif. c4 → c5	Retida
EfficientNet-B0	*86,3 → 88,8*	*76,6 → 83,4*	*87,9*
ViT-B/16	*83,4 → 84,5*	*69,8 → 72,1*	*85,8*
MobileNetV2	*86,6 → 90,1*	*78,3 → 90,2*	*88,4*
ResNet-50	*87,8 → 89,6*	*81,4 → 89,0*	*90,1*

Split por foto original, amostragem por cultura, 8.266 imagens de praga e um lote de espinafre fora do treino. Quatro modelos no Colab em 14/10, cerca de 12 h.

+7 a +12 pontos

Especificidade na lavoura

Nas três CNNs. Menos falso alarme.

Troca, não ganho

Sensibilidade cai de 2 a 5 pontos

Por imagem, o ciclo 4 acerta mais; o ViT quase não muda.

Calibração: onde ela vale

0,003

ECE na validação

Temperatura ajustada e τ = 0,85, com 98,9% de cobertura.

T < 1

A calibração sobe a confiança

T de 0,55 a 0,68 nos oito modelos, efeito do label smoothing.

0,146

ECE em campo, ciclo 4

Sem temperatura, 0,094. No ciclo 5: 0,091 com e 0,125 sem.

A calibração vale onde foi ajustada. Em campo, os erros saíram com confiança de 0,95 a 0,999.

Conclusão parcial

O sistema acerta o que se parece com o treino. Em fonte nova, lavoura ou horta, a acurácia cai de 10 a 23 pontos e os erros saem com confiança acima de 0,95.

Métrica válida, alcance curto

98,5% sem vazamento, mas só nas fontes que o modelo já conhece.

Confiança não acompanha

ECE 0,003 na validação; em campo, erros com 0,95 a 0,999 e nenhum interceptado.

Dados pesam mais que modelo

O ViT, 21 vezes maior, empata. Corrigir os dados mudou a lavoura.

O que falta para fechar

1

Coleta com fundo real

A partir de 16/10, em hortas, com o rótulo anotado na hora e separadas por horta.

2

Medir o gap

Ciclos 4 e 5 congelados, às cegas, com intervalo por cultura e sintoma.

3

Aproximar o treino do campo

Fundo real no treino, sem tocar nas fotos de avaliação e teste de dependência do fundo.

Só fotos com fundo real dizem quanto o sistema vale em uso. **Obrigado**.