



FitoVision

Seminário III · TCC-I · UNIVILLE 2026

Detecção automática de anomalias fitossanitárias em hortaliças folhosas

• Visão Computacional

• Transfer Learning

• Grad-CAM

• Classificação Binária

99,01%

TEST ACCURACY

98,89%

F1 MACRO

210.832

IMAGENS

3

ARQUITETURAS

José Pedro · Engenharia de Software

Orientador: Prof. Laurindo Vilonga Dumba

0 percurso de hoje

Do problema no campo ao MVP em produção — em cinco movimentos.

- 01

Problema & solução

Contexto agrícola brasileiro e o pipeline FastAPI + EfficientNet-B0

→
- 02

Dados & metodologia

210.832 imagens, três arquiteturas e Transfer Learning

→
- 03

Resultados

Comparativo final no test set — 99,01% de accuracy

→
- 04

Explicabilidade

Grad-CAM: folhas anômalas, saudáveis e o domain gap

→
- 05

MVP & próximos passos

Interface web em produção, literatura e o que fica para o TCC-II

→

O problema

No campo, o diagnóstico fitossanitário é **lento, inconsistente e caro** — e raramente chega a quem mais precisa: o pequeno produtor.

- **77% dos estabelecimentos rurais** brasileiros são de agricultura familiar (IBGE, 2019)
- Diagnóstico por **inspeção visual**: subjetivo, demorado e dependente de especialista
- Produtores **sem acesso regular** a agrônomos qualificados
- **Joinville e o Sul do Brasil**: região de alta produção de folhosas
- Perdas por doenças não diagnosticadas impactam a **segurança alimentar regional**

CULTURAS - ALVO

- Alface
- Rúcula
- Espinafre
- Acelga
- Couve



Manual

Inspeção visual sujeita a erros



Tardio

Diagnóstico lento — tempo crítico perdido



FitoVision


Automático e objetivo

25ms

POR IMAGEM

A solução: um pipeline completo

Da foto ao diagnóstico explicável em **menos de 1 segundo** — backend FastAPI, modelo EfficientNet-B0 e mapas Grad-CAM, servidos a uma interface React.



RESPOSTA DA API · **POST** /API/PREDICT/GRADCAM

```
{
  "label": "anomalous",
  "confidence": 0.991,
  "healthy_prob": 0.009,
  "gradcam_image": "<base64 PNG>"
}
```

STACK TÉCNICA


PyTorch 2.5	ML	FastAPI	API
React 19	Frontend	SQLite	DB
RTX 3050 · CUDA 12.3		Treino	

Dataset — 210.832 imagens

Quatro fontes públicas do Kaggle, unificadas e divididas em **70 / 15 / 15** de forma estratificada (seed=42).

FONTES DE DADOS	
DATASET	IMAGENS
PlantVillage (Kaggle)	~54.000
Lettuce Diseases (ashishjstar)	2.337
Lettuce Multi-Transform (shuvoku)	79.458
Plant Diseases Training (nirmal)	116.147
Total	210.832

⚠ **Roboflow (20 datasets) descartado** — todos de object detection (bounding box), inutilizáveis para classificação. Decisão baseada em evidência experimental.



SPLIT	SAUD.	ANÔM.	TOTAL
Treino 70%	49.736	97.846	147.582
Val 15%	10.658	20.967	31.625
Teste 15%	10.658	20.967	31.625

Metodologia — três arquiteturas avaliadas

Transfer Learning com pesos ImageNet · **AdamW** (Loshchilov & Hutter, 2019) · CosineAnnealingLR · 30 épocas. ViT-B/16 fica previsto para o **TCC-II**.

MobileNetV2 3,4_M PARÂMETROS Sandler et al., 2018 Depthwise separable convolutions e bottleneck invertido — projetado para mobile e edge AI.	EfficientNet-B0 5,3_M PARÂMETROS Tan & Le, 2019 · escolhido Compound scaling — profundidade, largura e resolução em conjunto. Melhor acurácia por parâmetro no ImageNet.	ResNet-50 25,6_M PARÂMETROS He et al., 2016 Skip connections resolvem o vanishing gradient — referência clássica em Transfer Learning.
--	--	--

```
config comum → 30 épocas AdamW lr=1e-3 wd=1e-4 CosineAnnealingLR AMP float16 CrossEntropy label_smoothing=0.1 Early stopping p=10 RTX 3050 · CUDA 12.3 seed=42
```

Comparativo final

Avaliação no test set de **31.625 imagens nunca vistas**. EfficientNet-B0 lidera em todas as métricas — confirmando Tan & Le (2019).


MODELO	PARAMS	ACCURACY	F1 MACRO	RECALL	FN CRÍTICO	LATÊNCIA
★ EfficientNet-B0	5,3M	99,01%	98,89%	98,85%	138 ✓	24,1 ms
MobileNetV2	3,4M	98,81%	98,67%	98,65%	179	14,3 ms
ResNet-50	25,6M	98,71%	98,56%	98,59%	215 ✗	16,7 ms

✓ **Critério TCC atingido.** F1 Macro $\geq 0,85 \rightarrow 98,89\%$ (+13,89 pp)

↘ **Eficiência > profundidade.** ResNet-50, com 4,8× mais parâmetros, ficou em último — compound scaling vence (Tan & Le, 2019).

Curvas de Treino – 3 arquiteturas

Gradient-weighted Class Activation Mapping (Selvaraju et al., 2017) · 3 modelos × 4 imagens · todas com classificação correta.



LEITURA POR LINHA


- L1 MobileNetV2
- L2 EfficientNet-B0 · produção
- L3 ResNet-50

✓ **EfficientNet-B0 (L2):** ativações quentes concentradas nas lesões — maior precisão regional e menor FN (**138**).

⚠ **ResNet-50 (L3):** ativações mais dispersas — coerente com o desempenho inferior (**215 FN**).

Métricas de Avaliação – test set

Sem lesão localizada, os modelos ativam **textura foliar difusa** — exatamente o comportamento esperado para uma folha sadia.



LEITURA POR LINHA


- L1 MobileNetV2
- L2 EfficientNet-B0 · produção
- L3 ResNet-50

✓ **Mapas frios e difusos.** O modelo aprendeu **textura foliar global** — não artefatos de fundo.

⚠ **MobileNetV2 (63%):** confiança menor em iluminação lateral atípica — menor robustez a variações de campo.

Falsos negativos & o domain gap

Anômala classificada como saudável. Não é só erro — é evidência que **confirma a seção 2.6 do TCC**.



Imagens fora do domínio

Os FN são folhas de mandioca / plantas compostas — morfologia muito diferente das folhosas do treino.



Domain gap confirmado

Modelos treinados em estúdio falham em condições de campo reais — o problema da seção 2.6.



Confiança baixa 52–86%

Os modelos "hesitam" nos FN — bem abaixo dos acertos (94–99%). Um threshold pode mitigar.



Achado válido

Confirma empiricamente a necessidade de coleta local em Joinville (TCC-II).



O Grad-CAM transforma erro em aprendizado científico — cada FN justifica a coleta local de imagens em campo prevista para o TCC-II.

Por que o EfficientNet-B0 venceu?

O ResNet-50 tem **4,8× mais parâmetros** e treinou **41% mais tempo** — e ainda assim ficou em último.

- 01

Melhor accuracy e F1

99,01% · 98,89% — superior em todos os indicadores avaliados.
- 02

Menor FN — o mais crítico no campo

138 vs 179 vs 215. Doença não detectada = **perda real na lavoura.**
- 03


Confirma Tan & Le (2019)

5,3M vs 25,6M params com acurácia superior — compound scaling > profundidade pura.
- 04


Treino 41% mais rápido

6,46 h vs 11,03 h do ResNet-50 — menor tempo e uso de VRAM.

CURVA DE APRENDIZADO — EFFICIENTNET-B0




FALSOS NEGATIVOS POR MODELO · menor é melhor



Interface web FitoVision

Sistema completo em produção — **FastAPI + React 19**, Grad-CAM viewer, gauge animado e histórico em SQLite, com resposta em < 25 ms.



COMPONENTES DA INTERFACE

- Hero Strip**
99,01% · 210.832 imagens · modelo ativo
- Gauge SVG animado**
Confiança · verde = saudável / vermelho = anômalo
- Grad-CAM viewer**
Overlay do heatmap em tempo real
- Barras de probabilidade**
Saudável + anômala, por classe
- Histórico SQLite**
GET / DELETE /api/history · persistência async

Comparação com a literatura

FitoVision é **competitivo com o estado da arte** — com dataset próprio multi-fonte e foco no contexto brasileiro.

REFERÊNCIA	TAREFA	DATASET	ACCURACY
Mohanty et al. (2016)	26 classes	PlantVillage	99,35%
Too et al. (2019)	Multi-classe CNNs	PlantVillage	98,80%
Atila et al. (2021)	5 classes	PlantVillage	97,40%
★ FitoVision · EfficientNet-B0	Binário · folhosas	Multi-fonte 210k	99,01%
FitoVision · MobileNetV2	Binário	Multi-fonte 210k	98,81%

✓ **Generalização confirmada:** val_acc ≈ test_acc (Δ máx. 0,05 pp) — e o Grad-CAM valida o foco nas lesões.

LIMITAÇÕES & MITIGAÇÕES · TCC-II

- Dataset proxy** — PlantVillage sem alface/rúcula → coleta local em Joinville
- Domain gap** — FN revelam falha em campo → validação com agricultores locais
- ViT-B/16** — RTX 3050 6GB inviável (OOM) → Google Colab Pro
- Latência em CPU** — medições em GPU → avaliar ONNX / TorchLite para mobile

Próximos passos — TCC-II (2026/2)

O que fica para o próximo semestre — do campo à publicação.



Coleta local — Joinville
Fotos em hortas e estufas da região, com o contexto agrícola brasileiro real.



Grad-CAM em produção
Ativar o overlay no frontend e documentar a análise completa na monografia.



ViT-B/16
Transformer de visão — previsto com Colab Pro ou GPU maior (RTX 3050 dá OOM).



Classificação multi-classe
De binário para tipo específico: míldio, oídio, clorose, pragas...



Deployment mobile
ONNX / TorchLite para inferência sem GPU — o cenário real do agricultor.



Artigo científico
Documentar metodologia e o comparativo completo para publicação após a defesa.



Detecção automática, **explicável** e pronta para o campo.

Transfer Learning · Grad-CAM · interface web — **30 mapas gerados**, 3 modelos comparados, domain gap identificado e documentado.

99,01%

TEST ACCURACY

98,89%

F1 MACRO

138

FN MÍNIMO · EFFICIENTNET

+13,89_{pp}

ACIMA DO CRITÉRIO $F1 \geq 0,85$