

UNIVERSIDADE DA REGIÃO DE JOINVILLE — UNIVILLE
DEPARTAMENTO DE INFORMÁTICA
CURSO DE ENGENHARIA DE SOFTWARE

**DETECÇÃO AUTOMÁTICA DE ANOMALIAS FITOSSANITÁRIAS EM
HORTALIÇAS FOLHOSAS UTILIZANDO VISÃO COMPUTACIONAL
E APRENDIZADO DE MÁQUINA**

JOSÉ PEDRO

Orientador: Prof. Laurindo Vilonga Dumba

Joinville — SC
2026

SUMÁRIO

1 DEFINIÇÃO DO PROJETO

- 1.1 Tema
- 1.2 Justificativa
- 1.3 Objetivo Geral
- 1.4 Objetivos Específicos

2 REVISÃO DA LITERATURA

- 2.1 Visão Computacional e Inteligência Artificial Aplicadas à Agricultura
- 2.2 Fundamentos de Aprendizado Profundo para Classificação de Imagens
- 2.3 Redes Neurais Convolucionais (CNNs)
- 2.4 Transfer Learning
- 2.5 Vision Transformers (ViTs) e Modelos Híbridos CNN+ViT
- 2.6 O Problema da Generalização (Domain Gap)
- 2.7 Inteligência Artificial Explicável (XAI) e Grad-CAM
- 2.8 Anomalias Fitossanitárias em Hortaliças Folhosas e Datasets Disponíveis
- 2.9 Trabalhos Relacionados

3 PROPOSTA E PROCEDIMENTOS METODOLÓGICOS

- 3.1 Caracterização do Delineamento de Pesquisa
- 3.2 Pipeline Metodológico
- 3.3 Caracterização do Ambiente Experimental
- 3.4 Técnicas e Ferramentas para Análise de Dados
- 3.5 Cronograma de Execução — TCC-II (2026/2)

4 MVP — PROJETO MÍNIMO VIÁVEL

- 4.1 Definição do MVP
- 4.2 Etapas do MVP
- 4.3 Critério de Validação
- 4.4 Evolução Pós-MVP
- 4.5 Reprodutibilidade

REFERÊNCIAS

1 DEFINIÇÃO DO PROJETO

Este capítulo apresenta a definição do projeto de pesquisa, abrangendo o tema proposto, sua justificativa, a questão de pesquisa central e os objetivos geral e específicos que nortearão o desenvolvimento do trabalho.

1.1 Tema

O presente projeto de pesquisa situa-se na interseção entre Inteligência Artificial, Visão Computacional e Ciência de Dados aplicados ao Agronegócio. O tema central é a detecção automática de anomalias fitossanitárias — incluindo doenças, deficiências nutricionais e danos por pragas — em hortaliças folhosas, por meio de algoritmos de Aprendizado de Máquina e análise de imagens digitais.

A linha de pesquisa está alinhada com as áreas de atuação do orientador, Prof. Laurindo Vilonga Dumba, que abrangem Visão Computacional, Machine Learning, Inteligência Artificial e Ciência de Dados. A escolha de hortaliças folhosas como objeto de estudo justifica-se pela sua expressiva relevância econômica na agricultura familiar da região de Joinville e do Sul do Brasil, bem como pela viabilidade de obtenção de datasets públicos de qualidade para a condução dos experimentos.

1.2 Justificativa

A seguir, apresentam-se a delimitação do estudo, suas relevâncias e a questão de pesquisa que motiva o trabalho.

1.2.1 Delimitação

O estudo delimita-se à detecção de anomalias visuais em folhas de hortaliças folhosas, especificamente alface (*Lactuca sativa*), rúcula (*Eruca vesicaria*), espinafre (*Spinacia oleracea*) e acelga (*Beta vulgaris* var. *cicla*). As anomalias alvo compreendem: (a) doenças fúngicas como míldio e oídio; (b) deficiências nutricionais como clorose por deficiência de nitrogênio; (c) danos por pragas como pulgões e lagartas minadores; e (d) estresse hídrico. A detecção será realizada a partir de imagens digitais obtidas de datasets públicos e, no próximo semestre, de coletas locais em hortas da região de Joinville, não contemplando sensoriamento remoto, análise de solo ou variáveis climáticas.

1.2.2 Relevância Científica e Acadêmica

A aplicação de Deep Learning ao diagnóstico fitossanitário é um campo em crescimento exponencial. Mohanty, Hughes e Salathé (2016) demonstraram que modelos de CNN treinados no dataset PlantVillage atingem acurácias superiores a 99% em condições controladas, estabelecendo um marco para a área. Entretanto, a generalização para condições reais de campo e para culturas específicas — como as hortaliças folhosas no contexto brasileiro — ainda representa uma lacuna a ser explorada. Este trabalho contribui academicamente ao aplicar e comparar arquiteturas modernas de Transfer Learning, incluindo Vision Transformers, nesse contexto específico, gerando evidências empíricas relevantes.

1.2.3 Relevância Social

Segundo o Censo Agropecuário de 2017 (IBGE, 2019), 77% dos estabelecimentos rurais brasileiros são de agricultura familiar. Esses produtores geralmente não dispõem de acesso a especialistas agrônomos de forma regular, dependendo de inspeção visual manual para o diagnóstico de problemas fitossanitários — processo lento, inconsistente e custoso. Uma ferramenta computacional acessível de diagnóstico automático pode democratizar o acesso à tecnologia de precisão, reduzir perdas de produção e contribuir para a segurança alimentar regional.

1.2.4 Relevância para a Formação Acadêmica

O desenvolvimento deste trabalho permite ao aluno consolidar competências fundamentais para um engenheiro de software moderno: programação orientada a dados, desenvolvimento e avaliação de modelos de ML, manipulação de frameworks de Deep Learning (PyTorch), versionamento de experimentos e escrita científica. A natureza interdisciplinar do projeto — conectando Engenharia de Software, IA e Agronomia — também estimula o pensamento sistêmico e a capacidade de aplicar conhecimento técnico a problemas reais de alto impacto.

1.2.5 Viabilidade

O projeto é tecnicamente viável dado que: (a) os principais datasets necessários são públicos e de acesso gratuito (PlantVillage, Kaggle, LeafyVclassify7BD); (b) os frameworks de Deep Learning são open-source e amplamente documentados; (c) o treinamento dos modelos pode ser conduzido em Google Colab com GPU gratuita, sem necessidade de infraestrutura computacional dedicada; (d) o orientador possui expertise nas áreas de Visão Computacional e Machine Learning, garantindo suporte técnico adequado.

1.2.6 Questão de Pesquisa

Como automatizar a detecção precoce de anomalias fitossanitárias em hortaliças folhosas utilizando técnicas de Visão Computacional e Aprendizado de Máquina, de modo a reduzir perdas na produção e apoiar decisões de manejo de pequenos e médios produtores rurais?

1.3 Objetivo Geral

Desenvolver e avaliar um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, utilizando técnicas de Visão Computacional e Aprendizado de Máquina, com ênfase na comparação entre redes neurais convolucionais (ResNet-50, MobileNetV2, EfficientNet-B0) e Vision Transformer (ViT-B/16) com Transfer Learning, de modo a fornecer diagnósticos precisos e contribuir com um framework metodológico extensível a outras culturas agrícolas.

1.4 Objetivos Específicos

- a. Realizar revisão sistemática da literatura sobre detecção de doenças e anomalias em plantas por meio de Visão Computacional e Machine Learning;
- b. Construir ou adaptar um dataset de imagens de hortaliças folhosas com e sem anomalias, a partir de fontes públicas (PlantVillage, Kaggle, LeafyVclassify7BD) e, no próximo semestre, coleta local em Joinville;
- c. Implementar pipeline de pré-processamento de imagens com redimensionamento, normalização e técnicas de data augmentation;
- d. Treinar e comparar modelos de classificação baseados em Transfer Learning: ResNet-50, MobileNetV2, EfficientNet-B0 e ViT-B/16, além de um baseline ingênuo (CNN treinada do zero);
- e. Avaliar e comparar os modelos utilizando métricas de Precisão, Recall, F1-Score, Acurácia, Matriz de Confusão e análise estatística;
- f. Aplicar a técnica Grad-CAM para validação da explicabilidade dos modelos e verificação das regiões de ativação;
- g. Analisar e discutir a extensibilidade da metodologia proposta para outras culturas agrícolas;
- h. Produzir monografia e artigo científico documentando a metodologia, os experimentos e os resultados obtidos.

2 REVISÃO DA LITERATURA

Este capítulo apresenta os fundamentos teóricos e o estado da arte que sustentam a proposta desta pesquisa. A revisão está organizada em nove subseções que cobrem desde os conceitos gerais de Inteligência Artificial e Visão Computacional aplicadas à agricultura até os trabalhos correlatos mais recentes, passando pelas arquiteturas de aprendizado profundo, técnicas de transferência de aprendizado, modelos baseados em Transformers, o problema da generalização entre domínios, explicabilidade de modelos e os datasets disponíveis para hortaliças folhosas.

2.1 Visão Computacional e Inteligência Artificial Aplicadas à Agricultura

A Inteligência Artificial (IA) e a Visão Computacional (CV) consolidaram-se como tecnologias habilitadoras para a agricultura de precisão, permitindo o monitoramento automatizado de culturas com redução de custos operacionais e dependência de especialistas humanos (Jafar et al., 2024; Upadhyay et al., 2025). Na perspectiva de Russell e Norvig (2022), um sistema de IA pode ser compreendido como um agente inteligente que percebe seu ambiente por meio de sensores e age sobre ele por meio de atuadores. No contexto agrícola, a câmera de um smartphone atua como sensor, captando imagens foliares em um ambiente parcialmente observável — pois fatores como composição do solo, umidade e histórico fitossanitário não são capturados pela imagem isolada. Essa formulação pode ser descrita pelo modelo PEAS (*Performance, Environment, Actuators, Sensors*), no qual a medida de desempenho é a acurácia do diagnóstico, o ambiente é a lavoura com variações de iluminação e fundo, o atuador é a recomendação de manejo e o sensor é a câmera digital.

No Brasil, a agricultura familiar representa aproximadamente 77% dos estabelecimentos agropecuários, sendo que apenas cerca de 20% dos produtores familiares dispõem de acesso regular a assistência técnica especializada (IBGE, 2019). Essa lacuna torna particularmente relevante o desenvolvimento de sistemas automatizados de diagnóstico fitossanitário que possam ser operados por produtores sem formação técnica em fitopatologia.

O trabalho pioneiro de Mohanty, Hughes e Salathé (2016) demonstrou que redes neurais convolucionais treinadas no dataset PlantVillage eram capazes de classificar 26 doenças em 14 espécies de plantas com acurácia superior a 99%. Essa publicação marcou o início de uma intensa produção científica na área, que desde então expandiu-se para incorporar drones, sensores IoT, imagens multiespectrais e aplicativos móveis como mecanismos de captura e processamento (Dhanya et al., 2022; Jafar et al., 2024; Upadhyay et al., 2025).

2.2 Fundamentos de Aprendizado Profundo para Classificação de Imagens

O aprendizado profundo (*deep learning*) constitui um subconjunto do aprendizado de máquina baseado em redes neurais artificiais com múltiplas camadas de representação. Conforme Russell e Norvig (2022, Cap. 18), uma rede neural *feed-forward* multicamadas é composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída, nas quais cada neurônio computa uma soma ponderada das entradas seguida pela aplicação de uma função de ativação não linear.

O processo de treinamento consiste na minimização de uma função de perda por meio do algoritmo de *backpropagation*, que propaga os gradientes do erro da camada de saída até a camada de entrada, ajustando os pesos sinápticos pela regra da descida pelo gradiente (Russell; Norvig, 2022). Faceli et al. (2023, Cap. 7) detalham o formalismo matemático desse ajuste, demonstrando que a convergência depende criticamente da taxa de aprendizado, do tamanho do lote (*batch size*) e de técnicas de regularização como *dropout* e *early stopping* para prevenir o sobreajuste (*overfitting*).

No contexto deste trabalho, o problema é formulado como uma tarefa de classificação supervisionada multiclasse, na qual o modelo recebe uma imagem de folha como entrada e produz como saída a probabilidade de pertencimento a cada classe de anomalia — conforme a definição formal de aprendizado supervisionado apresentada por Faceli et al. (2023, Cap. 1).

2.3 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais (CNNs) constituem a classe de arquitetura dominante para tarefas de classificação de imagens. Diferentemente das redes densas tradicionais, as CNNs exploram a estrutura espacial bidimensional das imagens por meio de três tipos principais de camadas: camadas convolucionais, que aplicam filtros aprendíveis para extrair mapas de características; camadas de *pooling*, que reduzem a dimensionalidade espacial preservando as características mais salientes; e camadas totalmente conectadas (*fully connected*), que realizam a classificação final (Russell; Norvig, 2022, Cap. 18).

A extração de características nas CNNs é hierárquica: as primeiras camadas aprendem a detectar bordas e texturas simples, enquanto camadas mais profundas combinam esses padrões elementares para reconhecer estruturas complexas como lesões foliares, manchas necróticas e halos cloróticos (Russell; Norvig, 2022). Essa capacidade de aprendizado automático de representações elimina a necessidade de engenharia manual de características,

que era a principal limitação das abordagens clássicas de visão computacional aplicadas à fitopatologia (Ngugi; Abelwahab; Abo-Zahhad, 2020).

Dentre as arquiteturas investigadas neste trabalho, destacam-se três modelos representativos do estado da arte em transferência de aprendizado para classificação de imagens:

ResNet-50 (He et al., 2016): introduziu o conceito de conexões residuais (*skip connections*), que permitem o treinamento eficaz de redes com dezenas ou centenas de camadas ao mitigar o problema do gradiente desvanecente (*vanishing gradient*). A arquitetura com 50 camadas tornou-se referência em tarefas de classificação de imagens e é amplamente utilizada como *backbone* para transferência de aprendizado em domínios agrícolas (Saleem et al., 2020; Jeyabose et al., 2022).

MobileNetV2 (Sandler et al., 2018): projetada para dispositivos com recursos computacionais limitados, utiliza convoluções separáveis em profundidade (*depthwise separable convolutions*) e blocos residuais invertidos para reduzir drasticamente o número de parâmetros e operações, mantendo acurácia competitiva. Essa eficiência viabiliza a inferência em tempo real em smartphones — aspecto crucial para o cenário de *edge AI* na agricultura familiar (Ahmed; Reddy, 2021; Gajjar et al., 2021).

EfficientNet-B0 (Tan; Le, 2019): propôs um método de escalonamento composto (*compound scaling*) que equilibra sistematicamente profundidade, largura e resolução da rede, alcançando melhor relação entre acurácia e eficiência computacional em comparação com arquiteturas escaladas manualmente. No contexto de diagnóstico foliar, EfficientNet-B0 apresenta desempenho competitivo com custo computacional inferior ao ResNet-50, sendo indicada para cenários com restrições de hardware (Demilie, 2024).

2.4 Transfer Learning

A transferência de aprendizado (*transfer learning*) consiste na reutilização de pesos sinápticos aprendidos em uma tarefa-fonte — tipicamente a classificação das 1.000 categorias do ImageNet — como ponto de partida para uma tarefa-alvo com dados escassos (Faceli et al., 2023, Cap. 7). O procedimento padrão envolve o congelamento das camadas iniciais da rede pré-treinada, que capturam padrões visuais genéricos como bordas e texturas, e o ajuste fino (*fine-tuning*) das camadas finais para o domínio específico — neste caso, anomalias em hortaliças folhosas.

Mohanty, Hughes e Salathé (2016) demonstraram que CNNs pré-treinadas no ImageNet, quando ajustadas no PlantVillage, atingiram acurácia de 99,35% na classificação de doenças em 14 espécies de plantas. Esse resultado consolidou o *transfer learning* como abordagem padrão para o diagnóstico foliar automatizado (Paymode; Malode, 2022; Shafik et al., 2024). Contudo, o próprio estudo de Mohanty et al. (2016) evidenciou que a acurácia do mesmo modelo cai drasticamente quando aplicado a imagens capturadas em condições reais de campo, revelando a fragilidade da generalização — tema aprofundado na Seção 2.6.

No presente trabalho, todas as arquiteturas avaliadas (ResNet-50, MobileNetV2, EfficientNet-B0 e ViT-B/16) são inicializadas com pesos pré-treinados no ImageNet e submetidas a *fine-tuning* progressivo, permitindo comparar a capacidade de adaptação de cada arquitetura ao domínio de hortaliças folhosas com dados limitados.

2.5 Vision Transformers (ViTs) e Modelos Híbridos CNN+ViT

Os Vision Transformers (ViTs), introduzidos por Dosovitskiy et al. (2021), representam uma mudança de paradigma na classificação de imagens ao substituir as operações convolucionais pelo mecanismo de *self-attention*. Nessa arquitetura, a imagem de entrada é dividida em fragmentos retangulares (*patches*) de tamanho fixo — tipicamente 16×16 pixels —, que são projetados linearmente e tratados como uma sequência de tokens, de modo análogo às palavras em modelos de processamento de linguagem natural.

A principal vantagem do mecanismo de *self-attention* em relação à convolução reside na capacidade de capturar dependências globais desde as primeiras camadas: enquanto um filtro convolucional possui campo receptivo local restrito, cada token do ViT pode atender a qualquer outro token da sequência, permitindo que o modelo identifique relações espaciais de longo alcance — por exemplo, correlacionar uma lesão em uma extremidade da folha com um padrão de descoloração em outra região distante (Dosovitskiy et al., 2021).

Modelos híbridos que combinam CNNs e ViTs têm se mostrado particularmente eficazes no diagnóstico foliar. Nesses modelos, as camadas convolucionais iniciais extraem características locais de baixo nível (bordas, texturas), enquanto os blocos Transformer subsequentes capturam relações globais entre regiões da imagem (Thakur et al., 2023). Estudos recentes demonstram que arquiteturas híbridas CNN+ViT superam CNNs puras em diversos cenários de classificação de doenças foliares, atingindo acurácias de 98% a 100% em milho, uva e tomate (Ghosh et al., 2025; Aboelenin et al., 2025; Paçal; Işık, 2024).

Uma limitação importante dos ViTs puros é a elevada demanda por dados de treinamento: sem pré-treinamento em grandes bases como o ImageNet-21k, o desempenho é inferior ao de CNNs em datasets de médio porte (Dosovitskiy et al., 2021). Por essa razão, neste trabalho optou-se por utilizar o ViT-B/16 pré-treinado no ImageNet com *fine-tuning*, seguindo a mesma estratégia de transferência de aprendizado aplicada às demais arquiteturas.

2.6 O Problema da Generalização (Domain Gap)

Um dos desafios mais críticos da literatura em diagnóstico foliar automatizado é a discrepância entre o desempenho em condições controladas de laboratório e o desempenho em condições reais de campo — fenômeno denominado *domain gap* ou lacuna de domínio (Ahmad; Gamal; Saraswat, 2023). Modelos treinados exclusivamente no PlantVillage, cujas imagens possuem fundo branco homogêneo e iluminação padronizada, frequentemente atingem acurácias entre 95% e 99%. Contudo, quando avaliados em imagens capturadas no campo — com variação de iluminação solar, presença de solo e outras folhas no fundo, diferentes ângulos de captura e estágios variados de maturação —, a acurácia pode cair para entre 31% e 72%, conforme evidenciado por múltiplos estudos (Mohanty; Hughes; Salathé, 2016; Upadhyay et al., 2025; Sharma; Tripathi; Mittal, 2023).

Revisões recentes confirmam que a transferibilidade entre domínios permanece como um problema aberto. Modelos tendem a aprender artefatos do dataset — como o fundo da imagem ou a textura da bancada — em vez de focar exclusivamente nas características patológicas das folhas (Jeyabose et al., 2022; Tian et al., 2024; Ahmad; Gamal; Saraswat, 2023). Estratégias de mitigação incluem: (a) *data augmentation* agressivo com rotações, espelhamentos, variações de brilho e recortes aleatórios; (b) treinamento com mistura de imagens laboratoriais e de campo, que pode elevar a acurácia cross-dataset para entre 78% e 82% (Upadhyay et al., 2025; Qin et al., 2025); e (c) uso de arquiteturas baseadas em regiões lesionadas (*lesion-centric*), que forcem o modelo a concentrar-se na área de interesse (Wang et al., 2025; Ngugi et al., 2024).

No presente trabalho, o problema do *domain gap* é abordado em duas frentes: neste semestre, mediante aplicação de técnicas de *data augmentation* no pipeline de treinamento e validação cruzada com múltiplos datasets publicados na literatura; e, no próximo semestre, mediante coleta local de imagens de hortaliças folhosas em hortas produtivas da região de Joinville.

2.7 Inteligência Artificial Explicável (XAI) e Grad-CAM

A explicabilidade de modelos de aprendizado profundo — conhecida como Inteligência Artificial Explicável (*Explainable AI* — XAI) — constitui uma exigência científica e prática para a adoção de sistemas de diagnóstico automatizado na agricultura. Conforme Faceli et al. (2023, Cap. 10), a interpretabilidade de um modelo é um critério de avaliação tão relevante quanto a acurácia, especialmente em domínios nos quais as decisões impactam diretamente a produção e a segurança alimentar.

Apesar de sua importância, técnicas de XAI permanecem subutilizadas na literatura de diagnóstico foliar. Ghosh et al. (2025) identificaram que a maioria dos estudos reporta apenas métricas de classificação, sem apresentar evidências visuais de que os modelos estão efetivamente aprendendo padrões patológicos relevantes. Essa lacuna é particularmente preocupante dado o problema do *domain gap* discutido na Seção 2.6: sem explicabilidade, não é possível distinguir se um modelo com alta acurácia aprendeu a reconhecer lesões foliares ou simplesmente memorizou o fundo branco do PlantVillage.

A técnica adotada neste trabalho é o *Gradient-weighted Class Activation Mapping* (Grad-CAM), proposta por Selvaraju et al. (2017). O Grad-CAM opera calculando os gradientes do escore da classe predita em relação aos mapas de características da última camada convolucional, ponderando esses mapas pela importância relativa de cada canal e gerando um mapa de calor bidimensional que é sobreposto à imagem original.

No contexto desta pesquisa, o Grad-CAM cumpre dupla função: (a) como ferramenta de validação científica, permitindo verificar se os modelos focam nas regiões de lesão foliar e não em artefatos de fundo; e (b) como mecanismo de confiança para o usuário final, que pode visualizar a justificativa da classificação.

2.8 Anomalias Fitossanitárias em Hortaliças Folhosas e Datasets Disponíveis

As hortaliças folhosas investigadas neste trabalho — alface (*Lactuca sativa*), rúcula (*Eruca vesicaria*), espinafre (*Spinacia oleracea*) e acelga (*Beta vulgaris* var. *cicla*) — são culturas de ciclo curto, alta perecibilidade e expressiva importância econômica na agricultura familiar da região Sul do Brasil (IBGE, 2019). As principais anomalias fitossanitárias que acometem essas culturas incluem doenças fúngicas como míldio e oídio, deficiências nutricionais manifestadas como clorose foliar, e danos mecânicos e de alimentação causados por pragas.

O dataset mais amplamente utilizado na literatura é o PlantVillage, que contém mais de 54.000 imagens de folhas de 14 espécies abrangendo 26 doenças (Mohanty; Hughes; Salathé, 2016). Contudo, o PlantVillage apresenta limitações significativas para o escopo deste

trabalho: as imagens foram capturadas em condições laboratoriais com fundo branco, e a representação de hortaliças folhosas é escassa. Iniciativas mais recentes começam a preencher essa lacuna: Islam et al. (2023) desenvolveram os datasets LeafyVclassify7BD e LeafyVdisease7BD, dedicados à classificação e detecção de doenças em folhosas, com acurácias reportadas acima de 90%.

A escassez de datasets públicos anotados de hortaliças folhosas brasileiras em condições reais de campo constitui uma lacuna explícita da literatura — apontada por múltiplas revisões (Upadhyay et al., 2025; Demilie, 2024; Jafar et al., 2024). Esta lacuna justifica a estratégia de coleta local planejada para o próximo semestre, na qual imagens serão capturadas em hortas produtivas da região de Joinville.

2.9 Trabalhos Relacionados

Esta seção apresenta uma síntese comparativa dos trabalhos mais relevantes identificados na revisão da literatura, organizados no Quadro 1.

Autores	Cultura	Dataset	Arquitetura	Acurácia	Diferencial deste TCC
Mohanty et al. (2016)	26 culturas	PlantVillage	AlexNet, GoogLeNet	99,35%	Foco em folhosas + ViT + Grad-CAM
Islam et al. (2023)	Folhosas	LeafyVclassify7BD	ResNet, YOLOv5	~91%	Comparação de 4 arquiteturas + XAI
Thakur et al. (2023)	Múltiplas	PlantVillage	ViT + CNN híbrido	~98%	Aplicação a folhosas + contexto BR
Paçal e Işık (2024)	Milho	PlantVillage	ViT + CNN	99,8%	Domínio folhosas + augmentation
Ghosh et al. (2025)	Tomate	Próprio	Swin+EfficientNetV2	~98%	Foco em folhosas + edge AI
Shafik et al. (2025)	Múltiplas	PlantVillage	Inception-Xception	~97%	ViT no escopo + coleta local
S e R (2025)	Múltiplas	PlantVillage	ViT puro	~96%	Folhosas + validação Grad-CAM
Upadhyay et al. (2025)	Revisão	Múltiplos	CNNs diversas	Variada	Implementação experimental

Quadro 1 — Comparação entre trabalhos relacionados e diferenciais do presente TCC.

Conforme evidenciado no Quadro 1, o presente trabalho diferencia-se da literatura existente em quatro aspectos principais: (a) foco exclusivo em hortaliças folhosas, um nicho sub-representado; (b) comparação sistemática de quatro arquiteturas distintas, incluindo um

Vision Transformer; (c) utilização do Grad-CAM como ferramenta de validação científica; e (d) contextualização para a realidade da agricultura familiar brasileira.

3 PROPOSTA E PROCEDIMENTOS METODOLÓGICOS

Este capítulo detalha a proposta metodológica atualizada para o TCC-II, incorporando as decisões de escopo definidas ao final do TCC-I: inclusão do Vision Transformer (ViT-B/16) no comparativo de arquiteturas, remoção do YOLOv8 do escopo, e foco neste semestre na estruturação teórica, implementação do pipeline e treinamento com datasets da literatura — com coleta local em Joinville prevista para o próximo semestre.

3.1 Caracterização do Delineamento de Pesquisa

O presente trabalho caracteriza-se como uma pesquisa de natureza quantitativa, dado que os resultados são expressos por métricas numéricas objetivas (Precisão, Recall, F1-Score e Acurácia) e submetidos a análise estatística comparativa entre os modelos avaliados.

Quanto aos objetivos, trata-se de uma pesquisa exploratório-descritiva. O caráter exploratório manifesta-se na investigação de qual arquitetura — dentre ResNet-50, MobileNetV2, EfficientNet-B0 e ViT-B/16 — apresenta melhor desempenho no domínio específico de hortaliças folhosas. O caráter descritivo expressa-se na documentação sistemática do comportamento de cada modelo sob diferentes configurações experimentais.

O delineamento adota a estratégia de pesquisa experimental computacional, na qual os quatro modelos são implementados, treinados e avaliados sob condições controladas e reproduzíveis, com registro protocolar de todos os parâmetros de entrada e métricas de saída a cada experimento.

3.2 Pipeline Metodológico

O pipeline metodológico proposto organiza-se em sete estágios sequenciais, descritos a seguir.

3.2.1 Estágio 1 — Aquisição e Organização dos Dados

Neste estágio, os dados de imagens de folhas são obtidos a partir de fontes públicas da literatura, incluindo o PlantVillage (Mohanty; Hughes; Salathé, 2016), subconjuntos de datasets referenciados nos artigos revisados (Islam et al., 2023; Joseph; Pawar; Chakradeo, 2024) e datasets disponibilizados no Kaggle. As imagens são organizadas em estrutura de diretórios hierárquica por espécie e classe de anomalia, com separação aleatória estratificada em conjuntos de treino (70%), validação (15%) e teste (15%), utilizando *seed* fixa para garantir reprodutibilidade.

3.2.2 Estágio 2 — Pré-processamento

Todas as imagens são redimensionadas para 224×224 pixels e normalizadas com média e desvio-padrão do ImageNet. Técnicas de *data augmentation* são aplicadas ao conjunto de treino: rotação aleatória ($\pm 30^\circ$), espelhamento horizontal e vertical, variação de brilho e contraste ($\pm 20\%$), recorte aleatório (*random crop*) e adição de ruído gaussiano. O conjunto de validação e teste não recebe augmentação.

3.2.3 Estágio 3 — Construção do Baseline Ingênuo

Antes de aplicar arquiteturas com transferência de aprendizado, uma CNN ingênua (*naïve baseline*) é treinada do zero para estabelecer um piso de referência. Essa rede simples consiste em três blocos convolucionais (Conv2D + BatchNorm + ReLU + MaxPool) seguidos por uma camada *fully connected* com *dropout* e saída *softmax*. O objetivo é demonstrar quantitativamente o ganho proporcionado pelo *transfer learning*.

3.2.4 Estágio 4 — Treinamento com Transfer Learning

As quatro arquiteturas-alvo são inicializadas com pesos pré-treinados no ImageNet. O treinamento segue estratégia de *fine-tuning* progressivo em duas fases: na primeira fase, apenas as camadas finais de classificação são treinadas (10 épocas, taxa de aprendizado 1×10^{-3}); na segunda fase, as camadas superiores da rede são gradualmente descongeladas e treinadas com taxa de aprendizado reduzida (1×10^{-4} a 1×10^{-5} , 30–50 épocas). O otimizador Adam é utilizado com *weight decay* de 1×10^{-4} , e *early stopping* com paciência de 10 épocas monitora a perda no conjunto de validação.

3.2.5 Estágio 5 — Avaliação e Comparação de Desempenho

Cada modelo é avaliado no conjunto de teste utilizando: Acurácia global, Precisão (macro e por classe), Recall (macro e por classe), F1-Score (macro e por classe) e Matriz de Confusão. Os experimentos são executados com no mínimo 5 *seeds* aleatórias diferentes, e testes estatísticos não paramétricos (Wilcoxon ou Kruskal-Wallis) são aplicados para verificar significância das diferenças entre modelos.

3.2.6 Estágio 6 — Análise de Explicabilidade (Grad-CAM)

Mapas de ativação Grad-CAM são gerados para amostras representativas de cada classe e modelo, sobrepondo os mapas de calor às imagens originais. A análise qualitativa verifica se o modelo foca nas regiões de lesão foliar ou em artefatos irrelevantes. Essa análise é documentada visualmente na monografia e constitui um dos diferenciais metodológicos do trabalho.

3.2.7 Estágio 7 — Documentação e Reprodutibilidade

Todo o código-fonte é versionado em repositório público no GitHub, com documentação de execução (README), arquivo de dependências (requirements.txt), *seeds* fixas e scripts de reprodutibilidade. Os hiperparâmetros e métricas de cada execução são registrados via MLflow ou em planilha estruturada.

3.3 Caracterização do Ambiente Experimental

3.3.1 Hardware

O treinamento dos modelos será conduzido na plataforma Google Colab, utilizando GPU NVIDIA Tesla T4 (16 GB VRAM) ou equivalente. Para tarefas de pré-processamento e análise de resultados, será utilizado o computador pessoal do pesquisador.

3.3.2 Software

O ambiente de software é composto por: Python 3.10+; PyTorch como framework principal de aprendizado profundo; torchvision para acesso aos modelos pré-treinados e pipelines de augmentação; scikit-learn para cálculo de métricas; Matplotlib e Seaborn para visualizações; e Jupyter Notebook / Google Colab como ambiente interativo de experimentação.

3.4 Técnicas e Ferramentas para Análise de Dados

A análise de dados segue abordagem estatística quantitativa, compreendendo: análise de métricas de classificação calculadas pelo scikit-learn; Matriz de Confusão visualizada com Matplotlib e Seaborn; curvas de aprendizado por época para diagnóstico de sobreajuste; testes estatísticos não paramétricos para comparação entre modelos; e visualizações Grad-CAM para validação qualitativa das regiões de ativação.

3.5 Cronograma de Execução — TCC-II (2026/2)

Atividade	Abr	Mai	Jun	Jul	Ago	Set	Out
Revisão da literatura e redação Cap. 2	X	X					
Implementação do pipeline (Estágios 1–3)		X	X				
Treinamento e avaliação (Estágios 4–5)			X	X			
Análise Grad-CAM (Estágio 6)				X	X		
Redação da monografia (Cap. 3–5)				X	X	X	
Redação do artigo científico					X	X	

Revisão final e preparação da defesa						X	X
Defesa do TCC-II							X

Quadro 2 — Cronograma de execução do TCC-II.

4 MVP — PROJETO MÍNIMO VIÁVEL

4.1 Definição do MVP

O Projeto Mínimo Viável (MVP) desta pesquisa consiste em um pipeline computacional funcional e validado para classificação binária de anomalias em imagens de folhas de hortaliças — isto é, a capacidade de classificar corretamente uma imagem como **folha saudável** ou **folha com anomalia**, como prova de conceito da abordagem proposta. O MVP estabelece o piso de desempenho a partir do qual o trabalho avança para a classificação multiclasse e para a comparação sistemática entre as quatro arquiteturas definidas no escopo.

A escolha da classificação binária como MVP justifica-se por três razões: (a) reduz a complexidade da tarefa inicial, permitindo validar a integridade do pipeline antes de escalonar para múltiplas classes; (b) a classificação binária (*saudável vs. doente*) é a primeira decisão que um sistema de triagem fitossanitária deve ser capaz de tomar; e (c) o resultado serve como *baseline* quantitativo para mensurar o ganho incremental da classificação multiclasse.

4.2 Etapas do MVP

Para a validação do MVP, serão realizadas as seguintes etapas concretas e mensuráveis:

- a. Download e organização do dataset PlantVillage e dos subconjuntos de folhosas disponíveis nos datasets da literatura (Islam et al., 2023), com separação das classes em duas categorias (saudável e anômala) e divisão treino/validação/teste (70%/15%/15%) com seed fixa;
- b. Implementação do pipeline de pré-processamento com redimensionamento para 224×224 pixels, normalização com média e desvio-padrão do ImageNet, e aplicação de data augmentation básico (flip horizontal, rotação $\pm 15^\circ$ e variação de brilho $\pm 10\%$);
- c. Treinamento da CNN ingênua (baseline) do zero, composta por três blocos convolucionais seguidos por camada fully connected com dropout, para estabelecer o piso de desempenho sem transfer learning;
- d. Treinamento da arquitetura MobileNetV2 pré-treinada no ImageNet, com fine-tuning das últimas camadas para a tarefa de classificação binária — escolhida como modelo-piloto do MVP por sua eficiência computacional e relevância para cenários de edge AI;

- e. Avaliação de ambos os modelos (baseline e MobileNetV2) no conjunto de teste, com cálculo de Acurácia, Precisão, Recall e F1-Score, e geração da Matriz de Confusão, demonstrando quantitativamente o ganho do transfer learning;
- f. Geração de visualizações Grad-CAM para ao menos 10 imagens de teste do MobileNetV2, demonstrando que o modelo foca nas regiões relevantes das folhas (lesões, manchas, clorose) e não em artefatos de fundo.

4.3 Critério de Validação

O MVP é considerado **validado** quando as seguintes condições são simultaneamente atendidas:

1. O modelo MobileNetV2 com fine-tuning atinge $F1\text{-Score} \geq 0,85$ no conjunto de teste, resultado condizente com o estado da arte para tarefas de classificação binária com Transfer Learning em datasets de plantas (Mohanty; Hughes; Salathé, 2016; Jeyabose et al., 2022);
2. O modelo MobileNetV2 supera o baseline ingênuo por margem estatisticamente relevante (diferença de $F1\text{-Score} \geq 0,10$), validando empiricamente a hipótese de que transfer learning é superior ao treinamento do zero neste domínio;
3. As visualizações Grad-CAM confirmam qualitativamente que o modelo está focando em regiões patologicamente relevantes das folhas (lesões, manchas) e não em artefatos do dataset (bordas, fundo).

4.4 Evolução Pós-MVP

A partir do MVP validado, o trabalho avançará em três frentes:

- a. Classificação multiclasse: expansão da tarefa para múltiplas classes de anomalias (míldio, oídio, clorose, danos por pragas, saudável), permitindo diagnóstico mais específico;
- b. Comparação entre arquiteturas: treinamento e avaliação das quatro arquiteturas-alvo (ResNet-50, MobileNetV2, EfficientNet-B0 e ViT-B/16) sob condições idênticas, com análise estatística das diferenças de desempenho, conforme os Estágios 4 e 5 do pipeline metodológico;

- c. Análise de explicabilidade completa: geração de mapas Grad-CAM para todas as arquiteturas e classes, com análise comparativa de quais modelos produzem ativações mais consistentes e interpretáveis.

4.5 Reprodutibilidade

Todo o código desenvolvido para o MVP estará disponível em repositório público no GitHub, com documentação de execução (README), arquivo de dependências (requirements.txt), *seeds* fixas e scripts de reprodutibilidade, seguindo boas práticas de engenharia de software aplicada a projetos de Machine Learning. Os notebooks de treinamento e avaliação do MVP serão compatíveis com Google Colab, permitindo a reprodução sem infraestrutura local.

REFERÊNCIAS

- ABOELENIN, S. et al. A hybrid framework for plant leaf disease detection and classification using convolutional neural networks and vision transformer. *Complex & Intelligent Systems*, v. 11, 2025. DOI: 10.1007/s40747-024-01764-x.
- AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, v. 11, p. 9042-9057, 2023. DOI: 10.1109/access.2023.3240100.
- AHMAD, A.; SARASWAT, D.; GAMAL, A. A survey on using deep learning techniques for plant disease diagnosis and recommendations for development of appropriate tools. *Smart Agricultural Technology*, 2022. DOI: 10.1016/j.atech.2022.100083.
- AHMED, A.; REDDY, G. A mobile-based system for detecting plant leaf diseases using deep learning. *AgriEngineering*, v. 3, p. 30-32, 2021. DOI: 10.3390/agriengineering3030032.
- DEMILIE, W. Plant disease detection and classification techniques: a comparative study of the performances. *Journal of Big Data*, v. 11, p. 1-43, 2024. DOI: 10.1186/s40537-023-00863-9.
- DHANYA, V. et al. Deep learning based computer vision approaches for smart agricultural applications. *Artificial Intelligence in Agriculture*, 2022. DOI: 10.1016/j.aiaa.2022.09.007.
- DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: *INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR)*, 2021.
- FACELI, K. et al. *Inteligência artificial: uma abordagem de aprendizado de máquina*. 2. ed. Rio de Janeiro: LTC, 2023.
- GAJJAR, R. et al. Real-time detection and identification of plant leaf diseases using convolutional neural networks on an embedded platform. *The Visual Computer*, v. 38, p. 2923-2938, 2021. DOI: 10.1007/s00371-021-02164-9.
- GHOSH, H. et al. Advanced neural network architectures for tomato leaf disease diagnosis in precision agriculture. *Discover Sustainability*, v. 6, 2025. DOI: 10.1007/s43621-025-01149-1.
- GIL, A. C. *Como elaborar projetos de pesquisa*. 5. ed. São Paulo: Atlas, 2010.
- HE, K. et al. Deep residual learning for image recognition. In: *IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR)*, 2016. p. 770-778.
- IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. *Censo Agropecuário 2017: resultados definitivos*. Rio de Janeiro: IBGE, 2019. ISSN 0103-6157.
- ISLAM, A. et al. A deep learning approach for classification and segmentation of leafy vegetables and diseases. In: *INTERNATIONAL CONFERENCE ON NEXT-GENERATION COMPUTING, IOT AND MACHINE LEARNING (NCIM)*, 2023. p. 1-6. DOI: 10.1109/ncim59001.2023.10212506.
- JAFAR, A. et al. Revolutionizing agriculture with artificial intelligence: plant disease detection methods, applications, and their limitations. *Frontiers in Plant Science*, v. 15, 2024. DOI: 10.3389/fpls.2024.1356260.
- JEYABOSE, A. et al. Deep learning-based leaf disease detection in crops using images for agricultural applications. *Agronomy*, v. 12, n. 10, 2022. DOI: 10.3390/agronomy12102395.

- JOSEPH, D.; PAWAR, P.; CHAKRADEO, K. Real-time plant disease dataset development and detection of plant disease using deep learning. *IEEE Access*, v. 12, p. 16310-16333, 2024. DOI: 10.1109/access.2024.3358333.
- MOHANTY, S.; HUGHES, D.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, 2016. DOI: 10.3389/fpls.2016.01419.
- NGUGI, H. et al. Revolutionizing crop disease detection with computational deep learning: a comprehensive review. *Environmental Monitoring and Assessment*, v. 196, 2024. DOI: 10.1007/s10661-024-12454-z.
- NGUGI, L.; ABELWAHAB, M.; ABO-ZAHHAD, M. Recent advances in image processing techniques for automated leaf pest and disease recognition: a review. *Information Processing in Agriculture*, 2020. DOI: 10.1016/j.inpa.2020.04.004.
- PAÇAL, I.; IŞIK, G. Utilizing convolutional neural networks and vision transformers for precise corn leaf disease identification. *Neural Computing and Applications*, v. 37, p. 2479-2496, 2024. DOI: 10.1007/s00521-024-10769-z.
- PAYMODE, A.; MALODE, V. Transfer learning for multi-crop leaf disease image classification using convolutional neural networks VGG. *Artificial Intelligence in Agriculture*, 2022. DOI: 10.1016/j.aiia.2021.12.002.
- QIN, R. et al. Advancing precision agriculture with deep learning enhanced SIS-YOLOv8 for Solanaceae crop monitoring. *Frontiers in Plant Science*, v. 15, 2025. DOI: 10.3389/fpls.2024.1485903.
- RUSSELL, S.; NORVIG, P. *Artificial intelligence: a modern approach*. 4. ed. Upper Saddle River: Pearson, 2022.
- S, M.; R, G. Plant leaf disease detection using vision transformers for precision agriculture. *Scientific Reports*, v. 15, 2025. DOI: 10.1038/s41598-025-05102-0.
- SALEEM, M. et al. Image-based plant disease identification by deep learning meta-architectures. *Plants*, v. 9, 2020. DOI: 10.3390/plants9111451.
- SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: *IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR)*, 2018. p. 4510-4520.
- SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: *IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV)*, 2017. p. 618-626.
- SHAFIK, W. et al. A novel hybrid inception-xception convolutional neural network for efficient plant disease classification and detection. *Scientific Reports*, v. 15, 2025. DOI: 10.1038/s41598-024-82857-y.
- SHAFIK, W. et al. Using transfer learning-based plant disease classification and detection for sustainable agriculture. *BMC Plant Biology*, v. 24, 2024. DOI: 10.1186/s12870-024-04825-y.
- SHARMA, V.; TRIPATHI, A.; MITTAL, H. DLNC-Net: deeper lightweight multi-class classification model for plant leaf disease detection. *Ecological Informatics*, v. 75, 102025, 2023. DOI: 10.1016/j.ecoinf.2023.102025.
- TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: *INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML)*, 2019. p. 6105-6114.

THAKUR, P. et al. Vision transformer meets convolutional neural network for plant disease classification. *Ecological Informatics*, v. 77, 102245, 2023. DOI: 10.1016/j.ecoinf.2023.102245.

TIAN, Q. et al. Enhancing practicality of deep learning for crop disease identification under field conditions. *Pest Management Science*, 2024. DOI: 10.1002/ps.8317.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. *Artificial Intelligence Review*, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WANG, S. et al. Advances in deep learning applications for plant disease and pest detection: a review. *Remote Sensing*, v. 17, n. 4, 698, 2025. DOI: 10.3390/rs17040698.