

UNIVERSIDADE DA REGIÃO DE JOINVILLE — UNIVILLE

Bacharelado em Engenharia de Software

José Pedro Vieira Silva

Orientador: Prof. Laurindo Vilonga Dumba

**UM ESTUDO DE CASO: DETECÇÃO AUTOMÁTICA DE ANOMALIAS
FITOSSANITÁRIAS EM HORTALIÇAS FOLHOSAS UTILIZANDO VISÃO
COMPUTACIONAL E APRENDIZADO DE MÁQUINA**

Joinville — SC

2026

JOSÉ PEDRO

Orientador: Prof. Laurindo Vilonga Dumba

**DETECÇÃO AUTOMÁTICA DE ANOMALIAS FITOSSANITÁRIAS
EMHORTALIÇAS FOLHOSAS UTILIZANDO VISÃO COMPUTACIONAL E
APRENDIZADO DE MÁQUINA**

Trabalho de Conclusão de Curso-I
apresentado ao Curso de Engenharia de Software,
da Universidade da Região de Joinville — UNIVILLE,
como requisito parcial para a aprovação na disciplina
TCC-I, sob orientação do Professor Laurindo Vilonga
Dumba.

Joinville — SC

2026

Resumo

A detecção precoce de anomalias fitossanitárias em hortaliças folhosas é um desafio crítico para a agricultura brasileira, especialmente para pequenos e médios produtores que dependem de inspeção visual manual — processo sujeito a inconsistências e atrasos diagnósticos. Este trabalho propõe e valida um sistema de detecção automática de anomalias em hortaliças folhosas — alface, rúcula, espinafre, acelga e couve — utilizando técnicas de Visão Computacional e Aprendizado de Máquina. A abordagem adotada fundamenta-se em Transfer Learning com fine-tuning de três arquiteturas de redes neurais convolucionais pré-treinadas no ImageNet: ResNet-50 (He et al., 2016), MobileNetV2 (Sandler et al., 2018) e EfficientNet-B0 (Tan; Le, 2019). O dataset binário foi construído a partir de quatro fontes públicas do Kaggle, totalizando 210.832 imagens organizadas em classes saudável e anômalo, com split estratificado 70/15/15 e seed fixa. Os modelos foram treinados com otimizador AdamW (Loshchilov; Hutter, 2019), CosineAnnealingLR, AMP float16 e label smoothing (Müller; Kornblith; Hinton, 2019) em GPU RTX 3050 6 GB. O EfficientNet-B0 obteve os melhores resultados: Accuracy 99,01%, F1 macro 98,89%, com apenas 5,3M parâmetros — superando o ResNet-50 (25,6M parâmetros) em todas as métricas e em 41% menos tempo de treino, confirmando empiricamente a eficiência do compound scaling. O critério de validação original (F1 macro $\geq 0,85$) foi superado em 13,89 pontos percentuais. A análise de explicabilidade via Grad-CAM demonstra que os modelos focam em regiões patologicamente relevantes das folhas, validando a robustez dos diagnósticos. O sistema inclui interface web funcional com FastAPI e React 19 para uso em campo.

Palavras-chave: visão computacional; aprendizado de máquina; redes neurais convolucionais; transfer learning; hortaliças folhosas; detecção de anomalias fitossanitárias; Grad-CAM; EfficientNet.

Abstract

The early detection of phytosanitary anomalies in leafy vegetables is a critical challenge for Brazilian agriculture, especially for small and medium producers who rely on manual visual inspection — a process prone to inconsistencies and diagnostic delays. This work proposes and validates an automatic anomaly detection system for leafy vegetables — lettuce, arugula, spinach, chard, and kale — using Computer Vision and Machine Learning techniques. The approach is based on Transfer Learning with fine-tuning of three convolutional neural network architectures pre-trained on ImageNet: ResNet-50, MobileNetV2, and EfficientNet-B0. A binary dataset of 210,832 images from four public Kaggle sources was built, organized into healthy and anomalous classes with stratified 70/15/15 split. EfficientNet-B0 achieved the best results: 99.01% accuracy and 98.89% macro F1-score, with only 5.3M parameters — outperforming ResNet-50 (25.6M parameters) in all metrics and training 41% faster. The original validation criterion (macro F1 ≥ 0.85) was exceeded by 13.89 percentage points. Grad-CAM explainability analysis confirms that models focus on pathologically relevant leaf regions. A functional web interface with FastAPI and React 19 enables field deployment.

Keywords: computer vision; machine learning; convolutional neural networks; transfer learning; leafy vegetables; phytosanitary anomaly detection; Grad-CAM; EfficientNet.

Lista de Abreviaturas e Siglas

AMP	Automatic Mixed Precision
ABNT	Associação Brasileira de Normas Técnicas
CNN	Convolutional Neural Network (Rede Neural Convolucional)
CV	Computer Vision (Visão Computacional)
DL	Deep Learning (Aprendizado Profundo)
F1	F1-Score (média harmônica de Precisão e Recall)
GPU	Graphics Processing Unit
Grad-CAM	Gradient-weighted Class Activation Mapping
IBGE	Instituto Brasileiro de Geografia e Estatística
IA	Inteligência Artificial
ML	Machine Learning (Aprendizado de Máquina)
MVP	Minimum Viable Product (Projeto Mínimo Viável)
OOM	Out of Memory
TCC	Trabalho de Conclusão de Curso
ViT	Vision Transformer
VRAM	Video Random Access Memory
XAI	Explainable Artificial Intelligence (IA Explicável)

Sumário

1 DEFINIÇÃO DO PROJETO

- 1.1 Tema
- 1.2 Justificativa
 - 1.2.1 Delimitação
 - 1.2.2 Relevância Científica e Acadêmica
 - 1.2.3 Relevância Social
 - 1.2.4 Relevância para a Formação Acadêmica
 - 1.2.5 Viabilidade
 - 1.2.6 Questão de Pesquisa
- 1.3 Objetivo Geral
- 1.4 Objetivos Específicos

2 REVISÃO DA LITERATURA

- 2.1 Visão Computacional e Inteligência Artificial Aplicadas à Agricultura
- 2.2 Fundamentos de Aprendizado Profundo para Classificação de Imagens
- 2.3 Redes Neurais Convolucionais (CNNs)
- 2.4 Transfer Learning
- 2.5 Vision Transformers (ViTs) e Modelos Híbridos CNN+ViT
- 2.6 O Problema da Generalização (Domain Gap)
- 2.7 Inteligência Artificial Explicável (XAI) e Grad-CAM
- 2.8 Anomalias Fitossanitárias em Hortaliças Folhosas e Datasets Disponíveis
- 2.9 Trabalhos Relacionados

3 PROPOSTA E PROCEDIMENTOS METODOLÓGICOS

- 3.1 Caracterização do Delineamento de Pesquisa
- 3.2 Pipeline Metodológico
- 3.3 Caracterização do Ambiente Experimental
- 3.4 Técnicas e Ferramentas para Análise de Dados
- 3.5 Cronograma de Execução — TCC-II (2026/2)

4 MVP — PROJETO MÍNIMO VIÁVEL E RESULTADOS

- 4.1 Definição do MVP

4.2 Resultados Experimentais

4.3 Análise de Explicabilidade — Grad-CAM

4.4 Critério de Validação

4.5 Evolução Pós-MVP

4.6 Reprodutibilidade

REFERÊNCIAS

1 DEFINIÇÃO DO PROJETO

Este capítulo apresenta a definição do projeto de pesquisa, abrangendo o tema proposto, sua justificativa, a questão de pesquisa central e os objetivos geral e específicos que nortearão o desenvolvimento do trabalho.

1.1 Tema

O presente projeto de pesquisa situa-se na interseção entre Inteligência Artificial, Visão Computacional e Ciência de Dados aplicados ao Agronegócio. O tema central é a detecção automática de anomalias fitossanitárias — incluindo doenças, deficiências nutricionais e danos por pragas — em hortaliças folhosas, por meio de algoritmos de Aprendizado de Máquina e análise de imagens digitais.

A linha de pesquisa está alinhada com as áreas de atuação do orientador, Prof. Laurindo Vilonga Dumba, que abrangem Visão Computacional, Machine Learning, Inteligência Artificial e Ciência de Dados. A escolha de hortaliças folhosas como objeto de estudo justifica-se pela sua expressiva relevância econômica na agricultura familiar da região de Joinville e do Sul do Brasil, bem como pela viabilidade de obtenção de datasets públicos de qualidade para a condução dos experimentos.

1.2 Justificativa

A seguir, apresentam-se a delimitação do estudo, suas relevâncias e a questão de pesquisa que motiva o trabalho.

1.2.1 Delimitação

O estudo delimita-se à detecção de anomalias visuais em folhas de hortaliças folhosas, especificamente alface (*Lactuca sativa*), rúcula (*Eruca vesicaria*), espinafre (*Spinacia oleracea*), acelga (*Beta vulgaris* var. *cicla*) e couve (*Brassica oleracea* var. *acephala*). As anomalias alvo compreendem: (a) doenças fúngicas como míldio e oídio; (b) deficiências nutricionais como clorose por deficiência de nitrogênio; (c) danos por pragas como pulgões e lagartas minadores; e (d) estresse hídrico. A detecção é realizada a partir de imagens digitais obtidas de datasets públicos e, no próximo semestre, de coletas locais em hortas da região de Joinville.

1.2.2 Relevância Científica e Acadêmica

A aplicação de Deep Learning ao diagnóstico fitossanitário é um campo em crescimento exponencial. Mohanty, Hughes e Salathé (2016) demonstraram que modelos de CNN treinados no dataset PlantVillage atingem acurácias superiores a 99% em condições controladas, estabelecendo um marco para a área. Entretanto, a generalização para condições reais de campo e para culturas específicas — como as hortaliças folhosas no contexto brasileiro — ainda representa uma lacuna a ser explorada. Este trabalho contribui academicamente ao aplicar e comparar três arquiteturas modernas de Transfer Learning nesse contexto específico, gerando evidências empíricas relevantes e disponibilizando código reprodutível.

1.2.3 Relevância Social

Segundo o Censo Agropecuário de 2017 (IBGE, 2019), 77% dos estabelecimentos rurais brasileiros são de agricultura familiar. Esses produtores geralmente não dispõem de acesso a especialistas agrônomos de forma regular, dependendo de inspeção visual manual para o diagnóstico de problemas fitossanitários — processo lento, inconsistente e custoso. Uma ferramenta computacional acessível de diagnóstico automático pode democratizar o acesso à tecnologia de precisão, reduzir perdas de produção e contribuir para a segurança alimentar regional.

1.2.4 Relevância para a Formação Acadêmica

O desenvolvimento deste trabalho permite ao aluno consolidar competências fundamentais para um engenheiro de software moderno: programação orientada a dados, desenvolvimento e avaliação de modelos de ML, manipulação de frameworks de Deep Learning (PyTorch), versionamento de experimentos e escrita científica. A natureza interdisciplinar do projeto — conectando Engenharia de Software, IA e Agronomia — também estimula o pensamento sistêmico e a capacidade de aplicar conhecimento técnico a problemas reais de alto impacto.

1.2.5 Viabilidade

O projeto é tecnicamente viável dado que: (a) os principais datasets necessários são públicos e de acesso gratuito (PlantVillage, Kaggle); (b) os frameworks de Deep Learning são open-source e amplamente documentados; (c) o

treinamento dos modelos foi conduzido na GPU local RTX 3050 6 GB (CUDA 12.3) e pode ser reproduzido no Google Colab com GPU gratuita; (d) o orientador possui expertise nas áreas de Visão Computacional e Machine Learning, garantindo suporte técnico adequado.

1.2.6 Questão de Pesquisa

Como automatizar a detecção precoce de anomalias fitossanitárias em hortaliças folhosas utilizando técnicas de Visão Computacional e Aprendizado de Máquina, de modo a reduzir perdas na produção e apoiar decisões de manejo de pequenos e médios produtores rurais?

1.3 Objetivo Geral

Desenvolver e avaliar um sistema de detecção automática de anomalias fitossanitárias em hortaliças folhosas, utilizando técnicas de Visão Computacional e Aprendizado de Máquina, com ênfase na comparação entre três redes neurais convolucionais com Transfer Learning — ResNet-50, MobileNetV2 e EfficientNet-B0 — avaliadas neste semestre, com previsão de inclusão do Vision Transformer (ViT-B/16) no TCC-II, de modo a fornecer diagnósticos precisos e contribuir com um framework metodológico extensível a outras culturas agrícolas.

1.4 Objetivos Específicos

- a. Realizar revisão sistemática da literatura sobre detecção de doenças e anomalias em plantas por meio de Visão Computacional e Machine Learning;
- b. Construir um dataset binário de imagens de hortaliças folhosas com e sem anomalias, a partir de fontes públicas (PlantVillage, Kaggle) e, no próximo semestre, coleta local em Joinville;
- c. Implementar pipeline de pré-processamento de imagens com redimensionamento, normalização e técnicas de data augmentation;
- d. Treinar e comparar modelos de classificação baseados em Transfer Learning: ResNet-50, MobileNetV2 e EfficientNet-B0 (avaliados neste semestre), além de um baseline ingênuo; o ViT-B/16 está previsto para o TCC-II;
- e. Avaliar e comparar os modelos utilizando métricas de Precisão, Recall, F1-Score, Acurácia e Matriz de Confusão;

f. Aplicar a técnica Grad-CAM para validação da explicabilidade dos modelos e verificação das regiões de ativação;

g. Analisar e discutir a extensibilidade da metodologia proposta para outras culturas agrícolas;

h. Produzir monografia e artigo científico documentando a metodologia, os experimentos e os resultados obtidos.

2 REVISÃO DA LITERATURA

Este capítulo apresenta os fundamentos teóricos e o estado da arte que sustentam a proposta desta pesquisa. A revisão está organizada em nove subseções que cobrem desde os conceitos gerais de Inteligência Artificial e Visão Computacional aplicadas à agricultura até os trabalhos correlatos mais recentes.

2.1 Visão Computacional e Inteligência Artificial Aplicadas à Agricultura

A Inteligência Artificial (IA) e a Visão Computacional (CV) consolidaram-se como tecnologias habilitadoras para a agricultura de precisão, permitindo o monitoramento automatizado de culturas com redução de custos operacionais e dependência de especialistas humanos (Jafar et al., 2024; Upadhyay et al., 2025). Na perspectiva de Russell e Norvig (2022), um sistema de IA pode ser compreendido como um agente inteligente que percebe seu ambiente por meio de sensores e age sobre ele por meio de atuadores. No contexto agrícola, a câmera de um smartphone atua como sensor, captando imagens foliares em um ambiente parcialmente observável.

No Brasil, a agricultura familiar representa aproximadamente 77% dos estabelecimentos agropecuários, sendo que apenas cerca de 20% dos produtores familiares dispõem de acesso regular a assistência técnica especializada (IBGE, 2019). Essa lacuna torna particularmente relevante o desenvolvimento de sistemas automatizados de diagnóstico fitossanitário que possam ser operados por produtores sem formação técnica em fitopatologia.

O trabalho pioneiro de Mohanty, Hughes e Salathé (2016) demonstrou que redes neurais convolucionais treinadas no dataset PlantVillage eram capazes de classificar 26 doenças em 14 espécies de plantas com acurácia superior a 99%. Essa publicação marcou o início de uma intensa produção científica na área, que desde então expandiu-se para incorporar drones, sensores IoT, imagens multiespectrais e aplicativos móveis como mecanismos de captura e processamento (Dhanya et al., 2022; Jafar et al., 2024).

2.2 Fundamentos de Aprendizado Profundo para Classificação de Imagens

O aprendizado profundo (deep learning) constitui um subconjunto do aprendizado de máquina baseado em redes neurais artificiais com múltiplas camadas de representação. Conforme Russell e Norvig (2022, Cap. 18), uma rede neural feed-forward multicamadas é composta por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída, nas quais cada neurônio computa uma soma ponderada das entradas seguida pela aplicação de uma função de ativação não linear.

O processo de treinamento consiste na minimização de uma função de perda por meio do algoritmo de backpropagation, que propaga os gradientes do erro da camada de saída até a camada de entrada, ajustando os pesos sinápticos pela regra da descida pelo gradiente (Russell; Norvig, 2022). Faceli et al. (2023, Cap. 7) detalham o formalismo matemático desse ajuste, demonstrando que a convergência depende criticamente da taxa de aprendizado, do tamanho do lote e de técnicas de regularização como dropout e early stopping para prevenir o sobreajuste.

2.3 Redes Neurais Convolucionais (CNNs)

As Redes Neurais Convolucionais (CNNs) constituem a classe de arquitetura dominante para tarefas de classificação de imagens. Diferentemente das redes densas tradicionais, as CNNs exploram a estrutura espacial bidimensional das imagens por meio de três tipos principais de camadas: camadas convolucionais, que aplicam filtros aprendíveis para extrair mapas de características; camadas de pooling, que reduzem a dimensionalidade espacial preservando as características mais salientes; e camadas totalmente conectadas, que realizam a classificação final (Russell; Norvig, 2022, Cap. 18).

Dentre as arquiteturas investigadas neste trabalho, destacam-se três modelos representativos do estado da arte:

ResNet-50 (He et al., 2016): introduziu o conceito de conexões residuais (skip connections), que permitem o treinamento eficaz de redes com dezenas ou centenas de camadas ao mitigar o problema do gradiente desvanecente. A arquitetura com 50 camadas e 25,6M parâmetros tornou-se referência em tarefas de classificação e é amplamente utilizada como backbone para transferência de aprendizado em domínios agrícolas (Saleem et al., 2020).

MobileNetV2 (Sandler et al., 2018): projetada para dispositivos com recursos computacionais limitados, utiliza convoluções separáveis em profundidade e blocos residuais invertidos para reduzir drasticamente o número de parâmetros (3,4M), mantendo acurácia competitiva. Essa eficiência viabiliza a inferência em tempo real em smartphones — aspecto crucial para o cenário de edge AI na agricultura familiar (Ahmed; Reddy, 2021; Gajjar et al., 2021).

EfficientNet-B0 (Tan; Le, 2019): propôs um método de escalonamento composto (compound scaling) que equilibra sistematicamente profundidade, largura e resolução da rede com apenas 5,3M parâmetros, alcançando melhor relação acurácia/parâmetro. Os resultados experimentais deste trabalho confirmam empiricamente a tese de Tan e Le (2019): o EfficientNet-B0 superou o ResNet-50 em todas as métricas (Accuracy: 99,01% vs 98,71%; F1 macro: 98,89% vs 98,56%) apesar de ter 4,8× menos parâmetros e treinar em 41% menos tempo (6,46h vs 11,03h), demonstrando que o compound scaling é mais eficiente do que simplesmente aumentar a profundidade ou o número de parâmetros (Loshchilov; Hutter, 2019).

2.4 Transfer Learning

A transferência de aprendizado (transfer learning) consiste na reutilização de pesos sinápticos aprendidos em uma tarefa-fonte — tipicamente a classificação das 1.000 categorias do ImageNet — como ponto de partida para uma tarefa-alvo com dados escassos (Faceli et al., 2023, Cap. 7). O procedimento padrão envolve o congelamento das camadas iniciais da rede pré-treinada e o ajuste fino (fine-tuning) das camadas finais para o domínio específico.

Mohanty, Hughes e Salathé (2016) demonstraram que CNNs pré-treinadas no ImageNet, quando ajustadas no PlantVillage, atingiram acurácia de 99,35% na classificação de doenças em 14 espécies de plantas. No presente trabalho, as três arquiteturas avaliadas (ResNet-50, MobileNetV2 e EfficientNet-B0) são inicializadas com pesos pré-treinados no ImageNet e submetidas a fine-tuning progressivo, comparando a capacidade de adaptação de cada arquitetura avaliada neste semestre ao domínio de hortaliças folhosas.

2.5 Vision Transformers (ViTs) e Modelos Híbridos CNN+ViT

Os Vision Transformers (ViTs), introduzidos por Dosovitskiy et al. (2021), representam uma mudança de paradigma na classificação de imagens ao substituir as operações convolucionais pelo mecanismo de self-attention. A principal vantagem reside na capacidade de capturar dependências globais desde as primeiras camadas, identificando relações espaciais de longo alcance nas imagens foliares.

Modelos híbridos CNN+ViT têm se mostrado particularmente eficazes no diagnóstico foliar, atingindo acurácias de 98% a 100% em milho, uva e tomate (Ghosh et al., 2025; Aboelenin et al., 2025). Neste trabalho, a avaliação do ViT-B/16 está prevista para o TCC-II, quando serão disponibilizados recursos computacionais compatíveis com o treinamento dessa arquitetura (RTX 3050 6 GB VRAM tornaria cada execução de 30 épocas inviável: estimativa de 45–75 horas por execução, com risco de Out of Memory com $\text{batch_size} \leq 8$).

2.6 O Problema da Generalização (Domain Gap)

Um dos desafios mais críticos da literatura em diagnóstico foliar automatizado é a discrepância entre o desempenho em condições controladas de laboratório e o desempenho em condições reais de campo — fenômeno denominado domain gap (Ahmad; Gamal; Saraswat, 2023). Modelos treinados exclusivamente no PlantVillage, cujas imagens possuem fundo branco homogêneo, frequentemente atingem acurácias entre 95% e 99%. Contudo, quando avaliados em imagens capturadas no campo, a acurácia pode cair para entre 31% e 72% (Mohanty; Hughes; Salathé, 2016; Upadhyay et al., 2025).

No presente trabalho, o problema do domain gap é abordado mediante aplicação de técnicas de data augmentation no pipeline de treinamento e validação com múltiplos datasets. A coleta local de imagens em hortas produtivas da região de Joinville está prevista para o próximo semestre, permitindo validação em condições reais de campo brasileiro.

2.7 Inteligência Artificial Explicável (XAI) e Grad-CAM

A explicabilidade de modelos de aprendizado profundo — conhecida como Inteligência Artificial Explicável (XAI) — constitui uma exigência científica e prática para a adoção de sistemas de diagnóstico automatizado na agricultura. Conforme Faceli et al. (2023, Cap. 10), a interpretabilidade de um modelo é um critério de

avaliação tão relevante quanto a acurácia, especialmente em domínios nos quais as decisões impactam diretamente a produção e a segurança alimentar.

A técnica adotada neste trabalho é o Gradient-weighted Class Activation Mapping (Grad-CAM), proposta por Selvaraju et al. (2017). O Grad-CAM opera calculando os gradientes do escore da classe predita em relação aos mapas de características da última camada convolucional, gerando um mapa de calor bidimensional sobreposto à imagem original. No contexto desta pesquisa, o Grad-CAM cumpre dupla função: (a) validação científica — verifica se os modelos focam nas regiões de lesão foliar; e (b) confiança para o usuário final — que pode visualizar a justificativa da classificação.

2.8 Anomalias Fitossanitárias em Hortaliças Folhosas e Datasets Disponíveis

As hortaliças folhosas investigadas neste trabalho — alface, rúcula, espinafre, acelga e couve — são culturas de ciclo curto, alta perecibilidade e expressiva importância econômica na agricultura familiar da região Sul do Brasil (IBGE, 2019). As principais anomalias fitossanitárias que acometem essas culturas incluem doenças fúngicas como míldio e oídio, deficiências nutricionais manifestadas como clorose foliar, e danos mecânicos causados por pragas.

O dataset mais amplamente utilizado na literatura é o PlantVillage, que contém mais de 54.000 imagens de folhas de 14 espécies (Mohanty; Hughes; Salathé, 2016). Contudo, o PlantVillage apresenta limitações para o escopo deste trabalho: imagens capturadas em condições laboratoriais com fundo branco, e representação escassa de hortaliças folhosas. Esta lacuna justifica a estratégia de múltiplas fontes adotada e a coleta local planejada para o próximo semestre.

2.9 Trabalhos Relacionados

Esta seção apresenta uma síntese comparativa dos trabalhos mais relevantes identificados na revisão da literatura, organizados no Quadro 1.

Aut ores	C ultura	D ataset	Arq uitetura	A curáci a	Diferencial deste TCC
-------------	-------------	-------------	-----------------	------------------	-----------------------

Mohanty et al. (2016)	26 culturas	PlantVillage	AlexNet, GoogLeNet	9,35%	Foco em folhosas + 3 CNNs + Grad-CAM
Islam et al. (2023)	Folhosas	LeafyVClassification7BD	ResNet, YOLOv5	91%	Comparação de 3 CNNs + XAI
Thakur et al. (2023)	Múltiplas	PlantVillage	ViT + CNN híbrido	98%	Aplicação a folhosas + contexto BR
Too et al. (2019)	Múltiplas	PlantVillage	Fine-tuning CNNs	8,8%	Domínio folhosas + augmentation avançado
Ghosh et al. (2025)	Tomate	Próprio	Swin+EfficientNetV2	98%	Foco em folhosas + edge AI
Fito Vision (este TCC)	Folhosas	Multi-fonte 210k	EfficientNet-B0	9,01%	Folhosas + binário + Grad-CAM + web app

Quadro 1 — Comparação entre trabalhos relacionados e diferenciais do presente TCC.

Fonte: Elaboração própria (2026).

Conforme evidenciado no Quadro 1, o presente trabalho diferencia-se da literatura existente em quatro aspectos principais: (a) foco exclusivo em hortaliças folhosas, um nicho sub-representado; (b) comparação sistemática de três arquiteturas CNN — ResNet-50, MobileNetV2 e EfficientNet-B0 — com previsão de inclusão do ViT-B/16 no TCC-II; (c) utilização do Grad-CAM como ferramenta de validação científica; e (d) contextualização para a realidade da agricultura familiar brasileira.

3 PROPOSTA E PROCEDIMENTOS METODOLÓGICOS

Este capítulo detalha a proposta metodológica para o TCC-I e TCC-II, incorporando as decisões de escopo: avaliação de três arquiteturas CNN (ResNet-50, MobileNetV2, EfficientNet-B0) neste semestre, com ViT-B/16 adiado para o TCC-II por limitações de hardware, remoção do YOLOv8 do escopo, e coleta local em Joinville prevista para o próximo semestre.

3.1 Caracterização do Delineamento de Pesquisa

O presente trabalho caracteriza-se como uma pesquisa de natureza quantitativa, dado que os resultados são expressos por métricas numéricas objetivas (Precisão, Recall, F1-Score e Acurácia) e submetidos a análise estatística comparativa entre os modelos avaliados.

Quanto aos objetivos, trata-se de uma pesquisa exploratório-descritiva. O caráter exploratório manifesta-se na investigação de qual arquitetura — dentre ResNet-50, MobileNetV2 e EfficientNet-B0 (avaliadas neste semestre) — apresenta melhor desempenho no domínio específico de hortaliças folhosas. O caráter descritivo expressa-se na documentação sistemática do comportamento de cada modelo sob diferentes configurações experimentais.

O delineamento adota a estratégia de pesquisa experimental computacional, na qual os três modelos são implementados, treinados e avaliados sob condições controladas e reproduzíveis, com registro protocolar de todos os parâmetros de entrada e métricas de saída a cada experimento.

3.2 Pipeline Metodológico

O pipeline metodológico organiza-se em sete estágios sequenciais, descritos a seguir.

3.2.1 Estágio 1 — Aquisição e Organização dos Dados

Os dados de imagens de folhas são obtidos a partir de fontes públicas da literatura, incluindo o PlantVillage (Mohanty; Hughes; Salathé, 2016) e datasets disponibilizados no Kaggle. As imagens são organizadas em estrutura binária (saudável/anômalo), com separação aleatória estratificada em conjuntos de treino

(70%), validação (15%) e teste (15%), utilizando seed fixa (42) para garantir reprodutibilidade.

3.2.2 Estágio 2 — Pré-processamento

Todas as imagens são redimensionadas para 224×224 pixels e normalizadas com média e desvio-padrão do ImageNet. Técnicas de data augmentation são aplicadas ao conjunto de treino: rotação aleatória ($\pm 30^\circ$), espelhamento horizontal e vertical, variação de brilho e contraste ($\pm 20\%$), recorte aleatório e ColorJitter. O conjunto de validação e teste recebe apenas redimensionamento e normalização.

3.2.3 Estágio 3 — Construção do Baseline Ingênuo

Uma CNN ingênua é treinada do zero para estabelecer um piso de referência. Essa rede simples consiste em três blocos convolucionais seguidos por uma camada fully connected com dropout e saída softmax, demonstrando quantitativamente o ganho proporcionado pelo transfer learning.

3.2.4 Estágio 4 — Treinamento com Transfer Learning

As três arquiteturas avaliadas neste semestre são inicializadas com pesos pré-treinados no ImageNet e submetidas a fine-tuning. O otimizador AdamW (Loshchilov; Hutter, 2019) é utilizado com weight decay desacoplado de 1×10^{-4} , e label smoothing de 0,1 é aplicado à função de perda para melhorar a calibração das probabilidades (Müller; Kornblith; Hinton, 2019). O scheduler CosineAnnealingLR e early stopping com paciência de 10 épocas completam a configuração. AMP float16 reduz o tempo de treino sem perda de acurácia.

3.2.5 Estágio 5 — Avaliação e Comparação de Desempenho

Cada modelo é avaliado no conjunto de teste utilizando: Acurácia global, Precisão (macro e por classe), Recall (macro e por classe), F1-Score (macro e por classe) e Matriz de Confusão. O test set de 31.625 imagens foi separado antes do início do treino e nunca utilizado durante otimização, garantindo a validade estatística das comparações.

3.2.6 Estágio 6 — Análise de Explicabilidade (Grad-CAM)

Mapas de ativação Grad-CAM são gerados para amostras representativas de cada classe e modelo, sobrepondo os mapas de calor às imagens originais. A análise qualitativa verifica se o modelo foca nas regiões de lesão foliar ou em artefatos irrelevantes, documentada visualmente na monografia.

3.2.7 Estágio 7 — Documentação e Reprodutibilidade

Todo o código-fonte é versionado em repositório público no GitHub, com documentação de execução (README), arquivo de dependências (requirements.txt), seeds fixas (42) e scripts de reprodutibilidade. Os hiperparâmetros e métricas de cada execução são registrados em JSON estruturado.

3.3 Caracterização do Ambiente Experimental

3.3.1 Hardware

O treinamento dos modelos foi conduzido no computador pessoal do pesquisador, equipado com GPU NVIDIA RTX 3050 Laptop (6 GB VRAM, CUDA 12.3), processador Intel/AMD e 16 GB RAM. O ambiente Windows 11 Education foi utilizado. Reprodução via Google Colab (NVIDIA Tesla T4, 16 GB VRAM) está documentada no repositório GitHub do projeto.

3.3.2 Software

O ambiente de software é composto por: Python 3.12; PyTorch 2.5.1+cu121 como framework principal; torchvision para acesso aos modelos pré-treinados e pipelines de augmentação; scikit-learn para cálculo de métricas; FastAPI + Uvicorn para o backend da API; React 19 + TypeScript + Vite 6 para o frontend; SQLite async para persistência de histórico; e Matplotlib/Seaborn para visualizações.

3.4 Técnicas e Ferramentas para Análise de Dados

A análise de dados segue abordagem estatística quantitativa, compreendendo: análise de métricas de classificação calculadas pelo scikit-learn; Matriz de Confusão visualizada com Matplotlib e Seaborn; curvas de aprendizado por época para diagnóstico de sobreajuste; e visualizações Grad-CAM para validação qualitativa das regiões de ativação de cada arquitetura.

3.5 Cronograma de Execução — TCC-II (2026/2)

Atividade	br	ai	un	ul	go	et	ut
Revisão da literatura e redação Cap. 2							
Implementação do pipeline (Estágios 1–3)							
Treinamento e avaliação (Estágios 4–5)							
Análise Grad-CAM + ViT-B/16 (Estágio 6)							
Coleta local em Joinville							
Redação da monografia (Cap. 3–5)							
Redação do artigo científico							
Revisão final e preparação da defesa							
Defesa do TCC-II							

Quadro 2 — Cronograma de execução do TCC-II.

Fonte: Elaboração própria (2026).

4 MVP — PROJETO MÍNIMO VIÁVEL E RESULTADOS

Este capítulo descreve o Projeto Mínimo Viável (MVP) do FitoVision, apresentando os resultados experimentais obtidos com o treinamento e avaliação das três arquiteturas, a análise de explicabilidade via Grad-CAM e a interface web desenvolvida para uso em campo.

4.1 Definição do MVP

O MVP consiste em um pipeline computacional funcional e validado para classificação binária de anomalias em imagens de folhas de hortaliças — classificação correta de uma imagem como **folha saudável** ou **folha com anomalia**, como prova de conceito da abordagem proposta. O MVP estabelece o piso de desempenho a partir do qual o trabalho avança para a classificação multiclasse e para a comparação sistemática entre mais arquiteturas no TCC-II.

A escolha da classificação binária como MVP justifica-se por três razões: (a) reduz a complexidade da tarefa inicial, permitindo validar a integridade do pipeline; (b) a classificação binária (saudável vs. anômalo) é a primeira decisão que um sistema de triagem fitossanitária deve ser capaz de tomar; e (c) o resultado serve como baseline quantitativo para mensurar o ganho incremental da classificação multiclasse.

4.2 Resultados Experimentais

Os três modelos foram treinados por 30 épocas no dataset de 210.832 imagens (147.582 treino, 31.625 validação, 31.625 teste). A avaliação final foi realizada no test set — nunca visto durante treino ou validação. Os resultados são apresentados na Tabela 1.

Modelo	Parâmetros	Acurácia	F1 Macro	Recisão	F1 Recall	N	Latência	Tempo
EfficientNet-B0 ★	7,3M	9,01%	8,89%	8,93%	8,85%	38	4,1 ms	2,46h
MobileNetV2	7,4M	8,81%	8,67%	8,69%	8,65%	79	4,3 ms	5,4h

ResNe									
t-50	5,6M	8,71%	8,56%	8,54%	8,59%	15	6,7 ms	1	1,03h

Tabela 1 — Comparativo de desempenho no test set de 31.625 imagens. ★ Modelo em produção. *FN = Falsos Negativos (doença não detectada — erro mais crítico). **Inclui overhead de cold cache e throttle noturno; tempo real estimado em 6–7h.

Fonte: Elaboração própria (2026).

O EfficientNet-B0 obteve os melhores resultados em todas as métricas, sendo escolhido como modelo de produção do sistema. Um achado relevante é que o ResNet-50, apesar de possuir 4,8× mais parâmetros que o EfficientNet-B0 (25,6M vs 5,3M), ficou em último lugar em todas as métricas. Isso confirma empiricamente a tese central de Tan e Le (2019): o compound scaling — escalar profundidade, largura e resolução simultaneamente — é mais eficiente do que simplesmente aumentar a profundidade ou o número de parâmetros.

A diferença entre val_acc e test_acc é mínima em todos os modelos (máximo 0,05 pp), confirmando que os modelos generalizaram bem e não sofreram overfitting ao conjunto de validação. O critério original do TCC ($F1 \text{ macro} \geq 0,85$) foi superado em 13,89 pontos percentuais pelo EfficientNet-B0 (98,89%).

A análise dos falsos negativos (doenças não detectadas) é especialmente relevante no contexto agrônomo: um falso negativo significa que uma planta doente foi classificada como saudável, podendo levar ao alastramento da doença. O EfficientNet-B0 obteve o menor número de falsos negativos (138), seguido pelo MobileNetV2 (179) e ResNet-50 (215).

4.3 Análise de Explicabilidade — Grad-CAM

A técnica Grad-CAM (Selvaraju et al., 2017) foi aplicada aos três modelos treinados para verificar qualitativamente se as regiões de ativação correspondem a áreas patologicamente relevantes das folhas. O código de geração dos mapas está implementado em `backend/app/ml/gradcam.py` e foi executado sobre amostras representativas do test set, gerando 30 mapas de calor (10 por modelo: quatro folhas saudáveis classificadas corretamente, quatro folhas anômalas classificadas corretamente e dois falsos negativos).

A Figura 1 apresenta os mapas Grad-CAM para folhas anômalas classificadas corretamente, organizados em três linhas (uma por arquitetura) e quatro colunas (pares imagem original / mapa de calor). Observa-se que o EfficientNet-B0 (segunda

linha) concentra as ativações de forma mais quente e localizada sobre as lesões foliares, enquanto o ResNet-50 (terceira linha) apresenta ativações mais dispersas em algumas imagens — comportamento coerente com seu maior número de falsos negativos (215 contra 138 do EfficientNet-B0).




Figura 1 — Mapas Grad-CAM para folhas anômalas classificadas corretamente. Linhas: MobileNetV2, EfficientNet-B0 e ResNet-50. Valores indicam a confiança da predição.

Fonte: Elaboração própria (2026).

A Figura 2 apresenta os mapas para folhas saudáveis. Nesse caso, os mapas de calor são mais difusos e frios, comportamento esperado: na ausência de lesões localizadas, não há uma região específica para o modelo destacar. Esse resultado valida que os modelos aprenderam características de textura foliar global, e não artefatos de fundo ou viés de aquisição. Nota-se ainda que o MobileNetV2 apresentou confiança reduzida (63%) em uma folha com iluminação lateral atípica, coerente com sua menor robustez a variações de campo.




Figura 2 — Mapas Grad-CAM para folhas saudáveis classificadas corretamente. A ativação difusa é esperada na ausência de lesões localizadas.

Fonte: Elaboração própria (2026).

A Figura 3 apresenta a análise dos falsos negativos — folhas anômalas incorretamente classificadas como saudáveis. Este é o achado de maior relevância

científica deste trabalho: as imagens que geraram falsos negativos correspondem a folhas de morfologia compostas (mandioca e plantas similares), substancialmente diferentes das hortaliças folhosas presentes no conjunto de treino. A confiança das predições nesses casos é significativamente menor (entre 52% e 86%) do que nas classificações corretas (entre 94% e 99%), indicando que os modelos apresentam maior incerteza diante de imagens fora do domínio de treino.




Figura 3 — Mapas Grad-CAM para falsos negativos (anômala classificada como saudável). A baixa confiança e as ativações dispersas evidenciam o problema do domain gap.

Fonte: Elaboração própria (2026).

Esse comportamento confirma empiricamente o problema do domain gap descrito na Seção 2.6: modelos treinados predominantemente em imagens de condições controladas apresentam degradação de desempenho quando expostos a imagens com morfologia ou contexto de aquisição distintos. A análise de explicabilidade, portanto, cumpriu papel não apenas de validação dos acertos, mas também de diagnóstico das limitações do sistema — fornecendo justificativa empírica direta para a coleta local de imagens em campo na região de Joinville, prevista para o TCC-II. A capacidade de identificar a baixa confiança nesses casos também sugere a viabilidade de um mecanismo de limiar de confiança (threshold) para sinalizar predições incertas ao usuário, a ser investigado no próximo semestre.

4.4 Critério de Validação

O MVP é considerado **validado** quando as seguintes condições são simultaneamente atendidas:

1. O modelo EfficientNet-B0 com fine-tuning atinge F1-Score macro $\geq 0,85$ no conjunto de teste — **resultado obtido: 98,89%** (+13,89 pp acima do critério);
2. O modelo supera o baseline ingênuo por margem estatisticamente relevante (diferença de F1-Score $\geq 0,10$), validando empiricamente a hipótese de que transfer learning é superior ao treinamento do zero neste domínio — **critério atendido**;
3. As visualizações Grad-CAM confirmam qualitativamente que o modelo está focando em regiões patologicamente relevantes das folhas — **confirmado** para o EfficientNet-B0.

4.5 Evolução Pós-MVP

O MVP validado neste semestre estabelece a base metodológica e o piso de desempenho do FitoVision. A partir dele, o trabalho avançará em quatro frentes principais no TCC-II, com foco no refinamento do modelo e na validação em condições reais:

- a. Refinamento e mitigação do domain gap: os falsos negativos identificados pela análise Grad-CAM (Seção 4.3) demonstram que o sistema atual, treinado predominantemente em imagens de condições controladas, apresenta degradação diante de imagens de campo. A coleta local de imagens em hortas produtivas da região de Joinville permitirá re-treinar e validar os modelos em condições representativas do contexto agrícola brasileiro, com expectativa de redução dos falsos negativos;
- b. Inclusão do ViT-B/16 (Dosovitskiy et al., 2021): o Vision Transformer não foi treinado neste semestre devido à limitação de memória da GPU disponível (RTX 3050, 6 GB VRAM), que tornaria cada execução de 30 épocas inviável (estimativa: 45–75 horas, com risco de Out of Memory com $\text{batch_size} \leq 8$). Seu estudo comparativo está previsto para o TCC-II utilizando Google Colab Pro ou servidor com GPU de maior capacidade;
- c. Classificação multiclasse: expansão da tarefa de classificação binária (saudável/anômalo) para múltiplas classes de anomalias (míldio, oídio,

clorose, danos por pragas), permitindo diagnóstico mais específico e acionável pelo produtor;

- d. Mecanismo de limiar de confiança: a observação de que os falsos negativos apresentam confiança significativamente menor sugere a viabilidade de um threshold que sinalize predições incertas, encaminhando esses casos para revisão — funcionalidade a ser investigada e validada no próximo semestre.

4.6 Reprodutibilidade

Todo o código desenvolvido para o MVP está disponível em repositório público no GitHub, com documentação de execução (README), arquivo de dependências (requirements.txt), seeds fixas (42) e scripts de reprodutibilidade. Os pesos dos modelos treinados estão disponibilizados em ``backend/weights/``. O sistema pode ser executado localmente com ``python run.py`` (backend) e ``npm run dev`` (frontend), ou reproduzido no Google Colab utilizando os notebooks disponíveis no repositório.

REFERÊNCIAS

ABOELENIN, S. et al. A hybrid framework for plant leaf disease detection and classification using convolutional neural networks and vision transformer. *Complex & Intelligent Systems*, v. 11, 2025. DOI: 10.1007/s40747-024-01764-x.

AHMAD, A.; GAMAL, A.; SARASWAT, D. Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, v. 11, p. 9042-9057, 2023. DOI: 10.1109/access.2023.3240100.

AHMAD, A.; SARASWAT, D.; GAMAL, A. A survey on using deep learning techniques for plant disease diagnosis and recommendations for development of appropriate tools. *Smart Agricultural Technology*, 2022. DOI: 10.1016/j.atech.2022.100083.

AHMED, A.; REDDY, G. A mobile-based system for detecting plant leaf diseases using deep learning. *AgriEngineering*, v. 3, p. 30-32, 2021. DOI: 10.3390/agriengineering3030032.

DEMILIE, W. Plant disease detection and classification techniques: a comparative study of the performances. *Journal of Big Data*, v. 11, p. 1-43, 2024. DOI: 10.1186/s40537-023-00863-9.

DHANYA, V. et al. Deep learning based computer vision approaches for smart agricultural applications. *Artificial Intelligence in Agriculture*, 2022. DOI: 10.1016/j.aiia.2022.09.007.

DOSOVITSKIY, A. et al. An image is worth 16x16 words: transformers for image recognition at scale. In: *INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR)*, 2021.

FACELI, K. et al. *Inteligência artificial: uma abordagem de aprendizado de máquina*. 2. ed. Rio de Janeiro: LTC, 2023.

GAJJAR, R. et al. Real-time detection and identification of plant leaf diseases using convolutional neural networks on an embedded platform. *The Visual Computer*, v. 38, p. 2923-2938, 2021. DOI: 10.1007/s00371-021-02164-9.

GHOSH, H. et al. Advanced neural network architectures for tomato leaf disease diagnosis in precision agriculture. *Discover Sustainability*, v. 6, 2025. DOI: 10.1007/s43621-025-01149-1.

GIL, A. C. Como elaborar projetos de pesquisa. 5. ed. São Paulo: Atlas, 2010.

HE, K. et al. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016. p. 770-778.

IBGE — INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Censo Agropecuário 2017: resultados definitivos. Rio de Janeiro: IBGE, 2019. ISSN 0103-6157.

ISLAM, A. et al. A deep learning approach for classification and segmentation of leafy vegetables and diseases. In: INTERNATIONAL CONFERENCE ON NEXT-GENERATION COMPUTING, IOT AND MACHINE LEARNING (NCIM), 2023. p. 1-6. DOI: 10.1109/ncim59001.2023.10212506.

JAFAR, A. et al. Revolutionizing agriculture with artificial intelligence: plant disease detection methods, applications, and their limitations. *Frontiers in Plant Science*, v. 15, 2024. DOI: 10.3389/fpls.2024.1356260.

JEYABOSE, A. et al. Deep learning-based leaf disease detection in crops using images for agricultural applications. *Agronomy*, v. 12, n. 10, 2022. DOI: 10.3390/agronomy12102395.

JOSEPH, D.; PAWAR, P.; CHAKRADEO, K. Real-time plant disease dataset development and detection of plant disease using deep learning. *IEEE Access*, v. 12, p. 16310-16333, 2024. DOI: 10.1109/access.2024.3358333.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 2019.

MOHANTY, S.; HUGHES, D.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, 2016. DOI: 10.3389/fpls.2016.01419.

MÜLLER, R.; KORNBLITH, S.; HINTON, G. When does label smoothing help? In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2019.

NGUGI, H. et al. Revolutionizing crop disease detection with computational deep learning: a comprehensive review. *Environmental Monitoring and Assessment*, v. 196, 2024. DOI: 10.1007/s10661-024-12454-z.

NGUGI, L.; ABELWAHAB, M.; ABO-ZAHHAD, M. Recent advances in image processing techniques for automated leaf pest and disease recognition: a review. *Information Processing in Agriculture*, 2020. DOI: 10.1016/j.inpa.2020.04.004.

PAÇAL, I.; IŞIK, G. Utilizing convolutional neural networks and vision transformers for precise corn leaf disease identification. *Neural Computing and Applications*, v. 37, p. 2479-2496, 2024. DOI: 10.1007/s00521-024-10769-z.

PAYMODE, A.; MALODE, V. Transfer learning for multi-crop leaf disease image classification using convolutional neural networks VGG. *Artificial Intelligence in Agriculture*, 2022. DOI: 10.1016/j.aiia.2021.12.002.

RUSSELL, S.; NORVIG, P. Artificial intelligence: a modern approach. 4. ed. Upper Saddle River: Pearson, 2022.

SALEEM, M. et al. Image-based plant disease identification by deep learning meta-architectures. *Plants*, v. 9, 2020. DOI: 10.3390/plants9111451.

SANDLER, M. et al. MobileNetV2: inverted residuals and linear bottlenecks. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2018. p. 4510-4520.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2017. p. 618-626.

SHAFIK, W. et al. A novel hybrid inception-xception convolutional neural network for efficient plant disease classification and detection. Scientific Reports, v. 15, 2025. DOI: 10.1038/s41598-024-82857-y.

SHAFIK, W. et al. Using transfer learning-based plant disease classification and detection for sustainable agriculture. BMC Plant Biology, v. 24, 2024. DOI: 10.1186/s12870-024-04825-y.

TAN, M.; LE, Q. V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 2019. p. 6105-6114.

THAKUR, P. et al. Vision transformer meets convolutional neural network for plant disease classification. Ecological Informatics, v. 77, 102245, 2023. DOI: 10.1016/j.ecoinf.2023.102245.

TOO, E. C. et al. A comparative study of fine-tuning deep learning models for plant disease identification. Computers and Electronics in Agriculture, v. 161, p. 272-279, 2019. DOI: 10.1016/j.compag.2018.03.032.

UPADHYAY, A. et al. Deep learning and computer vision in plant disease detection: a comprehensive review of techniques, models, and trends in precision agriculture. Artificial Intelligence Review, v. 58, 2025. DOI: 10.1007/s10462-024-11100-x.

WANG, S. et al. Advances in deep learning applications for plant disease and pest detection: a review. *Remote Sensing*, v. 17, n. 4, 698, 2025. DOI: 10.3390/rs17040698.